

오늘 배울 것

AI 데이터 인텔리전스 전문가 과정 · 모형추정과 심화통계

우도와 MLE — 데이터에서 모수로

동전 던지기 하나로 시작해서, 데이터에 숨은 모수를 알아내는 첫 번째 발상까지

오늘 배울 것

이 절에서 할 일

1. 오늘 하루를 관통하는 질문 하나를 던집니다.
2. 그 질문에 쓰는 낱말 넷 — 모수 · 추정 · 우도 · MLE 를 한 문장씩 정의합니다.
3. 네 절이 어떤 순서로 그 질문에 답해 가는지 확인합니다.

오늘은 딱 하나의 질문을 붙잡고 갑니다.


"동전을 10번 던졌더니 앞면이 7번 나왔다. 이 동전의 진짜 앞면 확률은 얼마일까?"

답이 0.7 근처라는 건 짐작이 갑니다. 오늘 할 일은 그 0.7 을 어떤 원리로 골랐는지 적어 두는 거예요. 그 원리에 붙은 이름이 **최대우도추정(MLE)** 이고, 로지스틱 회귀의 손실함수도 보험 요율 산정도 이 질문을 넓힌 것입니다.

먼저 낱말 넷을 맞추고 갑니다.

- ▶ **모수(parameter)** — 분포의 모양을 정하는 숫자입니다. 동전이면 앞면 확률 p 하나, 포아송이면 평균 건수 λ , 정규분포면 μ 와 σ 예요.
- ▶ **추정(estimation)** — 손에 든 데이터에서 거꾸로 그 모수를 알아내는 작업입니다. 방향이 「모수 → 데이터」가 아니라 「데이터 → 모수」로 뒤집힌 것이고, 추정한 값에는 모자를 씌워 $\hat{p}$ 처럼 적습니다.
- ▶ **우도(likelihood)** — 관측된 데이터가 모수 후보 하나하나를 얼마나 지지하는지 매기는 점수입니다. 기호로는 $L(p)$ 라 적어요.
- ▶ **최대우도추정(maximum likelihood estimation, MLE)** — 그 점수를 가장 크게 만드는 모수를 추정값으로 고르는 방법입니다. 데이터만 보고 고르기 때문에 관측이 적으면 값이 극단으로 튀는데, 그 장면은 4절에서 봅니다.

우도의 정의에는 세로줄 하나가 숨어 있습니다. 사진에 걸린 식에도 같은 기호가 보여요.



▲ 네온사인으로 걸린 베이즈 정리 — 오늘 쓰는 것은 등호 오른쪽 위의 $P(B|A)$, 곧 모수를 정해 놓았을 때 데이터가 나올 확률이다
(출처: Wikimedia Commons, mattbuck, CC BY-SA 3.0)

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

세로줄 | 는 "오른쪽은 이미 일어났다고 치고"라는 뜻입니다. 그래서 $P(A | B)$ 는 " B 가 일어난 상황에서 A 일 확률"로 읽어요. 이 표기로 $P(\text{앞면 7번} | p = 0.7)$ 을 읽으면 "앞면 확률이 0.7 이라고 치면 열 번 중 앞면이 7번 나올 확률"이 되고, 이 값이 곧 오늘 계산할 우도 $L(0.7)$ 입니다.

오늘은 이 식에서 **오른쪽 방향 하나만** 씁니다 — 모수를 정해 놓고 데이터의 확률을 재는 방향이요. 등호를 건너 왼쪽 $P(A | B)$, 곧 데이터를 보고 난 뒤의 모수로 뒤집는 일은 다음 권의 주제입니다.

더 깊이 — 등호 왼쪽으로 뒤집을 때 필요해지는 남은 두 조각

오늘 절 구성

다섯 절이 이 질문 하나를 순서대로 다룹니다.

절	이 절이 답하는 것
1절 들어가며 — 데이터에서 모수로	방향을 뒤집는다는 게 무슨 뜻인가
2절 우도 — 확률을 거꾸로 읽으면	같은 식을 모수의 함수로 읽으면 무엇이 달라지나
3절 MLE — 가장 그럴듯한 모수 찾기	점수가 가장 높은 자리를 어떻게 찾고, 그 값은 얼마나 흔들리나
4절 포아송 MLE와 소표본의 함정	관측이 적으면 그 답이 왜 극단으로 튀나

절

이 절이 답하는 것

5절 오늘의 정리와 수업에서 다룰 질문 오늘 배운 것을 한 장으로 압축하고, 답이 갈리는 질문 하나를 든다

읽는 동안 네 가지 도구가 번갈아 나옵니다.

1. **예측 탭** — 그림을 보기 전에 결과를 먼저 찍어 보는 무채점 입력란입니다.
2. **위젯** — 슬라이더를 밀면 그림이 즉시 바뀌는 화면입니다.
3. **실행 카드** — 본문의 숫자를 직접 돌려 보는 코드 셀입니다.
4. **인출 퀴즈** — 방금 읽은 것을 덮어 두고 떠올려 보는 문항입니다. 절 끝에 한 문항씩 놓이고, 길이가 긴 3절은 소단원 끝에도 한 문항이 들어갑니다.

자세히 — 네 도구를 각각 어떤 순서로 쓰나

읽고 나면 이걸 할 수 있습니다.

- ▶ 확률과 우도를 한 문장으로 구분하기 — 2절
- ▶ 베르누이와 포아송의 MLE 를 손으로 유도하기 — 3~4절
- ▶ 추정값 하나에 표준오차를 붙여 읽기 — 3절
- ▶ 관측이 몇 건뿐인 작은 집단에서 MLE 가 왜 0 이나 1 로 튀는지 설명하기 — 4절

그래서 오늘 하루는 이렇게 흘러갑니다. 모수 후보마다 점수를 매기는 함수를 만들고(2절), 그 점수가 가장 높은 자리를 찾고(3절), 그 자리가 얼마나 못 미더워지는 데까지 가는지 봅니다(4절). 첫 날말부터 맞추고 출발하죠 — 1절에서 '모수'와 '추정'을 정의합니다.

오늘 배우는 것은 하나입니다 — 데이터가 가장 강하게 지지하는 모수 하나를 고르는 법, 그리고 그 하나를 얼마나 믿어도 되는지.

02 · 코어 · 15분

1절 들어가며 — 데이터에서 모수로

확률 공부의 방향을 뒤집어 봅시다

이 절에서 할 일

1. 지금까지의 계산 방향을 뒤집어, 데이터에서 모수로 가는 방향을 잡습니다.
2. 분포의 모양을 정하는 숫자인 **모수**가 무엇인지 정규분포 곡선 하나로 확인합니다.
3. 그 모수를 데이터로 맞추는 **추정**이 왜 두 단계인지 정리합니다.

지금까지 푼 문제는 전부 한 방향이었어요. "앞면 확률이 0.5인 동전을 10번 던지면 앞면이 몇 번쯤 나올까?", "시간당 평균 3건 걸려오는 콜센터에 다음 1시간에 5건이 올 확률은?" — 둘 다 **0.5 와 3 을 이미 안다는 전제로** 앞으로 나올 데이터를 계산한 물음입니다.


현실은 순서가 반대예요. 손에 쥔 건 데이터뿐이고, 0.5 와 3 자리에 들어갈 숫자는 아무도 안 알려줍니다. 앞면이 7번 나온 그 동전도 마찬가지죠. 0.7일까요, 0.5인데 운이 좋았던 걸까요?

추정(estimation) — 데이터에서 출발해 분포의 모수를 거슬러 알아내는 작업입니다. 레시피를 보고 요리의 맛을 예상하던 것을 뒤집어, 한입 먹어 보고 레시피를 알아맞히는 거예요. 방향으로 적으면 데이터 → 모수입니다.

모수 — 분포의 모양을 결정하는 숫자

모수(parameter) — 확률분포의 모양을 결정하는 숫자입니다. 모수 값을 바꾸면 분포의 위치와 퍼짐이 함께 바뀌어요. 기호는 분포마다 달라서 베르누이는 p , 포아송은 λ , 정규는 μ 와 σ 로 적습니다.

분포	모수	이런 데이터에 씁니다
베르누이	p (성공 확률)	클릭했다/안 했다, 사고가 났다/안 났다
포아송	λ (단위시간당 평균 건수)	시간당 전화 수, 연간 사고 건수
정규	μ (중심), σ (퍼짐 — 제곱한 σ^2 이 분산)	키, 몸무게, 측정 오차



▲ 정규분포 — 모수 μ 와 σ 가 정해지면 곡선의 위치와 퍼짐이 전부 정해진다 (출처: Wikipedia)

그림 범례는 퍼짐을 σ^2 (시그마 제곱, 곧 **분산**)으로 적었어요. 위 표의 σ 와는 제곱 관계라, $\sigma^2 = 1.0$ 이면 $\sigma = 1$ 이고 $\sigma^2 = 0.2$ 면 $\sigma \approx 0.45$ 입니다.

네 곡선을 μ 값으로 나눠 읽어 봅시다. **파랑**($\sigma^2 = 0.2$)·**빨강**($\sigma^2 = 1.0$)·**노랑**($\sigma^2 = 5.0$) 셋은 σ^2 이 커지는 순서로 퍼짐이 넓어지는데, 셋 다 $\mu = 0$ 이라 봉우리 자리는 같습니다. 봉우리가 옮겨간 곡선은 **초록** 하나뿐이고, 그 이유는 $\sigma^2 = 0.5$ 가 아니라 $\mu = -2$ 예요 — 그래서 왼쪽으로 갔습니다.

그래서 봉우리 위치를 정하는 모수 μ 와 퍼짐을 정하는 모수 σ 는 서로 따로 정해집니다 — 한쪽을 바꿔도 다른 쪽이 하는 일은 바뀌지 않아요. 곡선이 이 두 숫자로 정해지니 "분포를 안다"는 말은 곧 "모수를 안다"는 말이에요. 앞으로 참값은 p , 데이터로 구한 값은 $\hat{p}$ ("피햇")로 구분해 적습니다.

[직접 해보기] 분포마다 모수가 모양을 바꾸는 방식

앞 표의 베르누이·포아송·정규에 둘이 더해져 탭이 다섯입니다 — **베르누이** · **이항 $B(10, \cdot)$** · **포아송** · **정규 $N(0, \cdot)$** · **지수**. **이항**은 베르누이 시행 n 번의 성공 **횟수**(동전 10번에 앞면 몇 번), **지수**는 다음 사건이 오기까지의 **대기 시간**이에요. 탭 이름의 괄호는 고정해 둔 모수라, **$B(10, \cdot)$** 의 10 은 시행 횟수 n 이고 가운데점 **$\cdot$** 자리가 슬라이더로 움직이는 모수(p)입니다.


누적분포함수(CDF, cumulative distribution function) — x 이하가 나올 확률입니다. 기호로는 $F(x) = P(X \leq x)$ 라 적고, 위 패널의 막대를 왼쪽부터 x 까지 더한 값이에요. 아래 **누적 확률** 패널이 그리는 것이 이 함수입니다.

1. **조작.** 위젯은 **포아송** 탭이 열린 채 시작하고, 오른쪽 **평균** 값 표시란에 7.00 이 찍혀 있습니다($\lambda = 7.0$). 위쪽 탭을 갈아끼우고 슬라이더로 모수를 움직입니다.
2. **관찰.** 위 패널의 **하늘색** 막대·곡선과 아래 **남색** 누적선, 오른쪽 **평균** · **분산** 숫자가 함께 갱신됩니다. 색이 곧 역할이에요 — 하늘색은 분포 그 자체, 남색은 그 하늘색을 왼쪽부터 더해 온 누적입니다.
3. **확인 질문.** 밀어 본 결과로 답해 보세요. **포아송** 탭에서 λ 를 2에서 8로 키웠을 때 봉우리는 어느 쪽으로 갔고 퍼짐은 어떻게 됐나요? 적었으면 **정규 $N(0, \cdot)$** 탭으로 옮겨 **표준편차 σ** 슬라이더도 끝까지 밀어 봅니다. 여기서는 퍼짐과 봉우리 자리 중 무엇이 움직이나요?

모수 하나가 분포의 모양을 전부 정한다.

확률분포 5종의 분포 모양과 누적확률, 확률질량·확률밀도

베르누이 이항 $B(10, \cdot)$ **포아송** 정규 $N(0, \cdot)$ 지수



슬라이더로 평균 λ 를 밀어 봉우리와 퍼짐이 함께 커지는지 보세요.

평균 발생률 λ 7.0

평균 7.00 · 분산 7.00



▼ 누적확률 패널 접기

가로·세로 눈금은 탭에 들어올 때 슬라이더 전 구간을 훑어 한 번만 잡는다. 모수를 밀어도 눈금이 그대로라 두 상태의 높이·폭을 곧바로 견줄 수 있다. 세로축은 이산형이 확률질량, 연속형이 확률밀도이고, 연속형은 높이가 아니라 면적이 확률이라 1을 넘을 수 있다.

자세히 — 포아송 $\lambda=4.5$ 에서 누적선의 0.53 이 막대 다섯 개의 합으로 나오는 과정

더 깊이 — 탭마다 달라지는 누적선의 모양, 그리고 베르누이 탭만 다른 이유

더 깊이 — 화면에서 읽히는 수와 읽히지 않는 수 (점선 따라가기와 눈금 사정)

포아송의 λ 와 정규의 σ 를 밀면 봉우리와 퍼짐 중 무엇이 움직이나 — 적어 본 뒤 열어 보세요

추정 — 후보 분포 중에서 고르기

모수를 모르는 채 데이터만 받았을 때, 발상은 의외로 단순해요. 모수 후보를 바꿔 가며 "이 값이었다면 지금 이 데이터가 나왔을 법한가"를 따져 보고, 가장 그럴듯한 값을 고르는 것. 그 '그럴듯함'을 점수로 바꾼 것이 다음 절의 우도입니다.

다만 데이터가 정해 주지 않는 것이 하나 있어요. 어느 분포를 쓸지는 우리가 먼저 고릅니다. 모수를 아무리 정확히 맞춰도 고른 분포가 데이터의 생김새와 어긋나면 추정값은 그 어긋남을 그대로 물려받아요. 4절에서 콜센터 기록을 세는 값으로 보고 포아송을 고르는 대목이 그 선택을 하는 자리예요.

그래서 추정은 두 단계예요. 분포를 먼저 고르고, 그다음 그 분포의 모수를 데이터로 맞추니다.

핵심 주의점

데이터로 구한 $\hat{p}$ 을 참값 p 와 같은 값으로 읽으면 안 됩니다.

$$\hat{p} = 0.7 \neq p$$

- ▶ p : 참값 — 동전이 실제로 가진 앞면 확률로, 우리는 아직 모릅니다
- ▶ $\hat{p}$: 추정값 — 손에 든 표본에서 읽어 낸 값

$\hat{p}$ 은 손에 든 표본 하나가 준 값이라, 같은 동전을 다시 10번 던지면 다른 값이 나옵니다. 따라서 "앞면이 7번 나왔으니 이 동전의 앞면 확률은 0.7 이다" 는 틀린 문장이예요.

정확한 뜻은 다음과 같습니다.

10번 던져 앞면 7번인 이 표본에서 읽어 낸 앞면 확률이 0.7 이고, 참값 p 는 아직 모른다.

모수는 분포의 모양을 정하는 숫자이고, 추정은 데이터를 보고 그 숫자가 얼마였는지 거꾸로 구하는 일입니다.

다음 절에서는 두 번째 단계의 '그럴듯함'을 우도라는 점수로 바꿔, 모수 후보마다 점수를 매겨 봅니다.

더 깊이 — 빈도주의와 베이즈주의, 오늘은 어느 쪽 입장을 따르나

초급

정규분포 그림에서 σ^2 이 커지면 봉우리 자리도 함께 오른쪽으로 옮겨간다.

☐ A O (맞다)

☒ B X (틀리다)

정답

정답입니다 🎉 다시 풀기

💡 그림 범례의 네 항목을 μ 값으로 나눠 보세요. σ^2 이 $0.2 \cdot 1.0 \cdot 5.0$ 으로 커지는 세 곡선은 모두 $\mu = 0$ 이라 봉우리가 같은 자리에 있고, 퍼짐만 달라집니다. 봉우리가 왼쪽으로 옮겨간 곡선은 σ^2 이 아니라 $\mu = -2$ 인 초록 곡선 하나뿐이에요. 위치를 정하는 모수와 퍼짐을 정하는 모수가 서로 따로 정해진다는 것이 이 그림의 결론입니다.

03 · 코어 · 23분 · 코드 2개

2절 우도 — 확률을 거꾸로 읽으면

"그럴듯함"을 점수로 매기기

이 절에서 할 일


1. 데이터를 고정해 두고 모수 후보마다 점수를 매기는 **우도**를 정의합니다.
2. 동전 3번에 앞면 2번을 놓고, 같은 값 하나를 확률로도 우도로도 읽어 봅니다.
3. 곱셈 덩어리인 우도를 덧셈으로 옮긴 **로그우도**를 만듭니다.

앞 절의 "데이터를 가장 잘 설명하는 모수를 고른다" 에서 '잘 설명한다' 를 숫자 하나로 적은 것이 우도입니다.

우도(likelihood, 가능성) — 데이터를 이미 관측된 상수로 고정해 두고, 모수 후보마다 "이 모수였다면 지금 이 데이터가 나올 가능성" 을 매긴 함수입니다. 기호로는 $L(p \mid x)$ 라 적고, 세로줄 오른쪽이 고정해 둔 쪽, 왼쪽이 움직이는 쪽이에요.

확률(probability) — 거꾸로 모수를 상수로 고정하고 데이터 x 를 움직여 재는 값입니다. 기호로는 $P(x \mid p)$ 라 적어요.

동전을 3번 던져 앞면이 2번 나왔다고 해 보죠. $p = 2/3$ 인 동전에서 이 데이터가 나올 확률은 0.444 — 확률 읽기예요. 같은 0.444 를 "앞면 2번을 본 뒤 후보 $p = 2/3$ 에 매긴 점수" 로 읽으면 우도고요. 후보 $p = 0.5$ 의 점수는 0.375 입니다. 계산은 하나인데 **무엇을 움직이느냐**가 다른 거죠.




▲ 관측된 데이터 5개(가로축의 주황 점 $x = 1, 4, 5, 6, 9$)를 주황·파랑 두 분포에 견준 그림 — 가로축의 점은 어느 한쪽 소속이 아니라 두 분포가 똑같이 설명해야 할 공통 관측치이고, 데이터가 몰린 곳에 봉우리를 둔 쪽이 훨씬 그럴듯하다 (출처: 공돌이의 수학정리노트)

"데이터가 몰린 자리에 봉우리를 둔 주황 쪽이 훨씬 그럴듯하다" — 이 판단을 숫자로 바꾼 것이 우도예요.

자세히 — 0.444 와 0.148, 순서를 세느냐 마느냐로 갈리는 두 값

우도를 실제로 계산하는 법 — 높이를 곱한다

데이터 점 하나의 그럴듯함은 그 점 위에서 **젠 곡선의 높이**입니다. 봉우리 근처는 높이가 크고 꼬리 끝은 작죠.



▲ 데이터 5개 위에서 **젠 곡선의 높이**(검은 세로 점선)를 전부 곱한 값이 그 분포의 **우도** (출처: 공돌이의 수학정리노트)

데이터가 여러 개면, 각 관측이 **독립**일 때 — 한 결과가 다른 결과에 영향을 주지 않을 때 — 전부 함께 일어날 가능성은 각자의 높이를 **곱한 값**이에요.

우도함수 $L(\theta)$ — 모수 후보 θ (세타)를 넣으면 그럴듯함 점수 하나가 나오는 함수입니다. 관측마다 **젠 높이**를 전부 곱해 만들어요.

$$L(\theta) = f(x_1; \theta) \times \cdots \times f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

- ▶ θ : 지금 값을 따져 보는 모수 후보 (동전이라면 p , 콜센터라면 λ)
- ▶ x_i : i 번째 관측 데이터 — 이미 관측됐으므로 **상수** 취급
- ▶ $f(x_i; \theta)$: x_i 지점에서 **젠 곡선의 높이**. 세미콜론 왼쪽은 이미 관측된 데이터, 오른쪽은 값을 따져 보는 모수예요
- ▶ $\prod_{i=1}^n$: $i = 1$ 부터 n 까지 전부 곱하라는 기호 (덧셈 $\sum$ 의 곱셈 형태)


동전에서 이 높이는 아주 단순해요. 앞면이면 $f(\text{앞}; p) = p$, 뒷면이면 $f(\text{뒤}; p) = 1 - p$ 라, 앞·앞(HH)이면 $L(p) = p^2$, 앞·앞·뒤(HHT)면 $L(p) = p^2(1 - p)$ 입니다.

그래서 확률 계산과 달라지는 지점은 하나뿐이에요 — 확률은 θ 를 고정하고 x 를, 우도는 x 를 고정하고 θ 를 움직입니다. 오늘 가장 중요한 한 문장이예요.

자세히 — pmf 와 pdf, 세미콜론과 세로줄, 같은 높이를 부르는 표기 셋

관측이 하나 늘면 곡선은 어떻게 될까

사례 1 — 앞·앞(HH). 식이 $L(p) = p^2$ 라 p 가 클수록 점수가 좋아지고, $L(1.0) = 1$ 이 최고점입니다. "두 번 다 앞면이면 앞면만 나오는 동전 아닐까?" — 성급하지만 데이터에는 충실한 판단이죠.



▲ HH 관측 후의 우도곡선 $L(p)=p^2$ — 가로축 P_H 는 앞면 확률, 곡선은 왼쪽에 낮게 깔리다 오른쪽 끝 $p=1$ 에서 가장 높다 (출처: Wikipedia)

자세히 — 곡선이 왼쪽에 깔리다 오른쪽 끝에서야 치솟는 까닭, 그리고 앞면이 k 번일 때의 모양


뒷면이 하나 섞이면 식에 $(1 - p)$ 가 곱해집니다. 그 한 번의 곱이 이 모양을 어디까지 바꿀까요.

예측 아래 내용이 열렸습니다

앞·앞(HH)에 뒷면이 하나 더해지면 우도곡선의 최고점은 어디로 옮겨 갈까요?

- 1 $p = 1.0$ 에 그대로 남는다
- 2 $p = 2/3 \approx 0.67$ 로 내려온다
- 3 $p = 0.5$ 까지 내려온다

예측 탭의 답은 두 번째, $p=2/3 \approx 0.67$ 로 내려온다 입니다. 사례 2 — 앞·앞·뒤(HHT)에서는 $p = 1$ 이면 뒷면이 나올 수 없어 점수가 0으로 떨어져요. 뒷면 하나가 최고점을 오른쪽 끝에서 안쪽 $2/3$ 으로 끌어옵니다.



▲ HHT 관측 후의 우도곡선 $L(p)=p^2(1-p)$ — 세로 눈금이 앞 그림의 0~1에서 0~0.16으로 내려앉은 가운데, 최고점은 오른쪽 끝 $p=1$ 을 떠나 안쪽으로 옮겨 온다 (출처: Wikipedia)

세로 눈금이 바뀌었으니 봉우리가 커 보여도 최고값은 1에서 0.148로 낮아진 거예요 — 최고점 자리의 값이 $L(2/3) = (2/3)^2 \times (1/3) = 4/27 = 0.148$ 입니다.

같은 식을 두 방향으로 — 그림 한 장으로 확인하기

상황을 먼저 정해 두죠. 동전을 **3번** 던졌고 **앞면이 2번** 나왔어요 — 이 한 문장이 우리 데이터($x = 2$)입니다.


아래 왼쪽 패널은 $p = 2/3$ 인 동전이라고 정해 놓고, 3번 던지면 앞면이 0·1·2·3번 나올 확률을 막대로 그린 것이예요. 우리가 본 2번의 막대가 0.444입니다.

오른쪽은 거꾸로 '**3번 중 2번**'을 고정해 놓고 후보 p 를 0에서 1까지 훑어, 눈금마다 " p 가 그 값인 동전이라면 앞면 2번이 나올 확률"을 세로 높이로 찍은 것입니다. 이 곡선이 **우도곡선** $L(p)$ 이고, 가장 높은 자리가 $p = 2/3$ 이예요.

같은 값을 왼쪽에서는 $P(x | p)$, 오른쪽에서는 $L(p | x)$ 라 부릅니다 — 숫자는 하나인데 이름이 둘이고, 두 패널은 회색 점선 하나 (0.444)에서 만나요.

확률은 막대 넷의 합이 1, 우도는 곡선 아래 넓이가 0.25다.

동전 3번 던져 앞면 2번, 같은 식 $P(x | p)$, 확률·우도 값



왼쪽은 모수를 $p = 2/3$ 으로, 오른쪽은 데이터를 $x = 2$ 로 고정했다. 두 패널의 세로 눈금은 같게 맞췄다.
자료: 모형추정과 심화통계 실습 예시 — 동전 3번 던지기 예시

▲ 동전 3번 던져 앞면 2번($x = 2$) — 왼쪽 확률은 모수 $p = 2/3$ 을 고정하고 데이터 x 를 움직인 것 | 오른쪽 우도는 데이터 $x = 2$ 를 고정하고 모수 p 를 움직인 것. 두 패널을 가로지르는 회색 점선 위에서 왼쪽 $x = 2$ 막대의 높이와 오른쪽 곡선의 봉우리가 같은 0.444에 선다

결과 해석 — 확률과 우도, 한 표에 정리

먼저 0.444의 정체부터. 앞면 확률이 $2/3$ 인 동전을 3번 던져 앞면이 정확히 2번 나올 확률이에요.

$$\binom{3}{2} \left(\frac{2}{3}\right)^2 \left(\frac{1}{3}\right) = 3 \times \frac{4}{9} \times \frac{1}{3} = \frac{12}{27} = 0.444$$

$\binom{3}{2}$ 는 "3번 중 어느 2번이 앞면인가"를 고르는 경우의 수, 곧 HHT·HTH·THH의 3이에요.

오른쪽 곡선의 높이도 여전히 '데이터가 나올 확률'입니다 — p 의 확률이 아니에요. 저 식의 $2/3$ 자리에 다른 후보를 넣으면 곡선의 다른 눈금이 나옵니다. $p = 0.5$ 를 넣은 0.375는 "0.5짜리 동전이라면 앞면이 2번 나올 확률"이죠. 곧 곡선 위의 점 하나하나가 서로 다른 동전의 확률표에서 항목 하나씩 떼어 온 값이고, 봉우리는 그중 데이터를 가장 잘 만들어 내는 후보가 $p = 2/3$ 이라는 뜻입니다.

왼쪽 막대 넷의 합은 정확히 1인데 오른쪽 곡선 아래 넓이는 0.25예요. 서로 다른 표에서 항목 하나씩 뽑아 온 값이라 더할 이유가 없거든요. 그래서 "우도는 확률이다"는 틀립니다.

	확률 (probability)	우도 (likelihood)
고정 / 변수	모수 θ 고정, x 이동	데이터 x 고정, θ 이동
답하는 질문	"이 모수라면 어떤 데이터가?"	"이 데이터라면 어떤 모수가?"
더하면/적분하면	정확히 1	1이 아닐 수 있음
쓰이는 순간	예측 (모수 → 데이터)	추정 (데이터 → 모수)

	확률 (probability)	우도 (likelihood)
예시 (3번 중 앞면 2번)	$p = 2/3$ 고정 → $P(x = 2) = 0.444$	$x = 2$ 고정 → $L(0.5) = 0.375, L(2/3) = 0.444$

더 깊이 — 적분이라는 말, 속 빈 원 표기, 두 패널이 계수를 넣은 식인 까닭

로그우도 — 곱셈을 덧셈으로

우도는 곱셈 덩어리인데, 1보다 작은 값을 수천 번 곱하면 컴퓨터에서 아예 **0으로 떨어집니다**. 0.5 짜리 동전을 2,000번 던진 데이터라면 $0.5^{2000} \approx 10^{-602}$ 이라, 64비트 실수가 담는 하한 아래로 내려가 0 으로 반올림돼요. 이것이 **언더플로(underflow)** 입니다.

로그우도(log-likelihood) $\ell(\theta)$ — 우도에 로그를 씌운 함수입니다. 로그가 곱을 합으로 바꿔 주므로($\log(ab) = \log a + \log b$) 곱셈 덩어리가 덧셈 덩어리가 돼요. 필기체 ℓ (엘)로 쓰고, 통계에서 그냥 $\log$ 라 적으면 밑이 $e \approx 2.718$ 인 자연로그입니다.

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$$

- ▶ $\ell(\theta)$: 로그우도 — 곱셈 대신 덧셈으로 계산되는 그럴듯함 점수
- ▶ $\sum_{i=1}^n \log f(x_i; \theta)$: 각 데이터의 "로그 높이" 를 전부 더한 것

그 0.5^{2000} 을 로그로 옮기면 $\log 0.5 = -0.693$ 을 2,000번 더한 값, 곧 $2000 \times (-0.693) = -1386$ 입니다. 0 으로 뭉개지던 값이 음수 하나가 된 거예요.

그래서 순위는 안 바뀝니다 — 로그는 **단조증가** 함수라 크기 순서를 뒤집지 않아요. L 이 가장 큰 자리가 곧 ℓ 도 가장 큰 자리, 두 최고점은 **정확히 같은 위치**입니다.

자세히 — 로그가 무엇에 답하는 함수이고, 왜 곱이 합이 되고, 왜 순서가 안 바뀌나

로그를 씌워도 최고점은 그 자리 — 눈으로 확인



세로축이 통째로 늘리는데도 정말 최고점이 안 움직일까요? 앞면 7/10 데이터로 두 곡선을 나란히 그려 봤습니다. 계수를 뺀 식, 곧 $L(p) = p^7(1-p)^3$ 이라 왼쪽 봉우리 높이는 $0.7^7 \times 0.3^3 = 0.0022$ 예요. 세로 눈금과 봉우리의 가로 위치를 나눠 읽어 주세요.

로그를 씌워 세로 눈금이 눌러도 최고점은 $p = 0.70$ 그대로다.

우도와 로그우도, 앞면 확률 p 별, 우도·로그우도 값

$$\text{우도 } L(p) = p^7(1-p)^3$$

$$\text{로그우도 } \ell(p) = 7 \log p + 3 \log(1-p)$$



동전 10번에 앞면 7번. p 가 0이나 1에 가까우면 로그우도는 음의 무한대로 내려가므로 뜻이 있는 구간 0.30~0.95만 그렸다.
자료: 모형추정과 심화통계 실습 예시 — 동전 10번에 앞면 7번 예시

▲ 왼쪽 우도 $L(p)$ | 오른쪽 로그우도 $\ell(p)$ — 세로 눈금은 0~0.002대와 -10~-6으로 전혀 다른데 최고점 자리($p = 0.70$, 회색 점선과 속 빈 원)는 두 그림이 같다 — 로그는 세로축만 바꾸고 가로축은 건드리지 못한다

회색 점선과 속 빈 원은 두 그림 모두 $p = 0.70$ 에 꽂혀 있어요. 그 0.70이 1절에서 약속한 추정값 $\hat{p}$ 이고, 오른쪽 봉우리의 $\ell = -6.11$ 은 왼쪽 봉우리 높이 0.0022에 로그를 씌운 값입니다.

그래서 로그가 세로축은 바뀌 놓았지만 가로축은 건드리지 못했어요. 계산이 편한 ℓ 을 최대화해도 원래 L 의 답을 그대로 얻는다는 뜻입니다.

자세히 — 라벨의 0.0022와 -6.11이 정말 같은 점수인지 계산

핵심 주의점

우도에서 p 를 확률변수처럼 해석하면 안 됩니다.

$$L(p \mid x = 2) = \binom{3}{2} p^2(1-p)$$

p 전체에 대해 더하거나 적분해도 1이 아닙니다 — 이 절 앞의 두 패널 그림(동전 3번에 앞면 2번)에서 오른쪽 우도곡선 아래 넓이가 0.25였죠. 따라서 0.444는 " $p = 2/3$ 일 확률이 44.4%"라는 뜻이 아니에요.

정확한 뜻은 다음과 같습니다.

$p = 2/3$ 인 동전을 3번 던져 앞면이 2번($x = 2$) 나올 확률이 0.444다.

남은 일은 하나죠 — 7/10 데이터에서 0.70처럼 점수가 가장 높은 후보를 집어 오는 것, 그게 다음 절입니다.

우도는 데이터를 고정해 놓고 모수 후보마다 매긴 우도함수이고, 로그우도는 그 함수를 곱셈에서 덧셈으로 옮겨 적은 같은 함수입니다.

초급

곡선 위의 한 점은 어디서 왔나

두 패널 그림의 오른쪽 곡선은 '3번 중 앞면 2번' 을 고정해 두고 앞면 확률 후보 p 를 훑은 것입니다. 앞에서 0.444 를 만들 때 쓴 식 그대로 $p = 0.9$ 자리의 높이를 손으로 계산하고, 그 값이 어느 동전의 확률표에서 어느 항목을 떼어 온 값인지 한 문장으로 짚어 보세요.

여기에 자신의 답을 작성해 보세요.

제출

04 · 코어 · 32분 · 코드 5개

3절 MLE — 가장 그럴듯한 모수 찾기

정의는 한 문장이면 끝

이 절에서 할 일

1. 우도가 가장 높은 후보를 고르는 규칙에 **MLE** 라는 이름을 붙입니다.
2. 그 규칙을 동전에 넣어, 답이 k/n 이라는 공식 하나로 풀리는 것을 확인합니다.
3. 같은 공식을 계약 67만 8천 건에 넣어 값 하나를 내고, 그 값에 붙는 표준오차까지 함께 읽습니다.

우도라는 점수 함수를 만들었으니 추정은 싱겁습니다. **점수가 가장 높은 후보를 뽑으면 끝이에요.**

최대우도추정(Maximum Likelihood Estimation, MLE) — 우도를 가장 크게 만드는 모수를 추정값으로 고르는 방법입니다. 기호로는 $\hat{\theta}_{MLE}$ 라 적어요. 그림으로 먼저 보면, 같은 데이터에서 봉우리가 어디에 서는지가 한눈에 들어옵니다.

▲ 동전을 10번 던져 앞면 수만 센 데이터($n=10$)의 우도함수 $L(p)$ — 빨강 $t=1$, 초록 $t=3$, 파랑 $t=6$ 의 최고점이 각각 0.1·0.3·0.6, 곧 t/n 자리에 선다 (출처: Wikipedia)

그림의 t 는 앞면 횟수라 본문의 k 와 같은 뜻이고, 성공 횟수만 센 이런 데이터를 다루는 분포는 뒤에서 이항분포라 부릅니다. 세로 눈금은 열 번 중 어느 자리가 앞면인지를 고르는 경우의 수까지 곱해 둔 값이라 다음 절에서 적을 $L(p) = p^k(1-p)^{n-k}$ 로 계산한 값보다 그만큼 크지만, 상수배는 봉우리의 가로 위치를 못 바꾸니 이 그림에서는 높이가 아니라 봉우리의 가로 좌표만 읽습니다.

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta} L(\theta) = \operatorname{argmax}_{\theta} \ell(\theta)$$

- ▶ θ (세타) : 추정하려는 **모수를 통칭하는 기호** — 동전이면 p , 콜센터라면 λ
- ▶ $\operatorname{argmax}_{\theta}$: 함수값을 최대로 만드는 **θ 지점** — $\max$ 가 산의 높이라면 argmax 는 정상 좌표예요

도함수 $\ell'(\theta)$ — 곡선 각 자리의 접선 기울기를 θ 의 함수로 적은 것입니다. 접선은 그 점에서 곡선과 같은 방향으로 뻗는 직선이고, 기울기는 가로로 1 갈 때 세로로 오르내리는 양이에요. 도함수를 구하는 작업이 **미분**이고요.

오르막이면 기울기가 양수, 내리막이면 음수인데 정상에서는 접선이 수평이라 0 입니다. 그래서 최고점 좌표는 **미분해서 0 이 되는 자리를 찾으면 나와요.**

베르누이 MLE — 동전의 진짜 p

첫 번째 예는 동전입니다.

베르누이 분포(Bernoulli distribution) — 성공(1) 아니면 실패(0), 두 값만 나오는 한 번의 시행을 맡는 분포입니다. 모수는 성공 확률 p 하나뿐이라 p 를 정하면 분포 전체가 정해져요.

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

$x = 1$ 이면 $p^1(1 - p)^0 = p$, $x = 0$ 이면 $p^0(1 - p)^1 = 1 - p$ — 두 경우를 한 식에 눌러 담은 표기예요.

▲ 서로 다른 동전 셋 — 세로축(Wahrscheinlichkeit)이 확률, 가로축 k 는 이 그림의 표기로 본문의 결과 $x(0=\text{실패}, 1=\text{성공})$ 에 해당한다(아래 식에서 쓰는 $k =$ 앞면 총 횟수와는 다른 기호다). 색은 동전의 p 값이고(빨강 0.8, 파랑 0.2, 초록 0.5) 막대 높이는 그 동전이 각 결과를 낼 확률이라, 빨강은 $k=1$ 에서 0.8, $k=0$ 에서 0.2 로 갈린다 (출처: Wikipedia)

동전을 n 번 독립으로 던져 앞면이 k 번 나왔다면, 던짐마다의 확률을 다 곱한 우도가 지수법칙 덕에 한 덩어리로 모입니다.

$$L(p) = p^k(1 - p)^{n-k}$$

- ▶ x : 한 번 던진 결과 — 앞면이면 1, 뒷면이면 0
- ▶ p : 앞면이 나올 확률 — 우리가 추정하려는 모수
- ▶ n : 던진 총 횟수
- ▶ k : n 번 가운데 앞면이 나온 총 횟수

앞면 7번·뒷면 3번이면 $L(p) = p^7(1 - p)^3$ 이죠. 베르누이를 n 번 반복해 성공 횟수만 센 것은 **이항분포(binomial distribution)** 라 부릅니다.

미분해서 0 — 답은 "표본 비율"

곱셈 덩어리는 미분하기 불편하니 로그를 씌워 $\ell(p) = k \log p + (n - k) \log(1 - p)$ 로 바꾼 뒤, p 로 미분해 0 으로 놓고 풁니다. 답은 공식 하나로 풀려요.

$$\hat{p}_{\text{MLE}} = \frac{k}{n} = \frac{\text{성공 횟수}}{\text{전체 시행 횟수}}$$

공식으로 바로 구하는 해(closed-form solution) — 미분해서 0 으로 놓은 방정식이 이렇게 공식 하나로 풀린 답입니다. 후보를 컴퓨터로 훑을 것 없이 나눗셈 한 번이면 값이 나와요. 베르누이에서 공식으로 바로 구하는 해가 표본 비율 k/n 입니다.

앞면 7번 / 전체 10번이면 $\hat{p} = 7/10 = 0.70$ 이고요.

자세히 — 미분 두 단계로 k/n 이 나오는 과정

접선이 도는 방향 — 2차 미분을 그림으로

기울기가 0 인 자리가 최댓값인지 최솟값인지는 한 번 더 미분해서 판정합니다.

2차 미분 $\ell''(p)$ — 기울기의 기울기입니다. 그림으로 옮기면 접선이 도는 방향이라, 음수면 접선이 시계 방향으로 돌아 그 자리가 봉우리이고 양수면 반대로 돌아 골짜기예요. 크기는 봉우리가 꼭대기에서 얼마나 뾰족한지로 읽고, 그 크기가 절 뒤에서 관측 정보량이 되어 표준오차로 이어집니다.

아래 그림에서 볼 것은 둘이에요 — 왼쪽은 접선 다섯 개가 한 방향으로만 도는지, 오른쪽은 그 ℓ'' 이 한 번이라도 0 위로 올라오는지. 한 방향으로만 돈다면 접선이 수평이 되는 자리는 하나뿐이고, 그 하나가 방금 구한 k/n 입니다.

오른쪽 패널의 $\ell''(p)$ 곡선은 p 를 0 에서 1 로 훑는 동안 0 선 위로 올라오는 자리가 있을까요?

- 1 한 번도 올라오지 않는다 — 어디서나 음수다
- 2 봉우리 $p = 0.70$ 근처에서만 0 위로 올라온다
- 3 양 끝, 곧 p 가 0 이나 1 에 가까울 때 두 곳에서 0 위로 올라온다

아무 답이나 골라 보세요 — 채점하지 않습니다. 고르면 바로 아래 내용이 열립니다.

▲ 앞면 7/10 로그우도 $\ell(p)$ 에 얹은 접선 다섯 개는 p 를 0.50 에서 0.90 으로 옮기는 동안 기울기가 $+8.0 \rightarrow +4.2 \rightarrow 0 \rightarrow -6.3 \rightarrow -22.2$ 로 줄고, 오른쪽 2차 도함수 $\ell''(p)$ 는 어디서나 0 선 아래다 — 접선이 한 방향으로만 도니 수평이 되는 자리는 $p = 0.70$ 한 곳뿐이고, 그 자리가 k/n 이다.

예측 탭의 답은 첫 번째, 한 번도 올라오지 않는다 — 어디서나 음수다 입니다. 오른쪽 패널에서 가장 높이 올라온 자리조차 -37.8 이라, 곡선이 0 선 아래를 한 번도 벗어나지 않아요. 한 방향으로만 도는 곡선이니 접선이 수평이 되는 자리도 $p = 0.70$ 하나뿐입니다.

식으로도 같은 답이 나와요. 앞 접힘에서 구한 $\ell''(p) = -\frac{k}{p^2} - \frac{n-k}{(1-p)^2}$ 은 $k > 0 \cdot n - k > 0$ 이고 분모가 제곱이라 늘 양수이니, 두 항 모두 음수입니다 — p 가 무엇이든 $\ell''(p) < 0$ 이고 로그우도는 구간 전체에서 위로 볼록($\cap$ 모양) 이에요. 앞면 $k = 7 \cdot$ 뒷면 $n - k = 3$ 에 봉우리 좌표 $p = 0.70$ 을 넣으면 $-7/0.49 - 3/0.09 = -14.3 - 33.3 = -47.6$ 이고, 오른쪽 패널에 찍힌 그 값이 이것입니다.

앞면 7번 / 전체 10번이면 $\hat{p} = 0.70$ — 거창한 유도의 결론이 그냥 "비율" 입니다. "100번 중 58번 클릭했으니 클릭률 58%" 라고 말할 때 이미 최대우도추정을 하고 있었던 거예요. MLE 는 새 값을 만드는 게 아니라 그 익숙한 계산에 근거를 붙여 주고, 덕분에 직관이 안 통하는 모형에서도 "우도를 최대화하라" 하나로 밀고 나갈 수 있어요.

방금 손으로 푼 로그우도는 코드로 옮기면 딱 두 행이에요.

</> 코드 2 수식이 코드로는 이 두 행 - 베르누이...

```
# 수식이 코드로는 이 두 행 - 베르누이 로그우도  $l(p) = k \log p + (n-k) \log(1-p)$ 
import numpy as np

def log_likelihood(p, k, n):
    return k * np.log(p) + (n - k) * np.log(1 - p)

# 앞면 7 / 10 이면  $l(0.7) = -6.11$ ,  $l(0.5) = -6.93$  - 0.7 쪽 점수가 더 높다
```

이 함수에 앞면 7/10 을 넣으면 $\ell(0.7) = -6.11$, $\ell(0.5) = -6.93$ 이 나옵니다. 로그를 씌우기 전 우도로는 $L(0.7) = 0.00222$ 대 $L(0.5) = 0.00098$ 이었으니, 두 후보의 순서가 로그 눈금에서도 그대로 지켜지는 거예요.

글로는 못 믿겠다면 — 직접 돌려 보기

로그를 씌워도 최고점은 안 움직인다, 그 최고점이 k/n 이다, 관측이 많아지면 곱셈이 0 으로 내려앉는다 — 이 셋을 아래 카드가 한번에 확인해 줍니다.

</> 코드 3 우도 최고점

```
1 # 우도 최고점 · 로그우도 최고점 · 공식  $k/n$  은 같은 자리인가
2 import numpy as np
3
4 k, n = 7, 10 # 앞면 7번 / 전체 10번
5 p = np.linspace(0.001, 0.999, 999) # p 후보 999개
6 L = p**k * (1 - p)**(n - k) # 우도
7 logL = k * np.log(p) + (n - k) * np.log(1 - p) # 로그우도
8
9 print(f"우도 L(p) 최고점 : p = {p[np.argmax(L)].3f}")
10 print(f"로그우도 l(p) 최고점 : p = {p[np.argmax(logL)].3f}")
11 print(f"공식 k/n : p = {k / n:.3f}")
12
13 # 관측이 2,000개로 늘면 곱셈은 어떻게 되나 (앞면 확률 0.6인 동전)
14 rng = np.random.default_rng(42)
15 probs = np.where(rng.random(2000) < 0.6, 0.6, 0.4) # 관측 하나하나의 확률값
16 print()
17 print("관측 2,000개를 그대로 곱하면 :", np.prod(probs))
18 print("같은 데이터의 로그우도 :", round(float(np.sum(np.log(probs))), 1))
```

결과 해석

위 세 행이 모두 $p = 0.700$ 을 가리킵니다 — 후보 999개를 훑은 컴퓨터와 미분 두 단계가 같은 좌표에 도착했어요. 아래 두 행은 로그가 왜 필요한지를 보여 줍니다. 관측 2,000개의 확률값을 그대로 곱하면 출력이 **0.0**, 값이 너무 작아 컴퓨터가 표현을 포기한 (언더플로) 거예요. 로그우도는 **-1348.1** 로 멀쩡히 남죠.

[직접 해보기] 접선의 기울기가 0이 되는 곳


'미분해서 0'을 이번엔 손으로 찾아봅시다. 아래 위젯은 앞면 7/10 로그우도 곡선에 접선을 얹어 둔 것이예요.

1. 조작. 슬라이더를 왼쪽 끝에서 오른쪽 끝까지 밀어 보세요.

2. **관찰.** 하늘색 접선이 남색 곡선 위를 미끄러집니다. 기울기 뒤 숫자는 오르막에선 +, 내리막에선 -로 바뀌어요. 딱 $p = 0.70$ (최댓값 $\hat{p} = 0.70$ 이라 적힌 자리)에서는 $+0.0$ 이 됩니다. 부호 자리가 +로 남아 있어도 크기가 0이라는 표시예요. 같은 값이 슬라이더 오른쪽 접선 기울기 $\ell'(p)$ 값 표시란에도 $+0.0$ 으로 찍힙니다. 바로 아래 문구는 **기울기 ≈ 0 : 여기가 최댓값이다**로 바뀌고요. 0.70을 벗어나 있을 때는 **오르막: 후보 p 를 더 오른쪽으로** 처럼 어느 쪽으로 밀지 알려줍니다.
3. **확인 질문.** 밀어 본 결과로 답해 보세요 — 슬라이더를 $p = 0.95$ 까지 밀면 기울기는 0에 가까워지나요, 더 큰 음수로 벌어지나요?

접선 기울기가 0이 되는 p 가 최대우도추정값이다.

동전 앞면 7회 / 10회 관측의 이항 로그우도 $\ell(p)$, 자연로그



슬라이더로 후보 p 를 밀어 접선 기울기가 0이 되는 자리를 찾아보세요.

후보 p 0.40



접선 기울기 $\ell'(p)$

+12.5

오르막: 후보 p 를 더 오른쪽으로

동전 앞면 7회 / 10회 관측의 이항 로그우도 $\ell(p) = 7 \cdot \ln p + 3 \cdot \ln(1-p)$. 양끝에서 $-\infty$ 로 발산하므로 뜻이 있는 구간 $p \in [0.03, 0.97]$ 만 그리고, 세로 범위도 그 구간의 값에서 한 번 잡아 고정했다 — 슬라이더를 밀어도 눈금은 움직이지 않는다.

$p = 0.95$ 에서 기울기가 0에 가까워지나 더 큰 음수로 벌어지나 — 적어 본 뒤 열어 보세요

초급

공식으로 바로 구한 해 $\hat{p} = k/n$ 은 미분으로 얻은 근사값이라, 후보 p 를 촘촘히 훑어 우도가 가장 큰 자리를 고르면 소수점 아래에서 조금 다른 값이 나온다.

☒ A O (맞다)

☐ B X (틀리다)

제출

그래서, 우리 데이터에 넣으면

이제 계약으로 옮겨 봅시다. 오늘 쓰는 실제 데이터는 프랑스 자동차보험 계약 기록 **freMTPL2freq** 예요. 계약 하나가 기간 중 사고를 겪었으면 1, 아니면 0 이니 계약 하나가 곧 베르누이 시행 하나이고, 방금 유도한 공식이 그대로 쓰입니다.

$$\hat{p} = \frac{k}{n} = \frac{34,060}{678,013} = 0.0502$$

분자 34,060 은 기간 중 사고를 한 번이라도 겪은 계약 수, 분모 678,013 은 전체 계약 수예요.

사고 경험률 — 계약 하나가 유지 기간 중 사고를 한 번이라도 겪을 확률입니다. 계약 100건 중 5건꼴이라는 뜻이에요.

그런데 보고서에 이 숫자 하나만 적으면 반드시 되돌아오는 질문이 있습니다 — "그 5.02%, 얼마나 믿을 수 있나요?"

추정값이 얼마나 흔들리나 — 표준오차

MLE 는 봉우리의 **좌표**만 알려 주지 그 봉우리가 얼마나 뾰족한지는 말해 주지 않습니다.

관측 정보량(observed information, $I(\hat{p})$) — 로그우도의 2차 도함수에 부호를 뒤집은 값 $I(\hat{p}) = -\ell''(\hat{p})$ 입니다. 봉우리가 꼭대기에서 얼마나 뾰족한지를 재고, 클수록 데이터가 $\hat{p}$ 를 강하게 가리켜요. 앞면 7/10 이면 앞 그림의 $\ell''(0.70) = -47.6$ 을 뒤집어 $I(0.70) = 47.6$ 이예요.

표준오차(standard error, SE) — 추정량의 표준편차입니다. 같은 크기의 표본을 다시 뽑으면 추정값이 이만큼 흔들려요. 기호로는 $SE(\hat{p})$ 이라 적고, 단위는 추정값과 같습니다.

$I(\hat{p})$ 가 클수록, 곧 봉우리가 뾰족할수록 추정값은 덜 흔들립니다. 그 관계를 그대로 식으로 적은 것이 $SE(\hat{p})$ 이고, 베르누이에서는 이렇게 정리됩니다. 둘이 한 식이라는 유도는 다음 소단원 접힘에서 봐요.

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

▶ $\hat{p}(1 - \hat{p})$: 베르누이 한 번의 분산 — 0.5 에 가까울수록 크고 0 이나 1 쪽이면 작아집니다

▶ n : 관측 수 — 분모에 있으니 n 이 네 배가 되면 $SE(\hat{p})$ 는 절반이 됩니다

계약 678,013건을 넣으면 이렇게됩니다.

$$SE(\hat{p}) = \sqrt{\frac{0.0502 \times 0.9498}{678,013}} = 0.000265$$

동전을 10번 던져 앞면이 7번이면 $\hat{p} = 0.70$ 이니, 같은 식이 이렇게 되고요.

$$SE(\hat{p}) = \sqrt{\frac{0.7 \times 0.3}{10}} = 0.145$$

그래서 같은 공식인데 $SE(\hat{p})$ 는 546배 벌어졌습니다 — $SE(\hat{p})$ 를 정하는 것은 공식이 아니라 n 이에요. 0.145 는 추정값 0.70 의 5분의 1 이 넘어서, 열 번 던진 증거로는 이 동전이 공정한지조차 가리기 어렵다는 뜻이고요.

두 표준오차 공식은 한 식이다

관측 정보량 $I(\hat{p})$ 와 표준오차 $SE(\hat{p})$ 는 서로 다른 두 값이 아닙니다. 앞면 7/10 의 $I(0.70) = 47.6$ 을 역제곱근으로 뒤집으면 $1/\sqrt{47.6} = 0.145$ — 방금 SE 공식으로 구한 그 값이에요.

자세히 — 2차 미분에 k/n 을 넣으면 왜 $n/[\hat{p}(1-\hat{p})]$ 이 되나

더 깊이 — 왜 관측 정보량의 역제곱근이 표준오차인가

구간으로 읽기 — 신뢰구간

SE 를 구간으로는 어떻게 읽을까요. 표본이 크면 추정값의 흠어짐이 정규분포에 가까워지고, 이 성질을 **중심극한정리(central limit theorem)** 라 부릅니다. 정규분포는 중심 ± 2 표준편차 안에 약 95% 가 들어가니, **추정값 ± 2 SE 가 참값을 대략 95% 담는 구간**이 돼요. 이렇게 잘라 낸 구간에 붙은 이름이 **신뢰구간(confidence interval)** 입니다.

▲ 정규분포에서 중심 ± 2 표준편차가 덮는 넓이 — 중심 양옆 34.1% 영역 둘에 그 바깥 13.6% 영역 둘을 더하면 95.4% 다.
가로축의 σ 자리에 오늘의 SE 가 들어간다 (출처: Wikipedia)

가운데 34.1% 영역 둘에 그 바깥 13.6% 영역 둘을 더하면 95.4% — 추정값 ± 2 SE 를 95% 구간이라 부르는 근거가 이 넓이입니다.

아래 그림은 참값을 우리가 본 값이라 치고 같은 건수를 5,000번 다시 뽑아 본 결과예요. 왼쪽이 계약 678,013건, 오른쪽이 곧 만날 작은 **세그먼트** 하나입니다. 세그먼트는 지역·차종·마력 같은 조건의 조합 하나를 뜻하고, 오른쪽은 그 조합에 속한 계약이 63건뿐인 경우예요. 그 63건 가운데 4건이 기간 중 사고를 겪어 $\hat{p} = 4/63 = 0.0635$, 곧 6.35% 입니다.

▲ 참값을 우리가 본 값에 두고 같은 건수를 5,000번 다시 뽑으면, ± 2 SE 로 벌린 회색 구간 안에 계약 678,013건은 95.8% · 계약 63건은 94.2% 가 들어온다 — SE 가 0.027%p 대 3.07%p 라 63건에서는 구간이 추정값만큼 위아래로 벌어져서 추정값을 읽을 수 없다.

연파랑 막대는 다시 뽑은 추정값 5,000개가 몰린 자리, 하늘색은 같은 SE 로 그린 정규곡선이고, 회색 구간은 우리가 본 값 5.02% · 6.35% 를 중심에 둡니다. 오른쪽 패널 5% 자리에 있는 아주 짧은 남색 토막은 왼쪽 구간을 같은 가로축에 옮겨 놓은 것이예요 — 그 구간 길이가 0.11%p 입니다. %p(퍼센트포인트) 는 퍼센트끼리의 차이를 재는 단위로, 5.0% 와 5.1% 의 차이가 0.1%p 예요.

계약 678,013건의 구간은 0.0502 ± 0.0005 , 값으로는 **4.97% ~ 5.08%** 로 0.11%p 남짓입니다.

요율 — 계약 하나에 매기는 보험료의 기준 비율입니다. 사고를 겪을 확률이 곧 보험사가 돈을 낼 확률이라 요율은 사고 경험률과 같은 % 눈금에서 출발하고, 소수 첫째 자리까지 적으면 눈금이 0.1%p 예요. 위 구간 길이가 딱 그 눈금 한 단계라 요율을 5.0% 로 적을지 5.1% 로 적을지가 이 안에서 갈립니다.

그런데 구간이 이렇게 짧은 것은 n 이 67만이라서입니다. 요율은 전체에 한 숫자를 매기는 게 아니라 지역·차종·마력처럼 기준을 겹쳐 쪼개 세그먼트마다 따로 잡는데, 쪼개면 계약이 수십 건뿐인 세그먼트가 생겨요.

어디	$\hat{p}$	± 2 SE
전체 678,013건	0.0502	± 0.0005
지역 R43 1,326건	0.0407	± 0.011
지역 × 차종 × 마력 63건 세그먼트	0.0635	± 0.061

이 세 행을 사고 경험률 눈금 위에 그대로 얹으면 이렇게 보입니다.

▲ 표 세 행을 사고 경험률 눈금 위에 얹은 그림 — 속 빈 원이 추정값, 수염 양끝이 추정값 ± 2 SE 다. 전체 678,013건은 $5.02\% \pm 0.05\%$ 라 수염이 점 하나에 묻히고, 지역 R43 1,326건은 $4.07\% \pm 1.09\%$ p, 셋으로 쪼개 63건 세그먼트(하늘색)는 $6.35\% \pm 6.14\%$ p 로 ± 2 SE 가 추정값에 맞먹는다. 회색 점선은 요율을 5.0% 와 5.1% 로 가르는 반올림 경계다

맨 아래 행은 셋으로 쪼개 세그먼트이고, 계약 63건 가운데 4건이 기간 중 사고를 겪었습니다. ± 2 SE 가 추정값에 맞먹어요 — 사고 경험률이 0.2% 일 수도 12.5% 일 수도 있다는 뜻이라, 이 세그먼트에 요율을 매기는 것은 사실상 동전 던지기죠. MLE 는 이 세그먼트에서도 그대로 숫자 하나를 내놓지만, 그 숫자를 그대로 쓰면 안 되는 자리가 있다는 것을 SE 가 알려 줍니다.

더 깊이 — 이 근사를 믿으면 안 되는 자리

핵심 주의점

신뢰구간을 "참값이 이 구간 안에 있을 확률이 95%"로 해석하면 안 됩니다.

$$\hat{p} \pm 2 \text{SE}(\hat{p}) = 0.0502 \pm 0.0005$$

참값은 고정된 숫자 하나라 확률이 붙는 쪽이 아니고, 표본마다 새로 그려지는 것은 구간입니다. 따라서 "4.97% ~ 5.08% 안에 참값이 있을 확률이 95%"는 틀린 문장이예요.

정확한 뜻은 다음과 같습니다.

계약 678,013건을 같은 방식으로 다시 뽑아 구간을 매번 새로 그리면, 그 구간의 약 95%가 참값을 담는다.

MLE는 봉우리의 좌표를 알려 주고, SE는 그 봉우리가 얼마나 뽀족한지를 알려 줍니다.

$\pm 2 \text{SE}$ 가 추정값보다 커지는 극단은 다음 절에서 봅니다 — 세 번 던져 세 번 앞면이면 MLE는 무엇이라고 할까요?

초급

40건 세그먼트의 표준오차

지역·차종·마력을 같은 방식으로 겹쳐 쪼갠 세그먼트 가운데는 계약이 $n = 40$ 건뿐인 것도 있고, 그중 $k = 3$ 건이 기간 중 사고를 겪었습니다. 3절에서 이름을 붙인, 공식으로 바로 구하는 해 $\hat{p} = k/n$ 과 $\text{SE} = \sqrt{\hat{p}(1 - \hat{p})/n}$ 으로 이 세그먼트의 사고 경험률과 $\pm 2 \text{SE}$ 를 구하고, 그 값을 앞 표에 적힌 63건 세그먼트의 ± 0.061 과 견주어 어느 쪽이 더 위태로운지 한 문장으로 판정해 보세요.

여기에 자신의 답을 작성해 보세요.

제출

05 · 코어 · 26분 · 코드 2개

4절 포아송 MLE와 소표본의 함정

포아송 MLE — 콜센터의 시간당 전화 수

이 절에서 할 일

1. 개수를 세는 자료에서 "가장 그럴듯한 값"이 무엇으로 떨어지는지 식으로 확인합니다.
2. 공식으로 바로 못 구할 때 기율기를 따라 옮겨 가며 같은 자리를 찾습니다.
3. 관측이 적으면 그 자리가 어디까지 치우치는지 3번 던져 3번 앞면으로 봅니다.

3절의 베르누이 MLE는 k/n 이라는 비율이었죠. 이번 예는 개수를 세는 자료입니다.

▶ 카운트 데이터(count data) — "1시간에 전화가 몇 통 오나"처럼 0, 1, 2, ...로 세는 값이에요. 음수도 소수도 나오지 않습니다.

- ▶ **포아송 분포(Poisson distribution)** — 카운트 데이터의 표준 모형입니다. 모수가 λ 하나뿐이고, 그 하나가 곧 단위시간당 평균 사건 수예요.
 - ▶ **팩토리얼 $x!$** — x 부터 1 까지 하나씩 줄여 가며 내리 곱한 수입니다. $3! = 3 \times 2 \times 1 = 6$ 이고 $0! = 1$ 로 약속해요.
 - ▲ 포아송 분포 — 색은 λ 값이고 점 높이는 그 λ 에서 사건이 k 번 일어날 확률이라, 주황 $\lambda=1$ 은 0.37, 자주 $\lambda=4$ 는 0.20, 하늘 $\lambda=10$ 은 0.13 이 봉우리 높이다. 그림의 k 가 아래 식의 x 자리이고, 세로축 $P(x = k)$ 가 아래 식의 $P(X = x)$ 다 (출처: Wikipedia)
- 봉우리는 λ 근처에 서고, 꼬리는 오른쪽으로만 길어집니다.

더 깊이 — 봉우리가 λ 근처에 서고 꼬리가 오른쪽으로만 긴 이유

이 모양을 식으로 적은 것이 포아송의 확률식입니다. 위 그림에서 점 하나의 높이를 계산해 주는 식이에요.

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

- ▶ x : 단위시간에 실제로 일어난 사건 수
- ▶ λ (람다) : 단위시간당 **평균** 사건 수 — 포아송의 유일한 모수이자 추정 대상

우도에 로그를 씌워 미분하면 결론이 또 한 번 허무할 만큼 친숙해요.

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad (\text{표본평균})$$

- ▶ n : 관측 수 — 여기서는 지켜본 시간의 개수라, 5시간이면 5입니다
- ▶ x_i : i 번째 시간에 실제로 센 사건 수이고, $\bar{x}$ 는 그 값들을 더해 n 으로 나눈 표본평균이에요

5시간 동안 [3, 2, 4, 3, 5]통을 받았다면 $\hat{\lambda} = 17/5 = 3.4$ 통/시간입니다. 그림의 자주 곡선($\lambda = 4$) 근처죠. "평균 내면 되지"가 또 MLE 였던 거예요.

3.4 에도 표준오차가 붙습니다. 3절의 SE 와 같은 뜻으로, 추정값이 표본마다 흩어지는 정도예요.

$$SE(\hat{\lambda}) = \sqrt{\frac{\hat{\lambda}}{n}} = \sqrt{\frac{3.4}{5}} = 0.82$$

$\pm 2 SE$ 로 잡으면 1.75 ~ 5.05통/시간이에요. **그래서** 5시간짜리 기록으로는 시간당 2통짜리 콜센터와 5통짜리 콜센터를 아직 구분하지 못합니다.

자세히 — 로그우도를 미분해 $\hat{\lambda} = \bar{x}$ 가 나오는 과정

자세히 — SE 의 제곱근 안쪽이 왜 $\hat{\lambda}/n$ 인가


[직접 해보기] 관측이 쌓일수록 "그럴듯한 범위"가 좁아진다

이번 위젯의 콜센터는 진짜 λ 가 3.2(진짜 $\lambda = 3.2$ 회색 점선)인 곳이에요.

- 조작.** 위젯은 **관측 시간 n** 이 60시간인 화면으로 열립니다. 슬라이더를 왼쪽 끝 15시간으로 옮긴 뒤 300시간까지 천천히 늘리고, 다시 60시간으로 되돌려 놓으세요.
- 관찰.** 파랑 곡선은 각 λ 후보의 우도를 최고점 1에 맞춘 **상대우도**이고, 그 아래 열게 칠한 구간이 **$\approx 95\%$ 그럴듯한 λ 범위** — 상대우도가 최고점의 약 $15\%(e^{-1.92} = 0.147)$ 이상인 후보를 모아 놓은 자리예요. **그럴듯한 범위 폭** 숫자가 그 가로 길이라, 곡선이 뾰족해지는 만큼 줄어듭니다. 슬라이더를 60시간에 두면 **추정값 $\hat{\lambda}$** 이 3.18, **그럴듯한 범위 폭** 이 0.89로 찹힙니다.
- 확인 질문.** 밀어 본 결과로 답해 보세요 — 관측 시간을 4배로 늘리면 **그럴듯한 범위 폭** 은 4분의 1로 줄까요, 2분의 1로 줄까요? 15시간에서 **그럴듯한 범위 폭** 을 적어 두고, 4배인 60시간에서 같은 숫자를 다시 적어 두 값을 나눠 보면 됩니다.

관측이 쌓이면 그럴듯한 λ 의 범위가 좁아진다.

콜센터 시간당 전화 수 λ 의 상대우도, 최댓값 = 1



— 지금까지 본 데이터 — 처음 15시간 (비교용) $\approx 95\%$ 그럴듯한 λ 범위 진짜 $\lambda = 3.2$

슬라이더로 관측 시간을 늘려 음영 폭이 파랑 곡선보다 얼마나 좁아지는지 보세요.

관측 시간 n 60 시간

○

그럴듯한 범위 폭

0.89

좁을수록 확실

추정값 $\hat{\lambda}$

3.18

(데이터 평균)

가로·세로 눈금은 슬라이더를 어디에 두든 고정이라, 곡선이 뾰족해지는 것과 음영이 좁아지는 것만 움직인다. 세로축은 각 곡선의 최댓값을 1로 맞춘 상대우도라 높이가 아니라 폭을 견준다. 음영은 상대우도 $\geq \exp(-1.92)$ 인 구간($\approx 95\%$ 우도비 구간)이다. 자료: 난수(seed 42)로 만든 $\lambda = 3.2$ 포아송 표본 300개.

자세히 — 상대우도 기준값 0.147 이 카이제곱 3.84 에서 나오는 계산

관측을 4배로 늘리면 그럴듯한 범위가 얼마나 줄어드나 — 적어 본 뒤 열어 보세요

공식으로 바로 못 푸는 경우 — 수치 최적화

베르누이와 포아송은 미분 = 0 방정식이 손으로 풀려 $k/n, \bar{x}$ 를 얻었죠. 그런데 **감마분포**(0 보다 큰 값에만 사는 분포로, 다음 권에서 사전분포로 다시 만나요)나 곧 만날 로지스틱 회귀는 방정식 안에 모수가 얹혀 손으로 못 풀니다.

- ▶ **공식으로 바로 구하는 해(closed-form solution)** — 답이 공식 하나로 풀리는 해입니다. $\hat{p} = k/n$ 과 $\hat{\lambda} = \bar{x}$ 가 그 예예요.
- ▶ **수치 최적화(numerical optimization)** — 공식을 푸는 대신 후보를 고쳐 가며 반복해 최고점을 찾는 방법입니다.
- ▶ **학습률(learning rate)** — 한 번에 옮기는 이동량을 정하는 작은 수예요. 이동량 = 그 자리의 기울기 × 학습률이라, 기울기가 클수록 이동량도 커집니다.

절차는 세 단계입니다.

1. 출발점 θ_0 를 하나 잡습니다
2. 그 자리의 기울기 $\ell'(\theta)$ 를 계산해, 부호가 가리키는 쪽으로 θ 를 조금 옮깁니다
3. 기울기가 0 에 충분히 가까워지면 멈춥니다

앞 절 위젯에서 슬라이더를 밀며 기울기 부호를 읽던 것이 바로 2번이에요. 사람이 손으로 하던 판단을 컴퓨터가 초당 수천 번 하는 것뿐입니다.

예측

학습률을 0.02 에 고정해 두고 봉우리 쪽으로 옮겨 가면, 한 번의 이동량은 어떻게 될까요?

- 1 학습률이 고정이니 이동량도 늘 같다
- 2 봉우리에 가까워질수록 저절로 작아진다
- 3 봉우리에 가까워질수록 오히려 커진다

아무 답이나 골라 보세요 — 채점하지 않습니다. 고르면 바로 아래 내용이 열립니다.

예측 탭의 답은 두 번째, **봉우리에 가까워질수록 저절로 작아진다** 입니다. 이동량 = 그 자리의 기울기 × 학습률인데 봉우리에 다가갈수록 기울기가 0 으로 줄거든요.

숫자로 따라가 볼게요. 앞면 7/10 로그우도의 기울기는 $\frac{7}{p} - \frac{3}{1-p}$ 였죠. 출발점을 $p_0 = 0.50$ 으로, 학습률을 0.02 로 잡으면 자리가 이렇게 옮겨 갑니다.

$$0.50 \rightarrow 0.66 \rightarrow 0.696 \rightarrow 0.70$$

기울기가 $+8.0 \rightarrow +1.8 \rightarrow +0.2$ 로 줄면서 이동량도 $0.16 \rightarrow 0.036 \rightarrow 0.004$ 로 함께 작아져요. **그래서** 봉우리에 가까워질수록 이동량이 저절로 작아지고, 3절이 공식 하나로 구한 $\hat{p} = 0.70$ 에 반복으로도 같은 자리로 닿습니다. 한 번씩의 계산과 학습률을 잘못 잡았을 때 벌어지는 일은 아래 상자에 있어요.

자세히 — 단계마다 기울기 × 학습률을 재어 0.70 에 닿는 과정

▲ 앞면 7/10 로그우도 $\ell(p)$ 위를 왼쪽에서 오른쪽으로 옮겨 간 네 자리 — 기울기가 $+8.0 \rightarrow +1.8 \rightarrow +0.2$ 로 줄자 이동량도 $0.16 \rightarrow 0.036 \rightarrow 0.004$ 로 작아져, 회색 점선이 선 $p = 0.70$ 에서 기울기 0·이동량 0 으로 멈춘다. 속 빈 원이 멈춘 자리 $\hat{p} = 0.70$ 이고, 채운 점 셋은 지나온 후보 자리다. 화살표의 높낮이는 겹치지 않게 벌린 것이라 뜻이 없고, 읽을 것은 가로 길이다

▶ 음의 로그우도(NLL, Negative Log-Likelihood) — 로그우도에 마이너스를 붙인 값입니다. `scipy.optimize.minimize` 는 이름대로 최솟값만 찾으니까, 최대화 문제를 이 부호 뒤집기로 최소화 문제로 바꿔요.

$$\text{NLL}(\theta) = -\ell(\theta), \quad \hat{\theta}_{\text{MLE}} = \operatorname{argmin}_{\theta} \text{NLL}(\theta)$$

▶ $\operatorname{argmin}_{\theta}$: 함수값을 **최소**로 만드는 θ 지점입니다 — 3절의 $\operatorname{argmax}_{\theta}$ 가 정상의 좌표였다면 이쪽은 골짜기의 좌표예요

앞면 7/10 을 넣어 보면 $\ell(0.70) = -6.11$ 이니 $\text{NLL}(0.70) = +6.11$ 이고, 이 값이 가장 작아지는 자리도 $p = 0.70$ 입니다. 부호만 뒤집었으니 최소가 되는 자리와 최대가 되는 자리는 같은 θ 예요. 머신러닝의 "손실함수 최소화"에서 그 손실이 대개 NLL 이에요.

자세히 — 공식으로 바로 구하는 해와 수치 최적화를 한 표에 놓고 견주기

더 깊이 — 수렴 판정이란 무엇이고, 수렴 실패 경고를 만나면 어디부터 보나

초급

손실 최소화를 오늘의 말로

머신러닝 코드가 "손실함수를 최소화한다" 고 말할 때, 오늘 배운 말로는 무엇을 하고 있는 것일까요? 부호가 어디서 뒤집히는지와 argmin · argmax 가 어떤 관계인지를 짚어 한두 문장으로 옮겨 보세요.

여기에 자신의 답을 작성해 보세요.

제출

근데 이게 늘 통할까 — 소표본의 함정

새 동전을 받아 3번 던졌더니 3번 다 앞면이 나왔습니다. MLE 는?

$$\hat{p} = \frac{k}{n} = \frac{3}{3} = 1.0$$

"이 동전은 언제나 앞면만 나온다" — 겨우 3번 던져 놓고 뒷면의 가능성을 0 으로 못 박는 건 성급하죠. 그런데 데이터만 보는 MLE 입장에서는 이게 최선이예요. $p = 1$ 일 때 $L(1) = 1$ 로 만점이니까요.

▶ **소표본의 함정** — 관측이 적을 때 MLE 가 구간 끝의 극단값으로 밀리는 현상입니다. MLE 의 세계에는 "그래도 동전이면 반반 근처겠지"라는 상식이 들어갈 자리가 없거든요. 데이터가 많을 때는 미덕(선입견 없음)이지만, 적을 때는 약점이 됩니다.

3절에서 구한 SE 공식도 여기서는 쓸 수 없습니다. $\hat{p} = 1$ 을 넣으면 제곱근 안의 $\hat{p}(1 - \hat{p})$ 가 $1.0 \times 0 = 0$ 이라 이렇게 됩니다.

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{1.0 \times 0}{3}} = 0$$

$\pm 2SE$ 구간이 $[1.0, 1.0]$ 으로 붙어, 3번 던져 놓고 구간의 길이가 0 이라는 답이 나와요. $p = 1$ 이 기울기가 0 인 정상인 아니라 구간의 끝에 막혀 선 자리라서 그렇습니다.

자세히 — SE 를 재는 두 방법이 $\hat{p} = 1$ 에서 0 과 0.58 로 달라지는 계산

그래서 공식 대신 우도곡선에서 구간의 길이를 직접 계산합니다. 3번 던져 3번 앞면과 30번 던져 30번 앞면, 두 데이터의 우도곡선을 최고점 1 에 맞춰 나란히 놓았어요 — MLE 는 둘 다 1.0 입니다.

▲ 앞면만 나온 동전의 상대우도 — 가로축은 앞면 확률 후보 p , 세로축은 각 곡선의 최고값을 1로 맞춘 상대우도다. 두 패널 모두 최고점(속 빈 원)이 $p = 1.0$ 에 있지만, 상대우도가 0.147 이상인 회색 구간 막대는 3번짜리가 $p = 0.53$ 에서 시작해 길이 0.47, 30번짜리는 $p = 0.94$ 에서 시작해 길이 0.06 이다. 회색 점선은 반반 동전($p = 0.5$)의 자리다

MLE 는 둘 다 1.0 인데 회색 구간 막대의 길이는 0.47 대 0.06 으로 여덟 배 가까이 벌어졌습니다. 옆 후보를 배제하는 힘이 크게 다른 거예요 — 3번짜리에서는 반반 동전($p = 0.5$)도 최고점의 1/8 만큼 그럴듯한데, 30번짜리에서는 그 값이 10억분의 1 로 떨어집니다. 곡선이 이렇게 뭉툭하면 최고점 하나만 짚어 "이 동전은 언제나 앞면"이라고 말할 근거가 서지 않아요. 여기서 견줄 것은 높이가 아니라 그 구간의 길이입니다.

더 깊이 — 위 그림에서 회색 점선이 막대 왼쪽에 선 이유, 높이를 견주면 안 되는 이유

그래서 4절을 접으면 이래요. 카운트의 MLE 는 표본평균이라 기록 [3, 2, 4, 3, 5] 면 3.4통/시간이고, 공식으로 바로 못 구하면 기울기를 따라 옮겨 가며 같은 자리를 찾습니다. 관측이 적으면 그 자리가 $3/3 = 1.0$ 처럼 구간 끝으로 밀리고요.

핵심 주의점

$\hat{p} = 1.0$ 을 "이 동전은 뒷면이 나올 확률이 0 이다" 로 해석하면 안 됩니다.

$$\hat{p} = \frac{k}{n} = \frac{3}{3} = 1.0$$

MLE 는 손에 든 3번 안에서 점수가 가장 높은 후보를 집어 올 뿐, 던지지 않은 4번째를 배제할 근거는 이 데이터에 없습니다. 실제로 반반 동전($p = 0.5$)도 최고점의 1/8 만큼 그럴듯해서, "뒷면은 안 나온다" 는 틀린 문장이예요.

정확한 뜻은 다음과 같습니다.

3번 던져 3번 앞면인 데이터를 가장 그럴듯하게 만드는 후보가 $p = 1.0$ 일 뿐, 상대우도 0.147 이상인 후보는 $p = 0.53$ 부터 1.0 까지 길이 0.47 의 구간으로 남아 있다.

관측이 적으면 MLE 는 조금 틀리는 게 아니라 끝으로 밀리고, 그 끝에서는 SE 를 재던 공식의 값도 정의되지 않습니다.

그 끝으로 밀리지 않게 잡아 주는 항을 식 안에 만드는 일이 다음 권의 주제입니다.

초급

3번 던져 3번 앞면과 30번 던져 30번 앞면은 MLE 가 둘 다 1.0 이지만, 상대우도가 0.147 이상인 구간 길이는 3번짜리가 30번짜리의 여덟 배 가까이 길다.

☒ A O (맞다)

☐ B X (틀리다)

제출

06 · 코어 · 5분

5절 오늘의 정리와 수업에서 다룰 질문

오늘 정리 — 한 장으로 압축

이 절에서 할 일

1. 오늘 배운 개념 넷을 한 문장 정의로 다시 적습니다.
2. 같은 공식이 계약 67만 8천 건과 63건에서 어떻게 다른 답을 주는지 숫자로 되짚습니다.
3. 판단이 갈리는 질문 하나를 손에 들고 수업으로 갑니다.

오늘 한 일은 방향을 뒤집은 것 하나예요. 모수를 알고 데이터를 계산하던 방향에서, 데이터를 쥐고 모수를 되짚는 방향으로 옮겨 왔습니다.

우도(likelihood) — 데이터를 관측된 상수로 고정해 놓고, 모수 후보마다 "이 모수였다면 지금 이 데이터가 나올 가능성"을 매긴 점수입니다. 기호로는 $L(\theta)$ 라 적고, 곱셈 덩어리를 덧셈으로 옮겨 적은 것이 로그우도 $\ell(\theta)$ 예요. 확률과 값은 같은데 무엇을 고정하느냐가 반대입니다 — 동전 3번에 앞면 2번에서 0.444 하나를 두 이름으로 읽었죠.

최대우도추정(MLE) — 그 점수가 가장 높은 후보를 추정값으로 고르는 규칙입니다. 미분해서 0 으로 놓고 풀면 베르누이는 $\hat{p} = k/n$, 포아송은 $\hat{\lambda} = \bar{x}$ 로 공식 하나가 나왔어요. 방정식이 손으로 안 풀리면 기율기를 따라 옮겨 가며 같은 자리에 닿습니다 — 앞면 7/10 에서 $0.50 \rightarrow 0.66 \rightarrow 0.696 \rightarrow 0.70$ 이 그 이동이었고요.

표준오차(SE) — 같은 크기의 표본을 다시 뽑을 때 추정값이 흔들리는 정도입니다. 관측 정보량 $I(\hat{p})$ 의 역제곱근 $1/\sqrt{I(\hat{p})}$ 라, 봉우리가 뾰족하면 작고 뭉툭하면 커요. $\pm 2 SE$ 로 잘라 낸 구간이 신뢰구간입니다.

± 2 를 곱한 근거는 3절에서 본 정규분포 넓이 그림이었죠 — 가운데 34.1% 영역 둘에 그 바깥 13.6% 영역 둘을 더한 95.4% 입니다.

▲ 3절에서 본 그 넓이를 다시 — 정규분포에서 중심 ± 2 표준편차가 덮는 34.1% 영역 둘과 13.6% 영역 둘을 더하면 95.4% 다. 가로축의 σ 자리에 오늘의 SE 가 들어간다 (출처: Wikipedia)

소표본의 함정 — 관측이 적으면 MLE 가 구간 끝으로 밀립니다. 3번 던져 3번 앞면이면 $\hat{p} = 1.0$ 이고, SE 를 재던 공식마저 $SE = 0$ 이라는 잘못된 값을 냅니다.

숫자 셋을 나란히 두면 오늘 하루가 한눈에 들어옵니다.

어디	$\hat{p}$	$\pm 2 SE$	읽는 법
계약 678,013건	0.0502	± 0.0005	요율을 5.0% 로 적을지 5.1% 로 적을지만 같린다
지역 R43 1,326건	0.0407	± 0.011	0.011 이 추정값 0.0407 옆에서 눈에 보인다
지역 × 차종 × 마력 63건 세그먼트	0.0635	± 0.061	0.061 이 추정값 0.0635 에 맞먹어 값을 읽을 수 없다

세 행에 쓴 공식은 똑같습니다. 같린 것은 n 하나예요.

그래서 오늘 남는 물음은 "값을 어떻게 구하나"가 아니라 "SE 가 추정값에 맞먹는 세그먼트에는 무엇을 적나"입니다. MLE 는 63건 세그먼트에서도 똑같이 숫자 하나를 내놓지만, 그 숫자를 요율표에 그대로 옮겨 적을 수는 없거든요. 데이터 바깥의 정보(사전분포)를 식에 넣어 그 세그먼트의 추정값을 보정하는 방법 — 다음 권은 그 항을 식 안에 만들고, 오늘 적은 우도가 거기서 한 항으로 그대로 들어갑니다.

우도는 모수 후보마다 점수를 매긴 함수이고 MLE 는 그 함수의 최고점이지만, 최고점만으로는 그 답을 얼마나 믿어도 되는지 말할 수 없습니다 — 그래서 추정값과 표준오차는 늘 한 짝으로 읽습니다.

수업에서 다룰 질문

읽기는 여기까지입니다. 답이 하나로 정해지지 않는 문제를 하나 남겨 둘게요. 혼자 입장을 먼저 정해 두고, 수업에서 팀원들과 근거를 맞댄 뒤 팀 답 하나로 모으는 자리입니다.

초급 팀 문항

2/5 제출

팀 라운드 — 63건 세그먼트에 어떤 숫자를 적을까

3절에서 본 63건 세그먼트는 계약 63건 가운데 4건이 사고를 겪어 $\hat{p} = 0.0635$, $\pm 2 SE$ 가 ± 0.061 이었죠. 값과 구간을 함께 읽으면 사고 경험률이 0.2% 일 수도 12.5% 일 수도 있다는 뜻입니다. 그런데 요율표에는 세그먼트마다 숫자 하나를 적어야 해요. 팀 안에서 의견이 셋으로 갈렸습니다.

관점 A — 데이터가 준 6.35% 를 그대로 적는다. 추정값은 데이터가 가리키는 자리에 두고, 계약 63건이라는 사실과 구간 $\pm 6.1\%p$ 를 같은 표에 나란히 적어 증거가 적다는 것까지 함께 보고하면 된다. 숫자를 손보는 순간 그 표에는 분석가의 판단이 섞인다.

관점 B — 전체 값 5.02% 를 그 세그먼트에도 적는다. $\pm 2 SE$ 가 추정값에 맞먹는 값은 사실상 정보가 없는 값이다. 정보가 없다면 가장 두꺼운 근거인 계약 67만 8천 건의 값을 쓰는 편이 낫고, 그쪽 구간은 $\pm 0.05\%p$ 라 사실상 흔들리지 않는다.

관점 C — 세그먼트를 다시 짤다. 손볼 곳은 숫자가 아니라 표를 짚은 방식이다. 지역·차종·마력 셋으로 짚은 탓에 63건이 된 것이니, 마력을 빼고 지역 × 차종 두 기준으로만 합쳐 n 을 키우면 구간은 저절로 좁아진다.

자기 입장 하나와 근거 3가지, 그리고 확신도를 정해 오세요.

여기에 자신의 답을 작성해 보세요.

내 입장

A 데이터 그대로 적기

B 전체 값으로 대체

C 세그먼트 설계를 다시

확신도 아직 고르지 않음

1 = 거의 확신 없음 · 5 = 매우 확신

제출 제출하면 수정할 수 없습니다. 대신 지금까지의 팀 분포가 바로 보이고, 팀 답도 낼 수 있게 됩니다.

변호인 질문

팀이 답해야 할 반론 질문이 있습니다. 질문 카드는 내 답을 낸 뒤에 열립니다.

기록됨

코치가 반론 절차를 건너뛰었습니다. 바로 팀 답을 낼 수 있습니다.

팀의 답

내 답을 제출하면 팀 답을 낼 수 있습니다.