BERTopic

목차

1 토픽 모델링과 BERTopic

2 BERTopic의 구조

3 문장 임베딩

4 UMAP

5 HDBSCAN

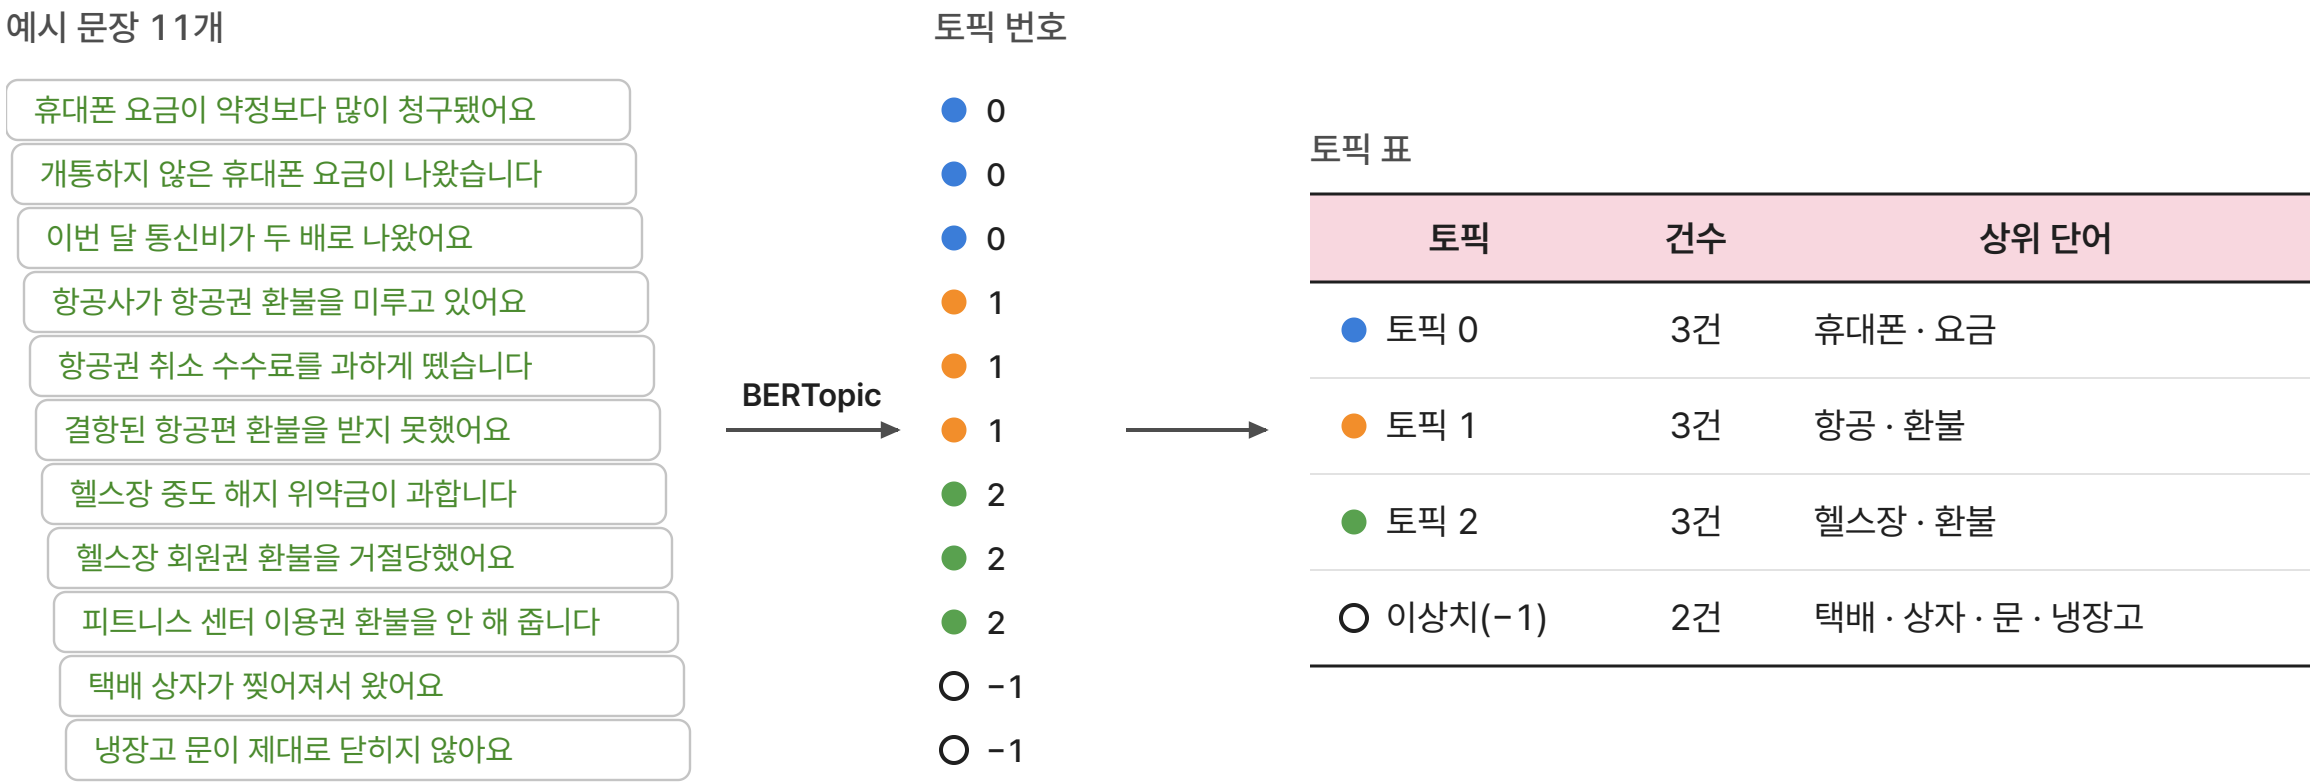
6 토큰화와 c-TF-IDF

7 토픽 표

8 민원 2만 건 적용

BERTopic - 토픽 모델링

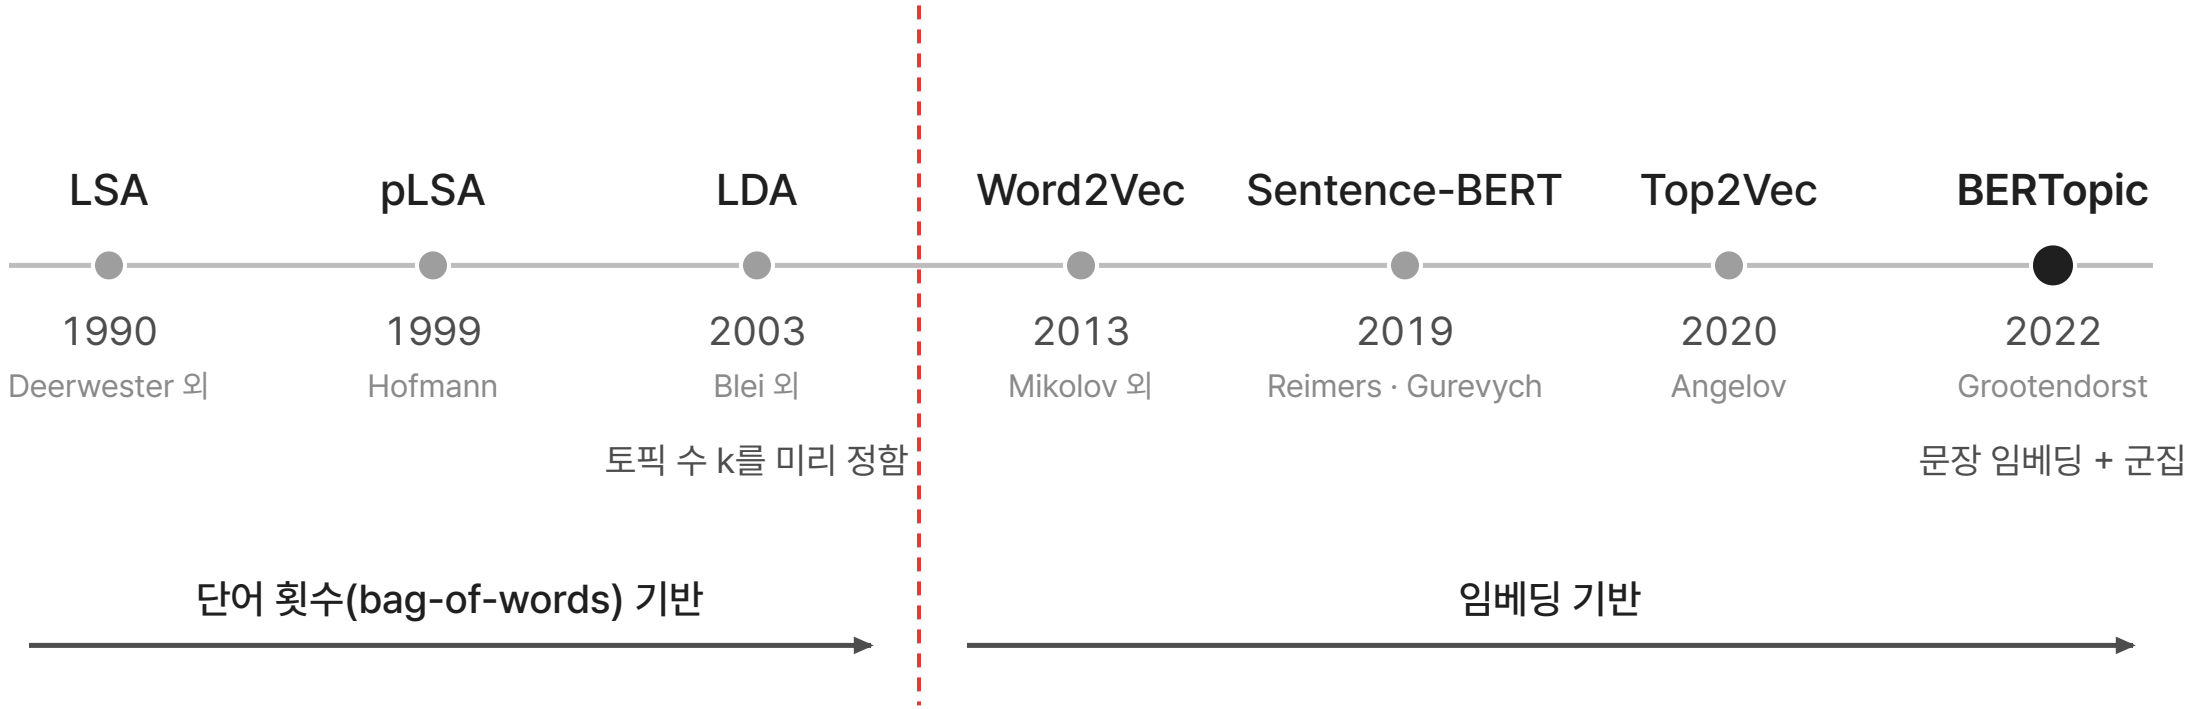
- ✓ 토픽 모델링은 라벨이 없는 문서 모음에서 주제(토픽)를 찾는 방법이다.
- ✓ 결과는 2가지다.
  - ○ 문서마다 토픽 번호
  - ○ 토픽마다 건수와 상위 단어를 정리한 토픽 표



토픽	건수	상위 단어
● 토픽 0	3건	휴대폰 · 요금
● 토픽 1	3건	항공 · 환불
● 토픽 2	3건	헬스장 · 환불
○ 이상치(−1)	2건	택배 · 상자 · 문 · 냉장고

BERTopic - 토픽 모델링의 흐름

✓ 단어 횟수로 주제를 찾던 방법에서 문장의 뜻(임베딩)으로 찾는 방법으로 바뀌었다.



BERTopic - LDA와 BERTopic

✓ LDA Latent Dirichlet Allocation

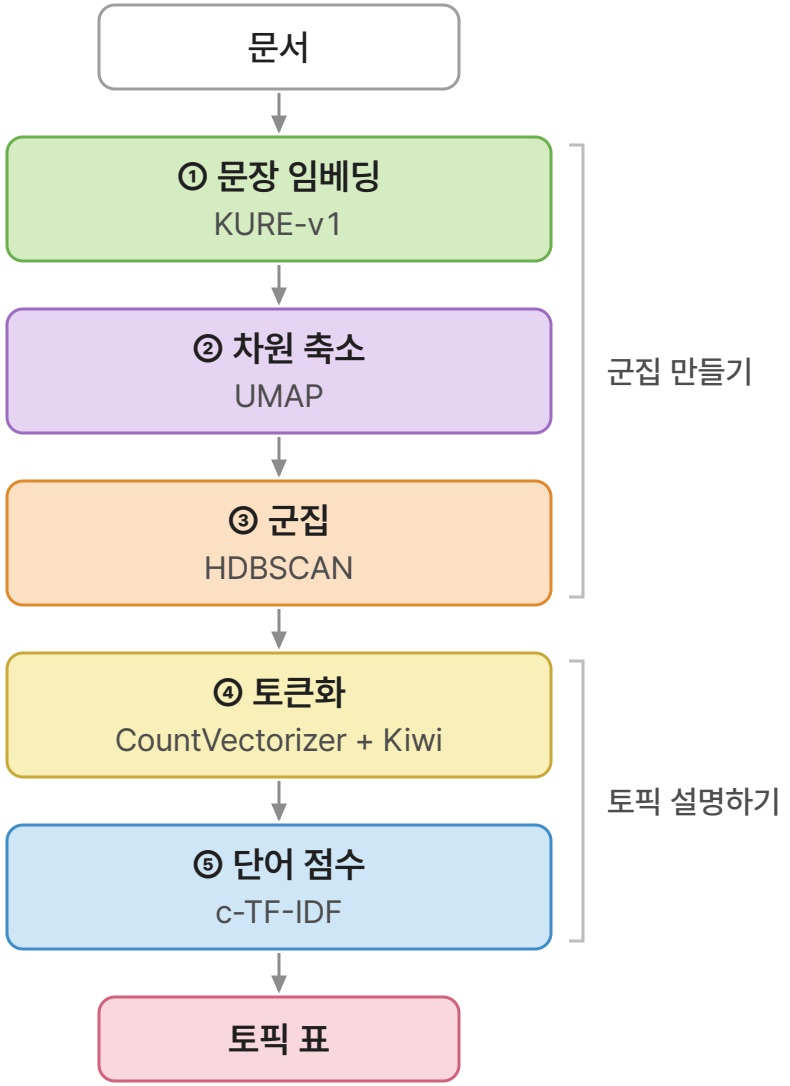
- ○ 문서를 단어 횟수로 나타낸다(단어의 뜻 · 순서는 쓰지 않음)
- ○ 문서 하나가 여러 토픽의 확률을 가진다
- ○ 토픽 수 k를 미리 정한다
- ○ 짧은 글은 단어가 적어 추정이 불안정하다

✓ BERTopic

- ○ 문서를 문장 임베딩(뜻)으로 나타낸다
- ○ 문서 하나에 토픽 하나를 정하고, 맞는 토픽이 없으면 이상치(−1)가 된다
- ○ 토픽 수는 군집 결과로 정해진다
- ○ 짧은 글도 문장 인코더가 뜻을 벡터로 나타낸다

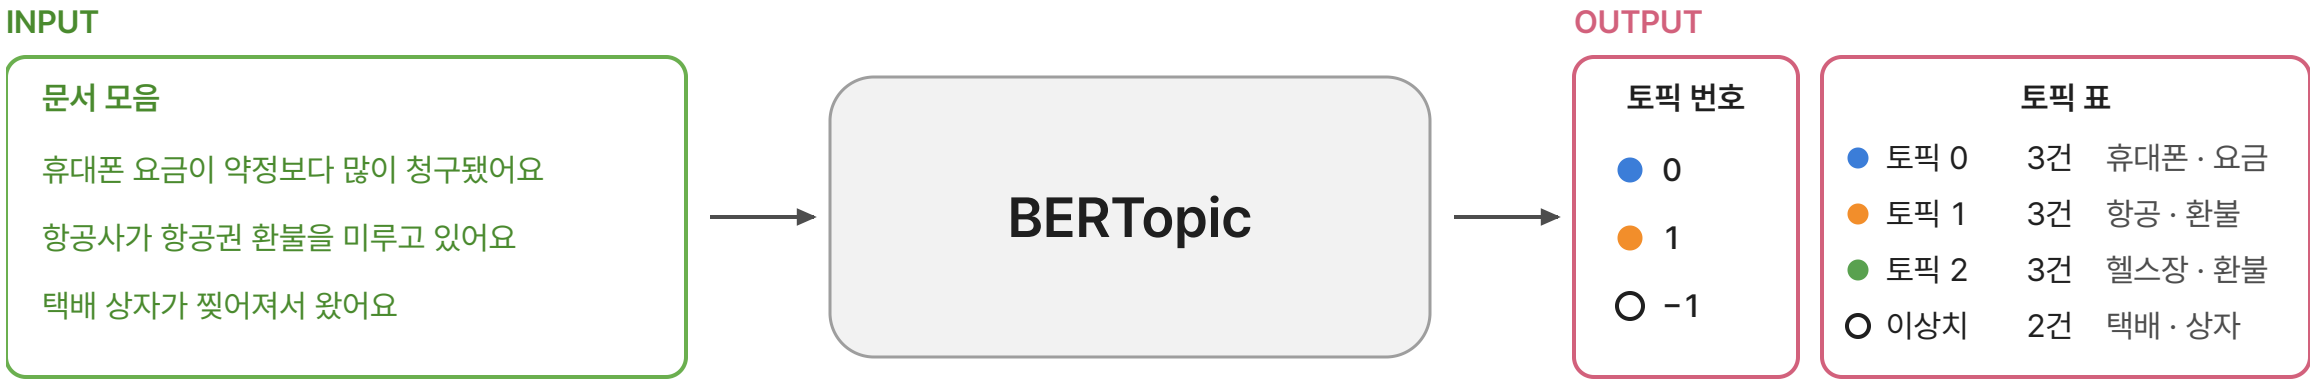
BERTopic - 구조

- ✓ BERTopic은 이미 있는 모델 5개를 차례로 잇는다.
  - ○ ④ 토큰화와 ⑤ 단어 점수를 합쳐 c-TF-IDF 한 단계로 부르기도 한다.
- ✓ 부품마다 다른 모델로 바꿀 수 있다(모듈식 구조).



BERTopic - 한눈에 보기

✓ 입력은 문서 모음이고, 출력은 문서마다 토픽 번호와 토픽 표다.

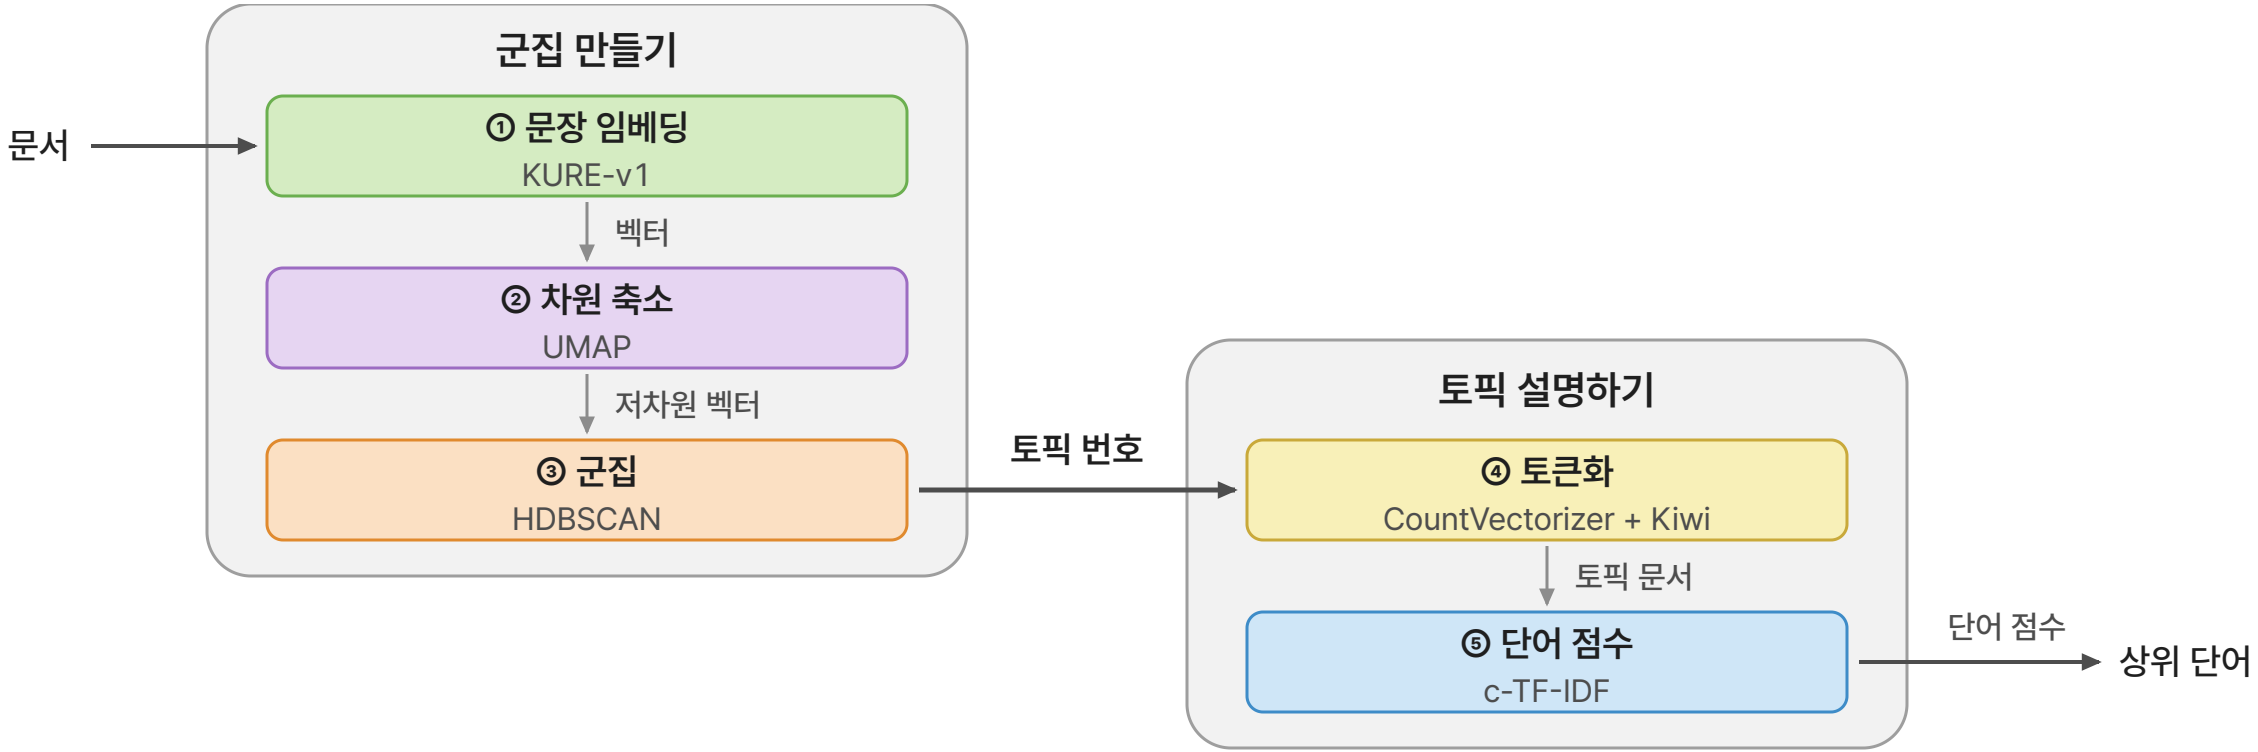


✓ 안쪽은 군집 만들기와 토픽 설명하기로 나뉜다.



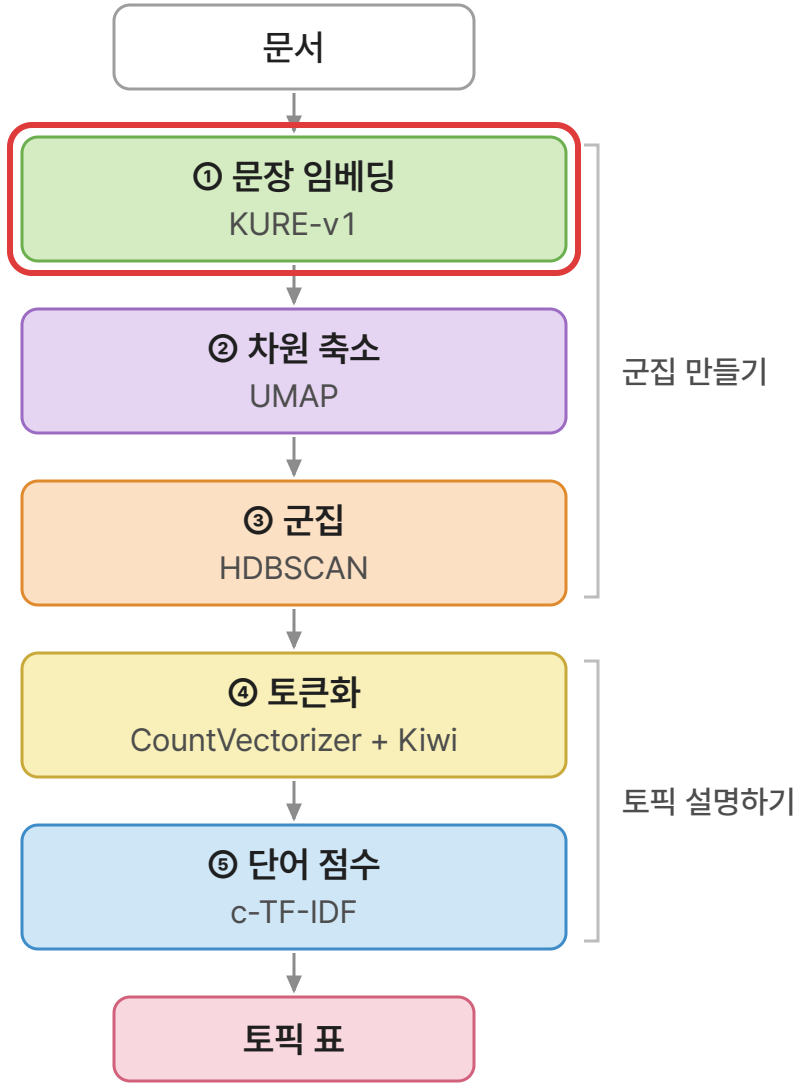
BERTopic - 군집 만들기와 토픽 설명하기

- ✓ 군집 만들기: 문서 → 벡터 → 저차원 벡터 → 토픽 번호
- ✓ 토픽 설명하기: 토픽 번호 → 토픽 문서 → 단어 점수 → 상위 단어
- ✓ 토픽 번호는 앞부분에서 정해지고, 뒷부분은 번호를 바꾸지 않는다.
  - ○ 불용어 목록을 바꾸면 상위 단어만 바뀐다.



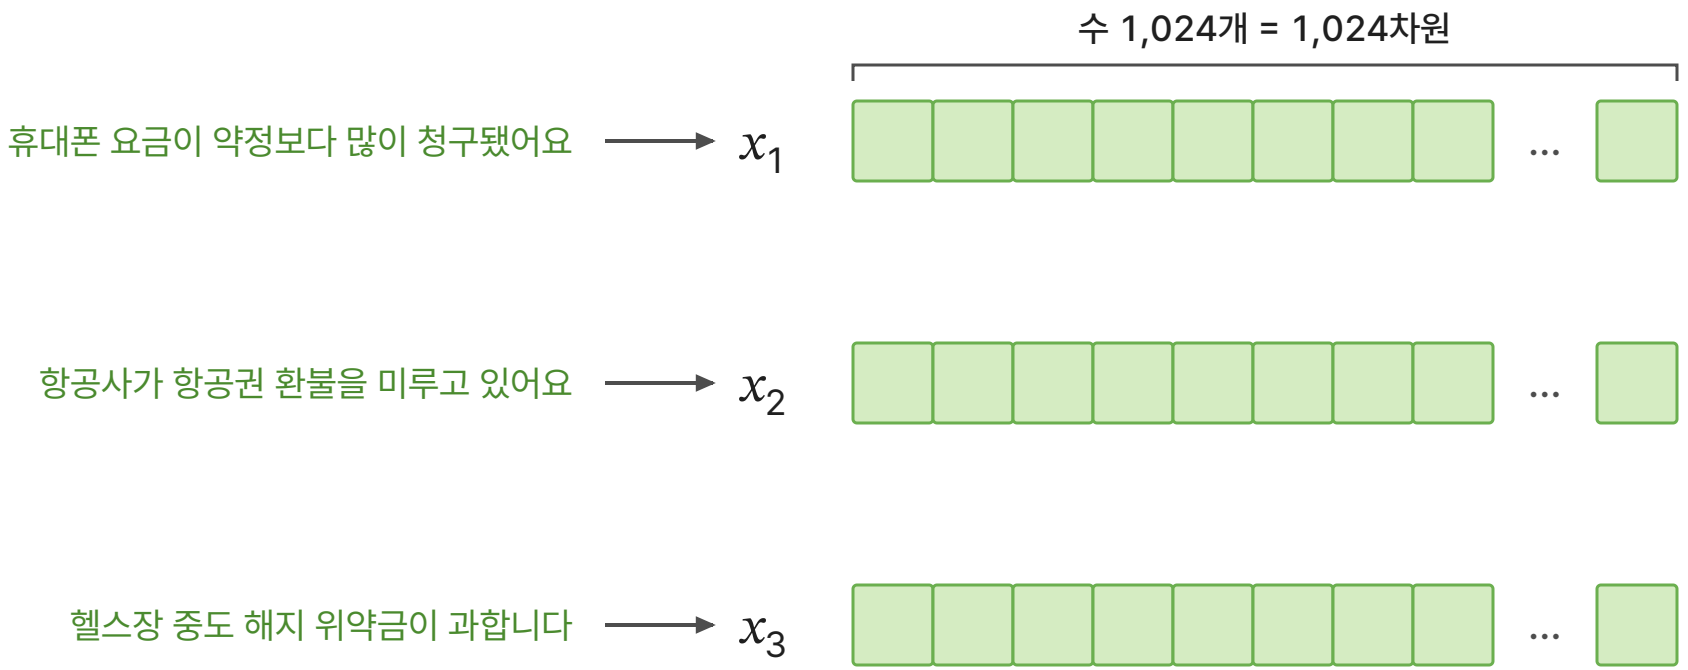
BERTopic - 문장 임베딩

- ✓ 문장 임베딩은 문장 하나를 숫자 벡터 하나로 바꾼 것이다.
- ✓ 뜻이 가까운 문장은 벡터도 가깝게 나오도록 학습된 모델(문장 인코더)을 쓴다.
  - ○ 이 수업의 문장 인코더: KURE-v1



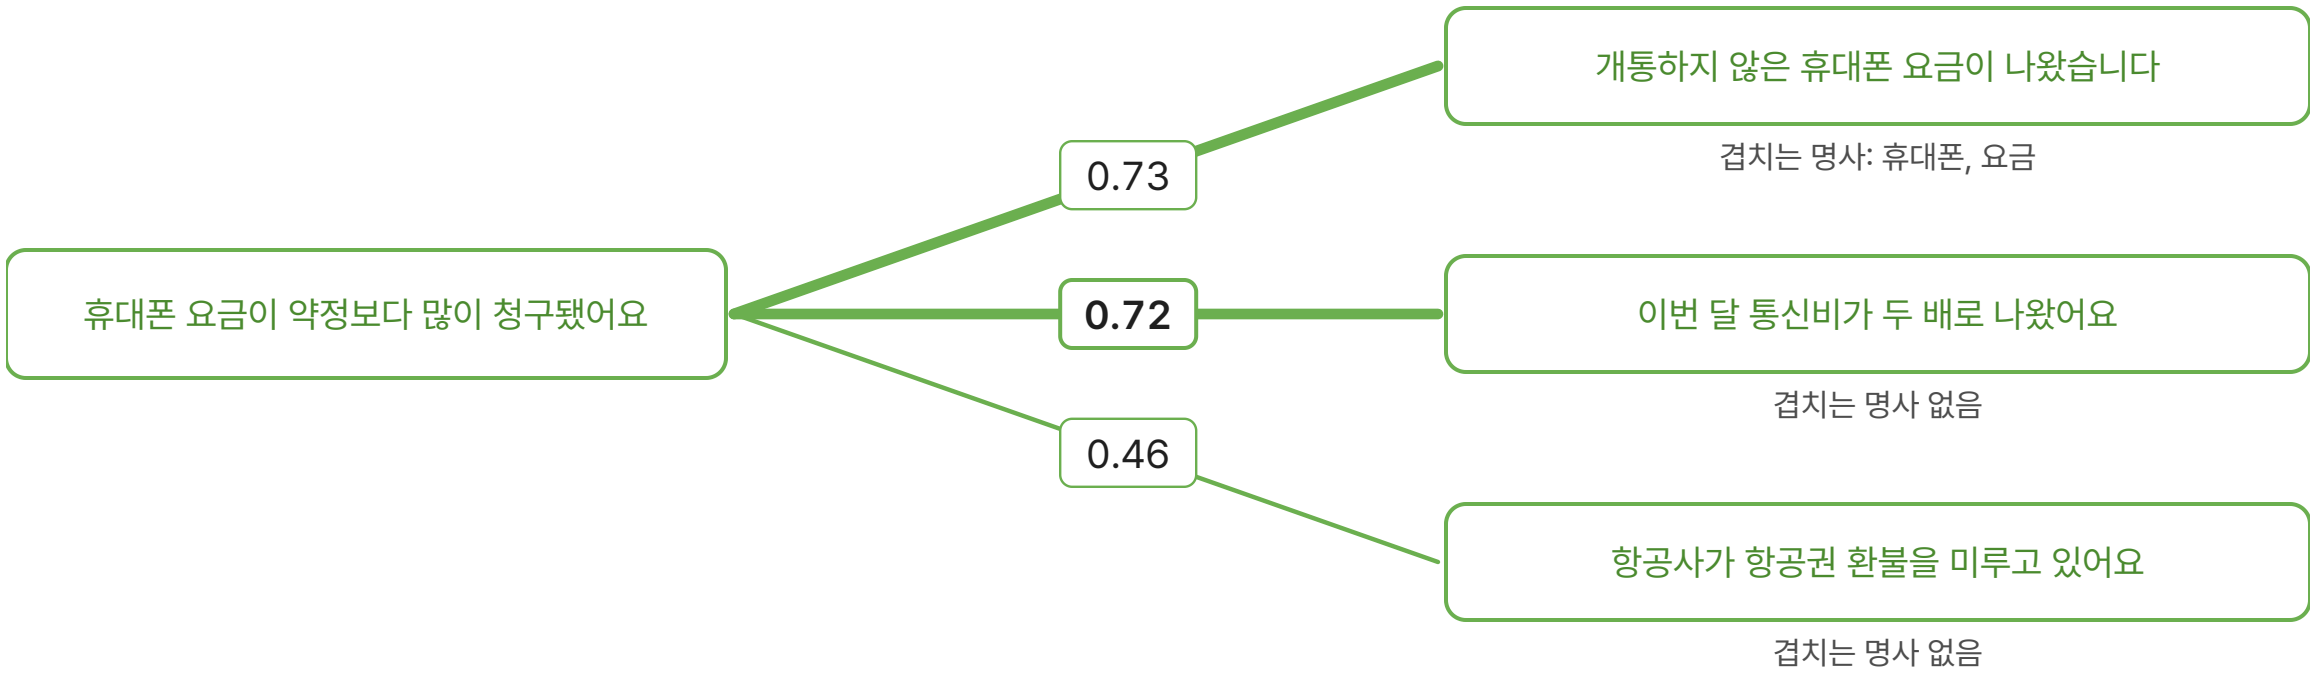
BERTopic - 문장 임베딩

- ✓ 문장마다 1,024차원 벡터가 하나씩 생긴다.
- ✓ 벡터의 차원은 벡터를 이루는 수의 개수다.
  - ○ KURE-v1은 1,024차원, multilingual-e5-small은 384차원



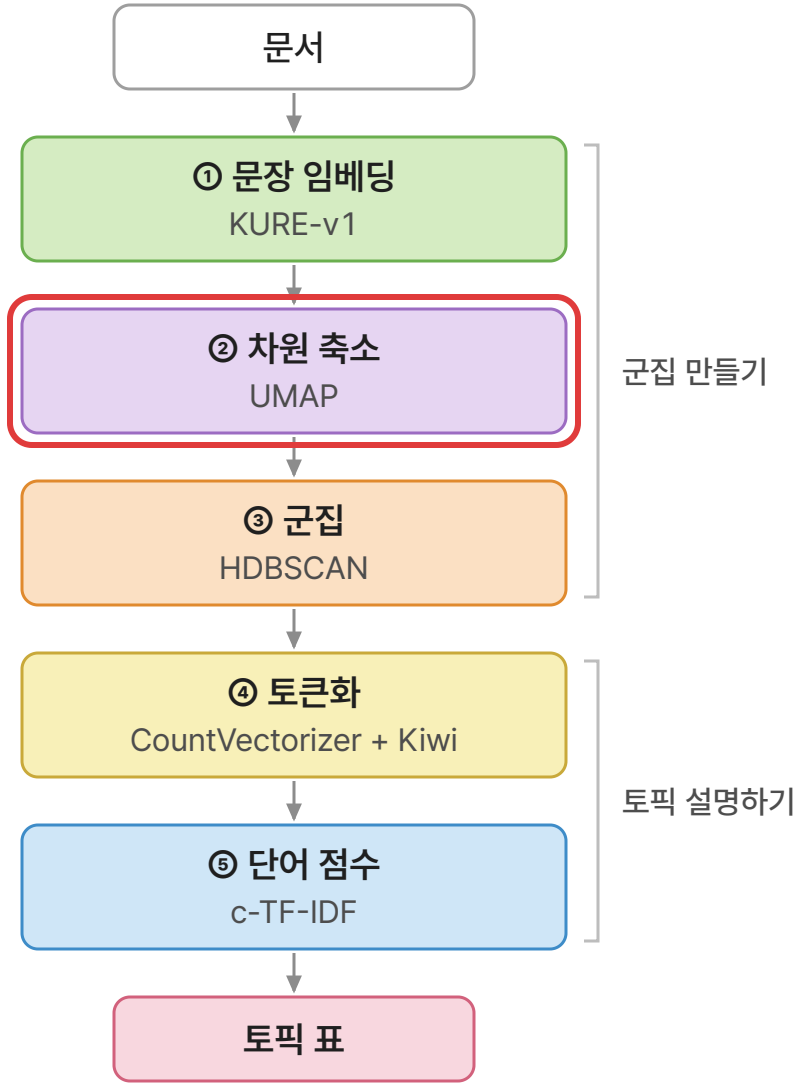
BERTopic - 문장 임베딩

- ✓ 두 벡터가 얼마나 가까운지는 코사인 유사도로 계산한다(1에 가까울수록 가깝다).
- ✓ 같은 단어가 없어도 뜻이 가까우면 코사인 유사도가 크다.
  - ○ 「휴대폰 요금이 약정보다 많이 청구됐어요」와 「이번 달 통신비가 두 배로 나왔어요」: 0.72
  - ○ 휴대폰 요금 문장과 항공권 환불 문장: 0.46



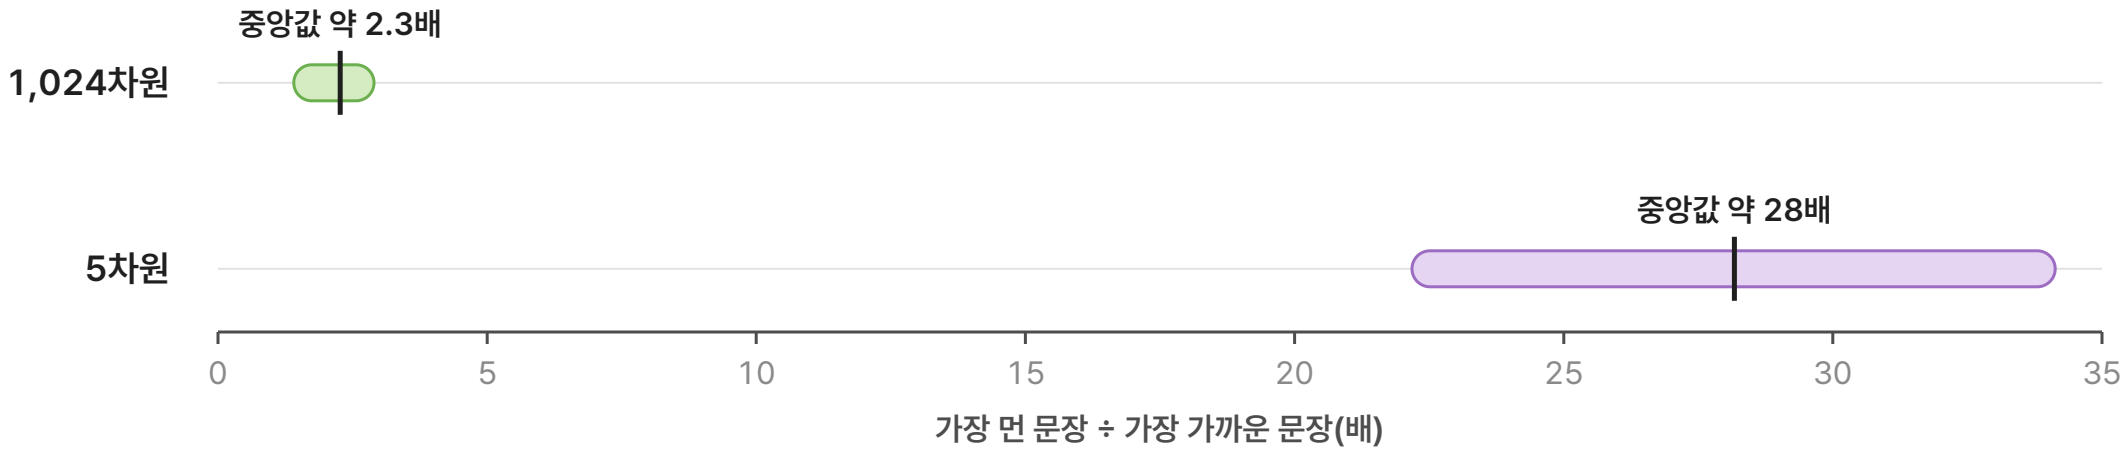
BERTopic - UMAP

- ✓ UMAP(Uniform Manifold Approximation and Projection)은 고차원 벡터를 저차원으로 줄이는 비선형 차원 축소 방법이다.
  - ○ PCA는 분산이 큰 방향으로 투영하지만, UMAP은 가까운 이웃이 가깝게 남도록 점을 저차원에 새로 배치한다.
- ✓ BERTopic에서는 1,024차원을 5차원으로 줄여 HDBSCAN에 전달한다.



BERTopic - UMAP

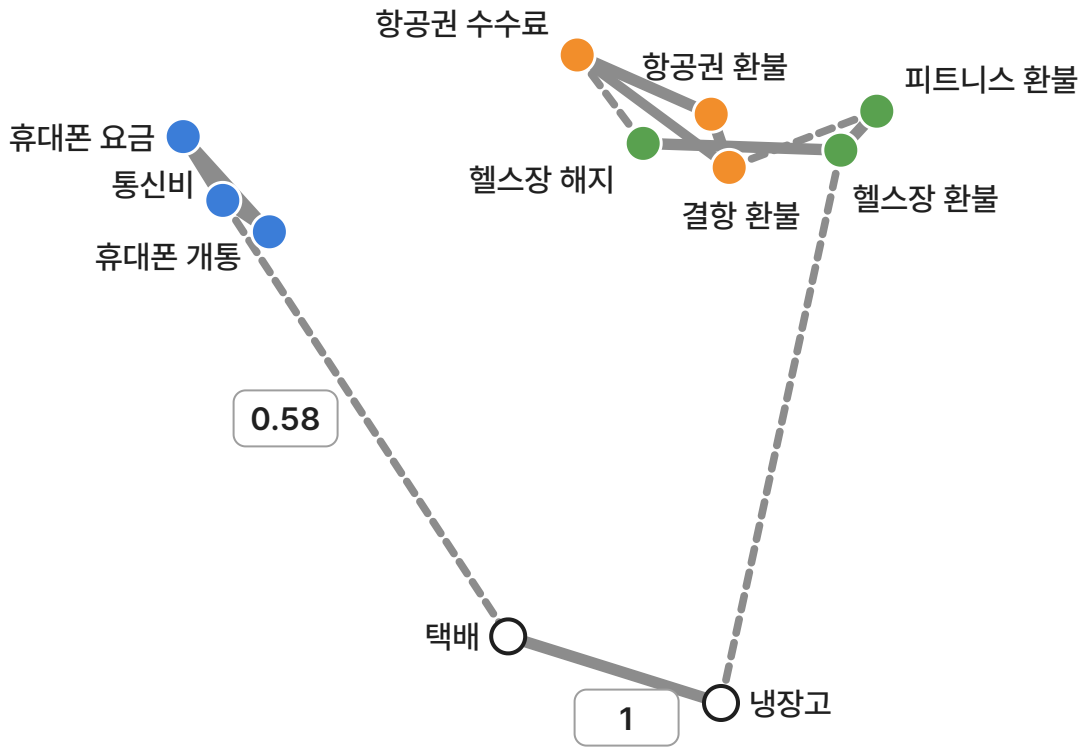
- ✓ HDBSCAN은 가까운 문장이 밀집된 영역을 군집으로 찾는다.
- ✓ 1,024차원처럼 차원이 높으면 가장 가까운 문장과 가장 먼 문장의 거리 차이가 작아지기 쉽다.
  - ○ 거리는 차원마다의 차이를 모두 더하므로, 주제와 상관없는 작은 차이도 1,024개가 모이면 커진다.
- ✓ 문장마다 가장 먼 문장이 가장 가까운 문장보다 몇 배 먼지 구해, 예시 문장 11개의 중앙값을 비교한다.
  - ○ 1,024차원 약 2.3배 → 5차원 약 28배
- ✓ 5차원으로 줄이면 이웃과 나머지의 거리 차이가 커져 밀집된 영역을 찾기 쉬워진다.
- ✓ 그래서 UMAP은 이웃 관계를 유지한 채 5차원으로 줄인다.



막대: 예시 문장 11개의 값이 있는 범위 · 세로선: 중앙값(1,024차원은 코사인 거리, 5차원은 직선 거리)

BERTopic - UMAP

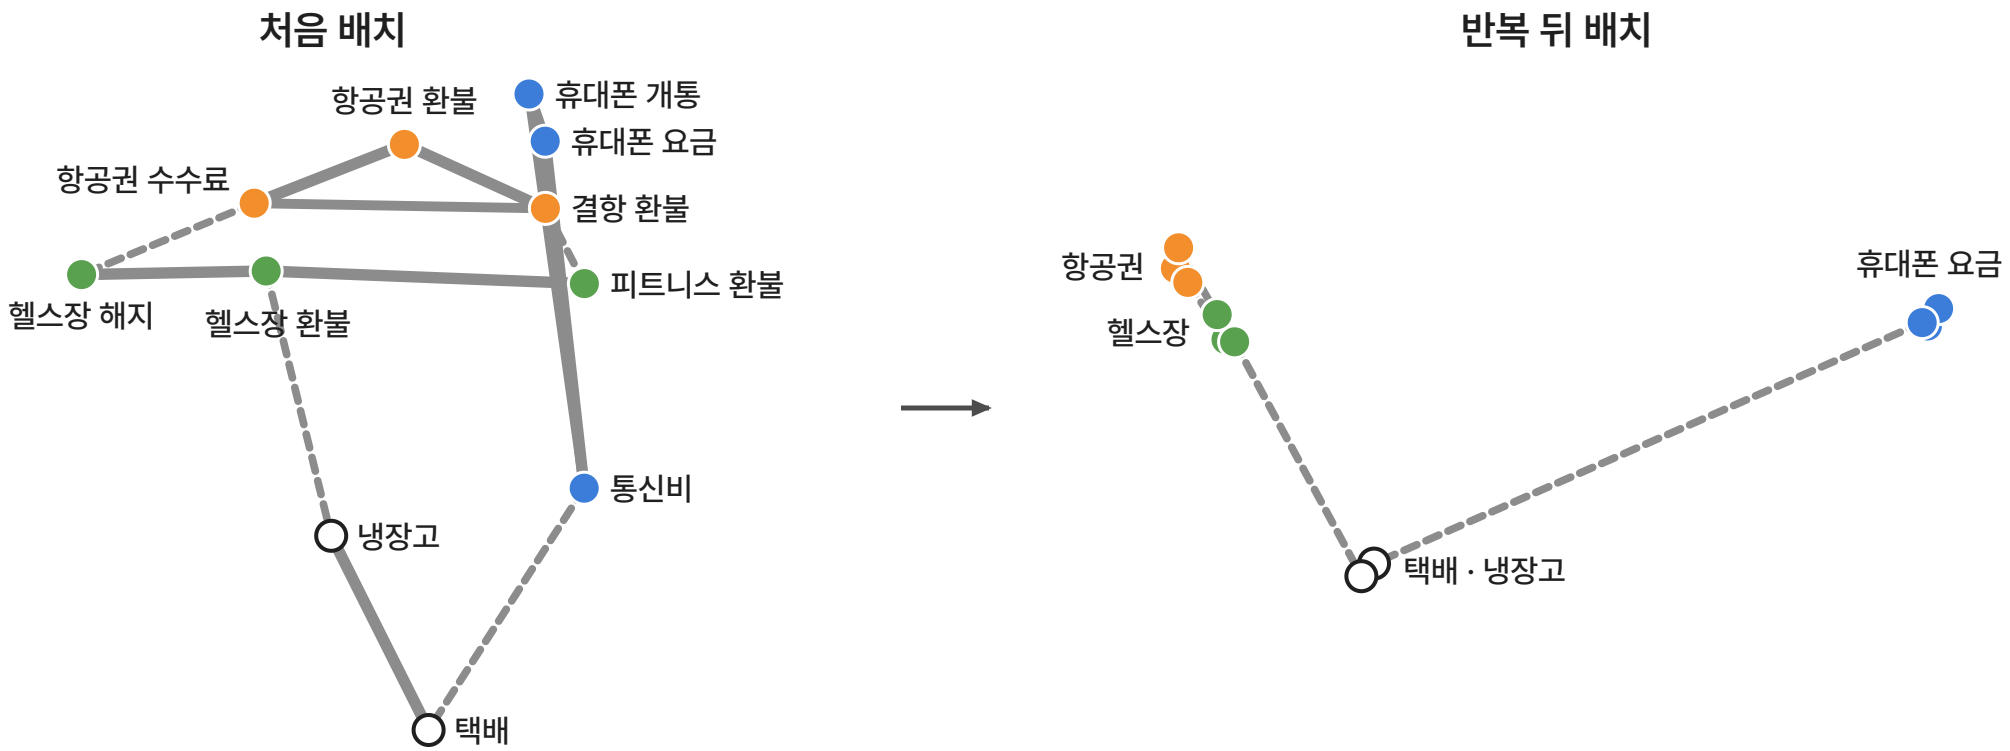
- ✓ Step 1 : 고차원에서 문장마다 가장 가까운 이웃 n_neighbors 개를 찾아 잇는다.
  - ○ n_neighbors는 자기 자신을 포함한 수다(예시 문장은 3, 이웃 2개).
- ✓ 연결 강도는 그 점에서 가장 가까운 이웃까지의 거리를 기준으로 정한다.
  - ○ 가장 가까운 이웃은 1, 그보다 멀수록 0에 가까워진다.



선 굵기: 연결 강도 · 실선 0.8 이상, 점선 0.8 미만 · 점 위치: 1,024차원 벡터를 PCA로 2차원에 그림

BERTopic - UMAP

- ✓ Step 2 : 저차원에 점을 배치하고, 그래프와 같은 모양이 되도록 위치를 반복해서 조정한다.
  - ○ 이어진 점은 연결 강도만큼 당겨지고, 이어지지 않은 점은 밀려난다.
  - ○ 약하게 이어진 점은 덜 당겨져 멀어지기도 한다.
- ✓ 가까운 이웃 관계는 남고, 먼 점 사이의 정확한 거리는 남지 않는다.



두 그림 모두 같은 5차원 공간의 위치를 같은 PCA 방향(반복 뒤 위치로 구함)으로 그림 · 선은 Step 1의 이웃 그래프

BERTopic - UMAP

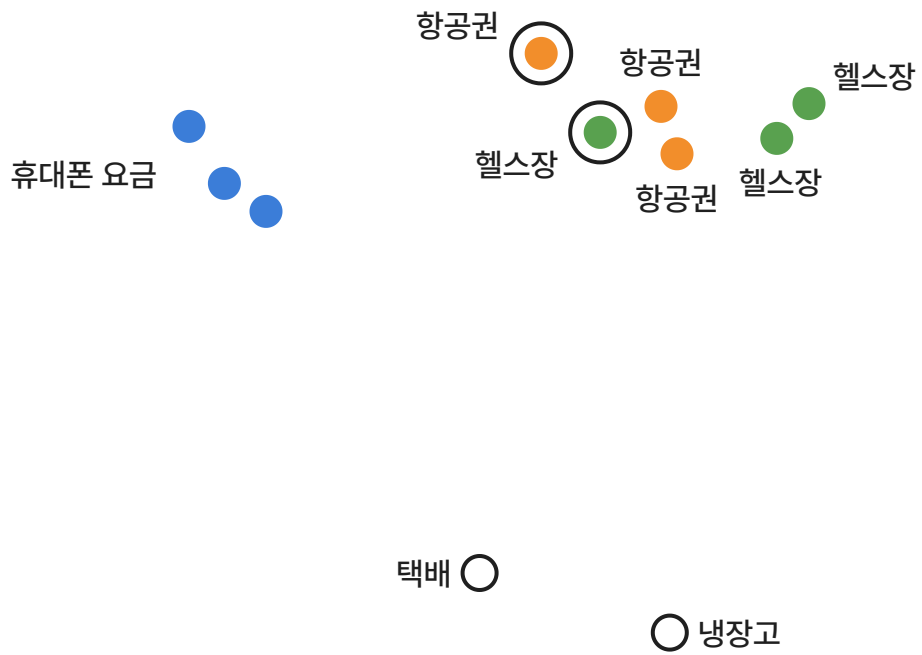
- ✓ PCA는 원래 값에 가중치를 곱해 더한 새 값(주성분)으로 옮기는 선형 변환이다.
  - ○ $\mathrm{PC}_1 = w_1 x_1 + w_2 x_2 + \cdots + w_p x_p$
  - ○ 분산이 가장 큰 방향부터 서로 직교하는 방향을 차례로 찾고, 분산이 작은 방향은 버린다.
- ✓ UMAP은 이웃 그래프를 만든 뒤, 저차원에서 같은 이웃 관계가 되도록 위치를 반복해서 조정한다.
  - ○ 곱하고 더하는 계산 한 번이 아니라 그래프와 반복 조정이라 비선형이다.

	PCA	UMAP
변환	선형: 곱하고 더한다	비선형: 이웃 그래프 + 반복 조정
보존하는 것	전체 분산	가까운 이웃 관계
새 위치의 뜻	원래 값의 가중합이라 해석하기 쉽다	위치 값과 먼 거리는 해석하기 어렵다
다시 실행하면	같은 결과	시드 · 인자에 따라 조금 달라진다

BERTopic - UMAP

- ✓ PCA는 전체 분산을, UMAP은 가까운 이웃 관계를 보존한다.
  - ○ PCA 2차원에서는 주제가 있는 문장 9개 가운데 2개의 가장 가까운 문장이 다른 주제다.
  - ○ UMAP 결과에서는 9개 모두 가장 가까운 문장이 같은 주제다.
- ✓ UMAP 결과에서 멀리 떨어진 두 점의 거리는 원래 거리로 해석하지 않는다.

PCA: 1,024차원 → 2차원



UMAP: 1,024차원 → 5차원



검은 원: 가장 가까운 문장이 다른 주제인 문장 · UMAP의 5차원 결과는 PCA로 2차원에 그림

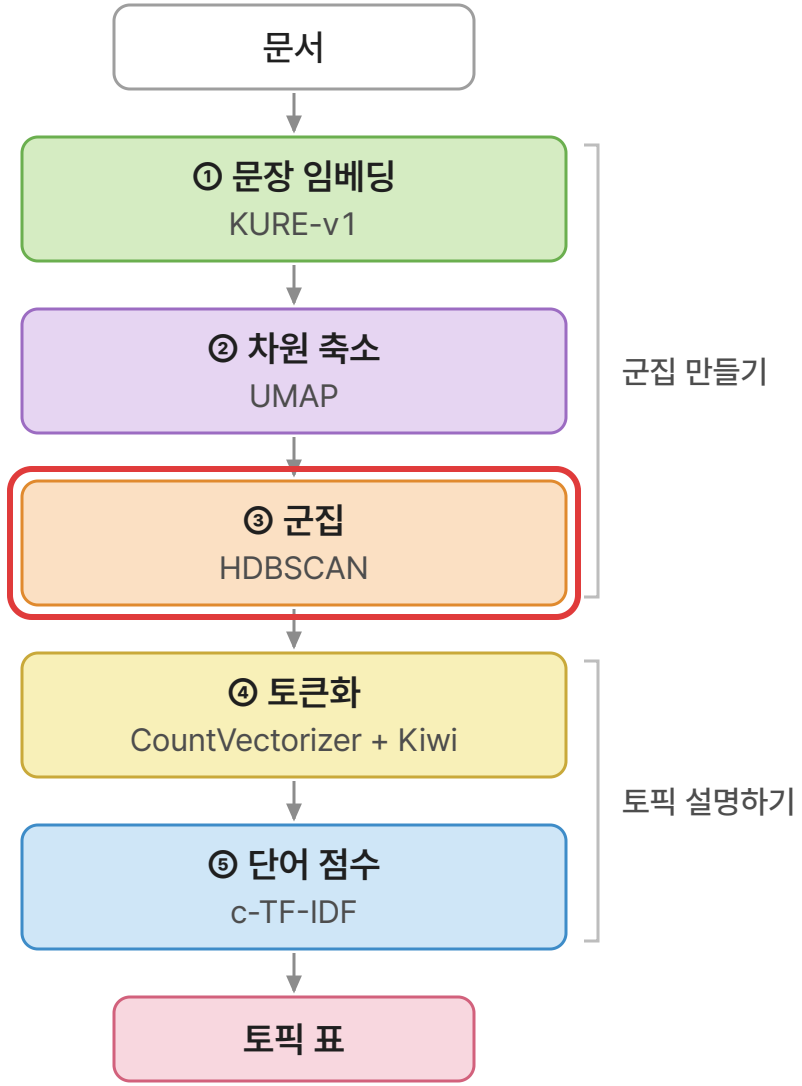
BERTopic - UMAP

- ✓ n_neighbors : 유지할 이웃의 수. 작으면 작은 무리를, 크면 큰 구조를 더 반영한다.
- ✓ n_components : 줄인 뒤의 차원(BERTopic 기본 5)
- ✓ min_dist : 저차원에서 점끼리 얼마나 가깝게 모일 수 있는지. 군집이 목적이면 0을 쓴다.
- ✓ random_state : 시드. 고정하지 않으면 실행할 때마다 결과가 달라진다.
  - ○ 위치를 조정할 때 무작위로 고른 점을 쓰므로 시드에 따라 배치가 조금씩 달라진다.



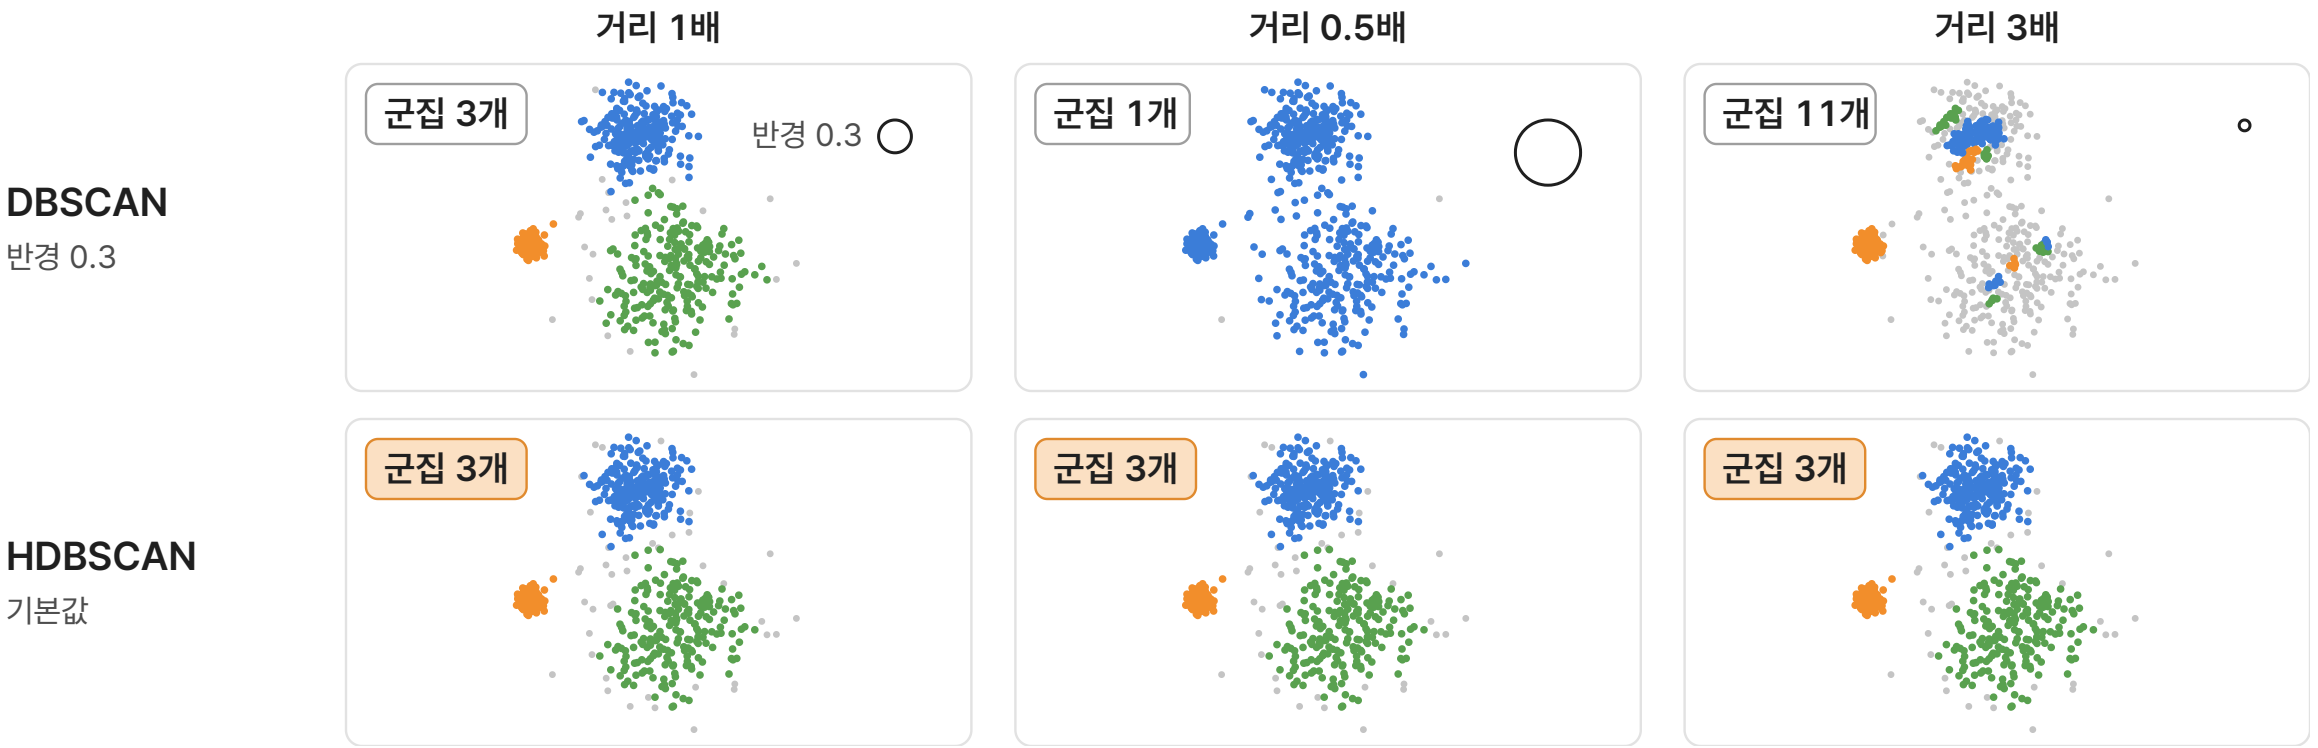
BERTopic - HDBSCAN

- ✓ HDBSCAN(Hierarchical Density-Based Spatial Clustering of Applications with Noise)은 밀도 기반 군집화 방법이다.
- ✓ 밀도가 높은 영역을 군집으로, 밀도가 낮은 영역의 점을 이상치로 나눈다.
- ✓ 군집 수를 미리 정하지 않는다.
- ✓ DBSCAN과 달리 반경(eps)을 하나로 정하지 않는다.
  - ○ 여러 거리 기준에서 계속 유지되는 군집을 고른다.



BERTopic - HDBSCAN

- ✓ DBSCAN은 반경 하나(eps)를 정하고, 그 반경 안의 이웃 수로 밀도를 정한다.
- ✓ 같은 점이라도 점 사이 거리가 바뀌면 DBSCAN의 군집 수가 바뀐다.
- ✓ UMAP이 만든 벡터는 거리에 정해진 단위가 없어 알맞은 반경을 미리 알 수 없다.
  - ○ HDBSCAN은 반경을 하나로 정하지 않아 거리가 바뀌어도 군집 수가 같다.

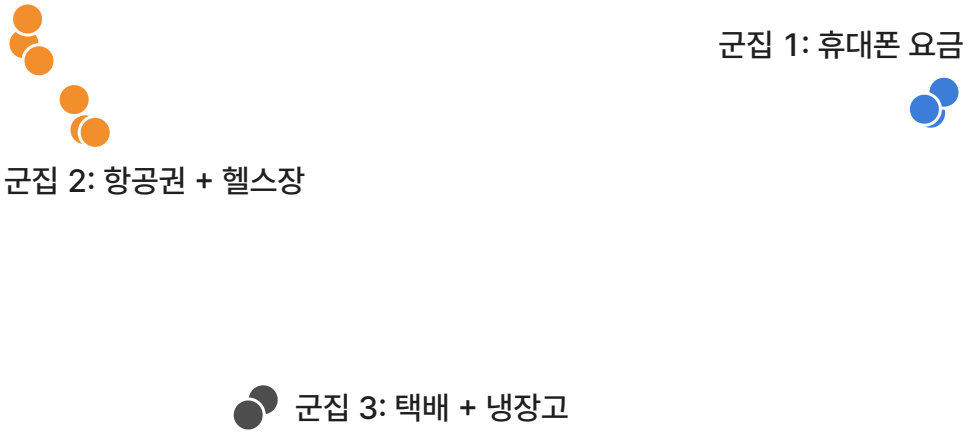


점 750개(scikit-learn 예제) · 회색 점: 이상치 · 원: 반경 0.3(점과 같은 배율)

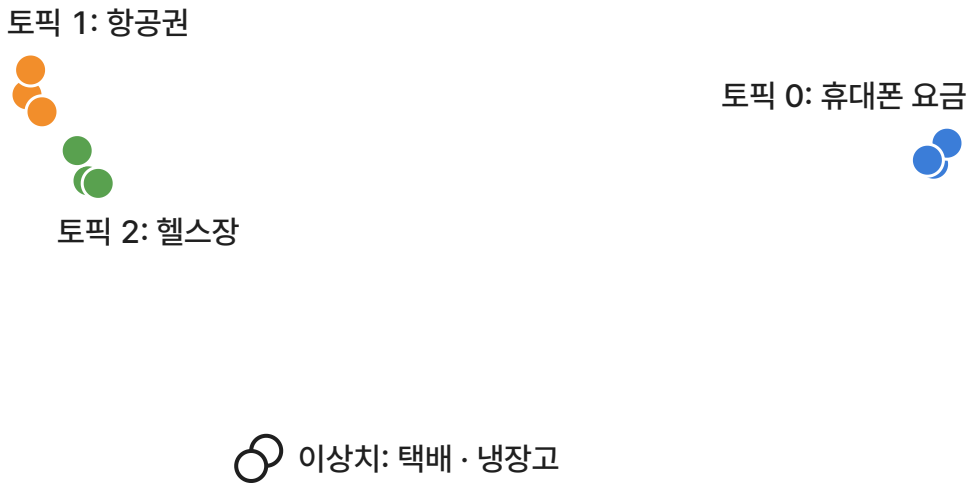
BERTopic - HDBSCAN

- ✓ K-Means는 군집 수 k를 정하고, 모든 문서를 가장 가까운 중심에 배정한다.
  - ○ 주제와 먼 문서도 어느 군집에 배정되어, 그 문서의 단어까지 그 군집의 단어 점수에 포함된다.
- ✓ HDBSCAN은 어느 군집에도 가깝지 않은 문서를 이상치로 남긴다.

K-Means(k = 3)

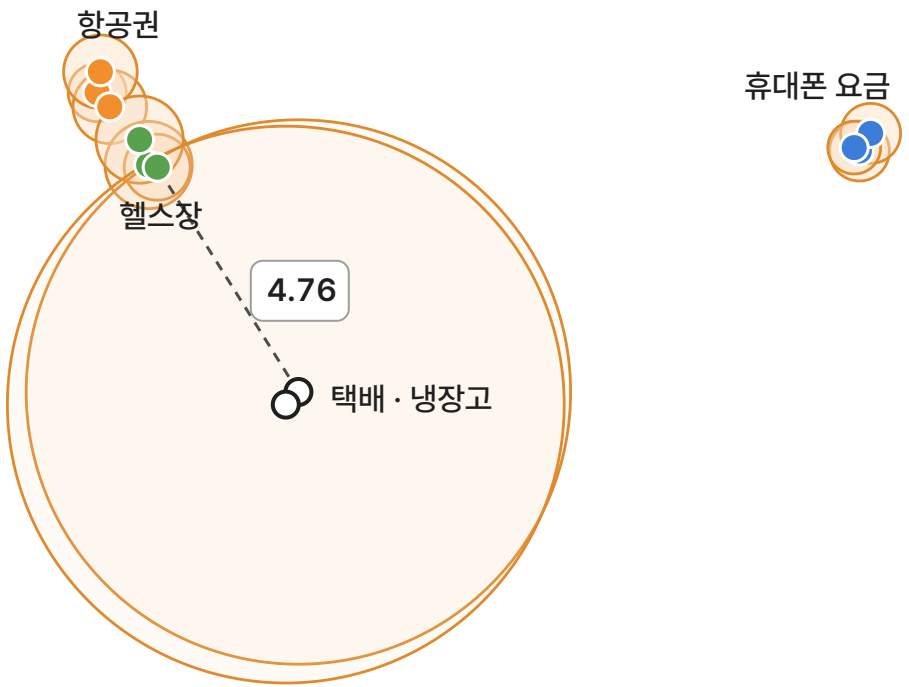


HDBSCAN



BERTopic - HDBSCAN

- ✓ Step 1 : 점마다 min_samples 번째로 가까운 이웃까지의 거리(핵심 거리)를 구한다.
  - ○ 이웃에 자기 자신은 포함하지 않는다(min_samples 2면 두 번째로 가까운 다른 점).
  - ○ 핵심 거리가 짧으면 주변이 밀집된 점이고, 길면 밀도가 낮은 영역의 점이다.
- ✓ 택배 · 냉장고는 서로 가깝지만 둘뿐이라, 두 번째 이웃이 헬스장 문장이어서 핵심 거리가 길다.

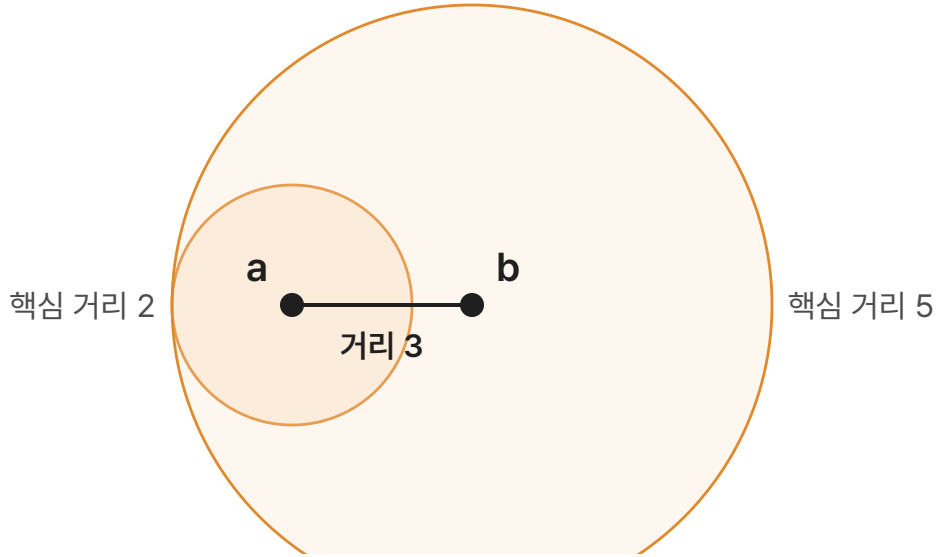


문장	두 번째로 가까운 문장	핵심 거리
휴대폰 요금	휴대폰 개통	0.52
휴대폰 개통	휴대폰 요금	0.52
통신비	휴대폰 요금	0.46
항공권 환불	항공권 수수료	0.51
항공권 수수료	결항 환불	0.64
결항 환불	항공권 수수료	0.64
헬스장 해지	피트니스 환불	0.76
헬스장 환불	피트니스 환불	0.58
피트니스 환불	헬스장 해지	0.76
택배	**헬스장 환불**	**4.76**
냉장고	**헬스장 환불**	**4.87**

원 반지름: 핵심 거리(위치와 같은 배율) · 위치: 5차원 결과를 PCA로 2차원에 그림

BERTopic - HDBSCAN

- ✓ Step 2 : 두 점마다 상호 도달 거리를 구한다.
  - ○ 상호 도달 거리(mutual reachability distance)는 두 점의 거리와 두 점의 핵심 거리 가운데 가장 큰 값이다.
  - ○ 예: 핵심 거리 2 · 5, 두 점의 거리 3 → 상호 도달 거리 5
  - ○ 주변 밀도가 낮은 점은 가까운 점과도 상호 도달 거리가 길어진다.
- ✓ 냉장고와 택배는 거리가 0.35 지만 상호 도달 거리는 4.87이다.



상호 도달 거리 = 2 · 5 · 3 가운데 가장 큰 값 = 5

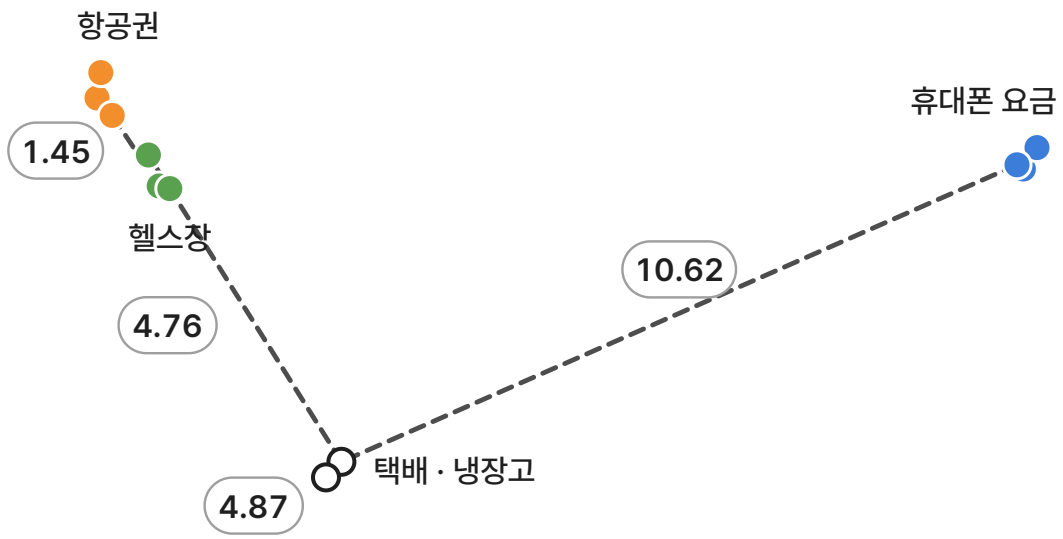
두 문장	거리	두 핵심 거리	상호 도달 거리
휴대폰 요금 · 통신비	0.46	0.52 · 0.46	0.52
헬스장 환불 · 피트니스 환불	0.58	0.58 · 0.76	0.76
택배 · 헬스장 환불	4.76	4.76 · 0.58	4.76
냉장고 · 택배	**0.35**	**4.87 · 4.76**	**4.87**

거리: 5차원 결과의 직선 거리 · 두 핵심 거리: 앞 문장과 뒤 문장의 핵심 거리

BERTopic - HDBSCAN

✓ Step 3 : 상호 도달 거리로 최소 신장 트리를 만든다.

- 최소 신장 트리(minimum spanning tree)는 모든 점을 이으면서 연결 길이의 합이 가장 작은 트리다.
- 점이 n개면 연결은 n – 1개다(예시 문장 11개 → 연결 10개).



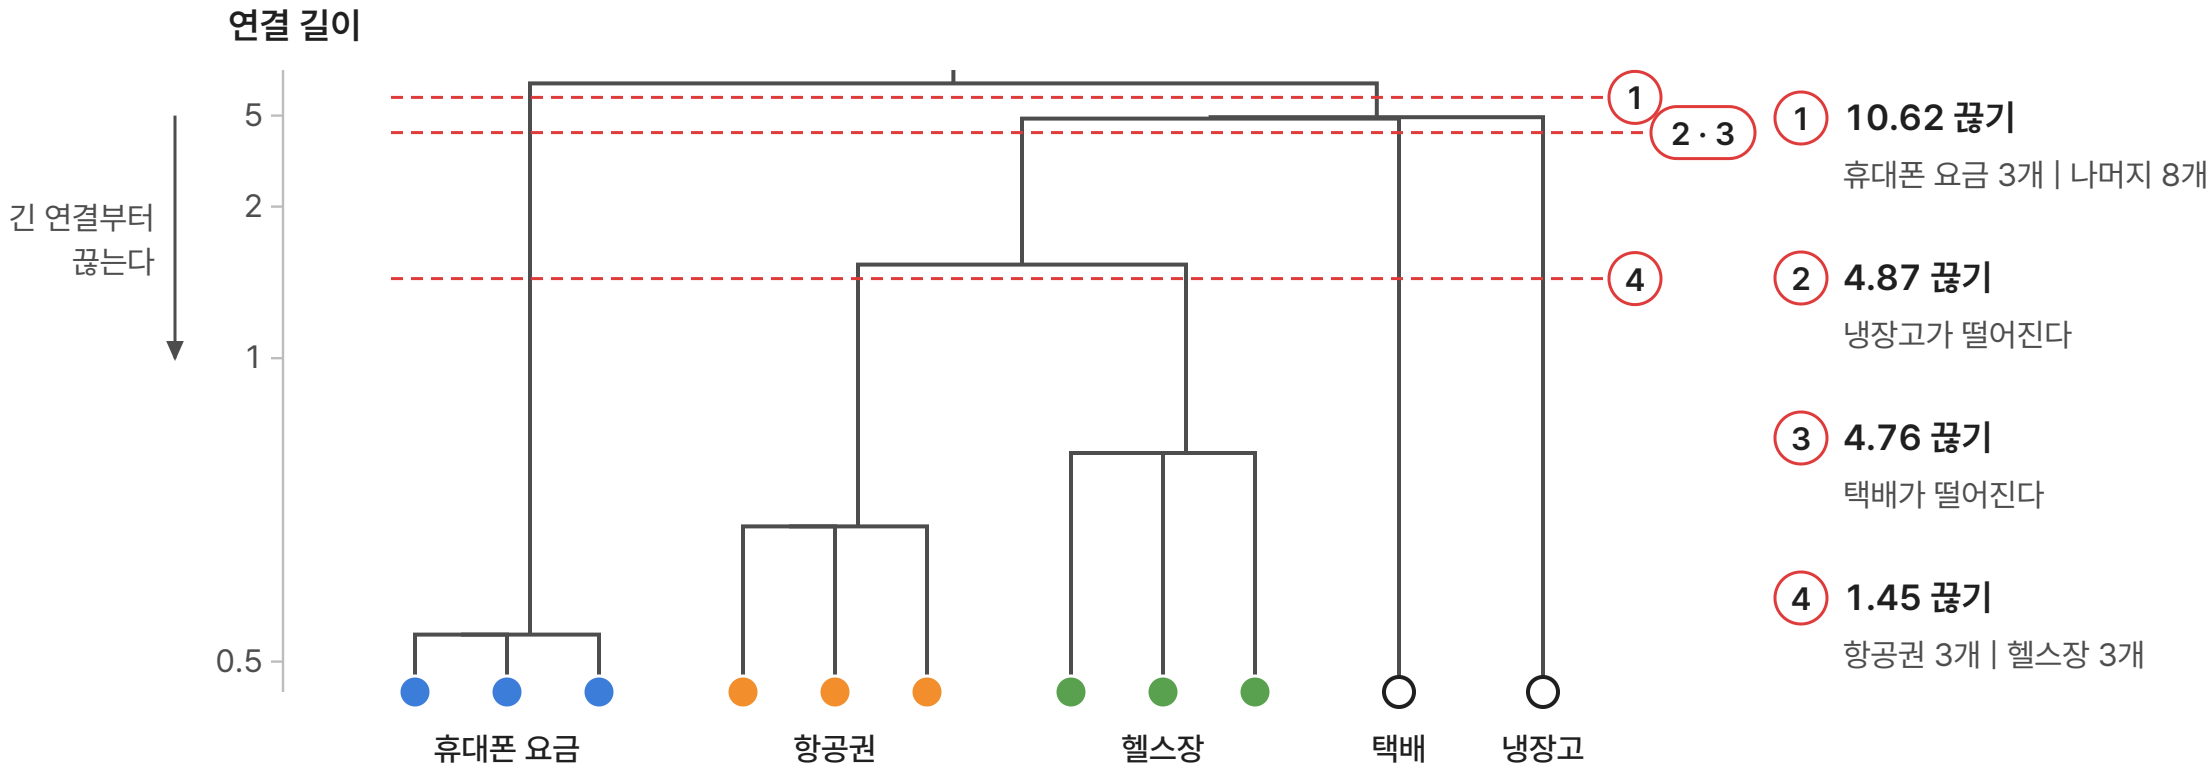
이은 두 문장(긴 것부터)	거리	상호 도달 거리
통신비 · 택배	10.62	10.62
냉장고 · 택배	0.35	4.87
택배 · 헬스장 환불	4.76	4.76
항공권 수수료 · 헬스장 해지	1.45	1.45
헬스장 해지 · 헬스장 환불	0.55	0.76
피트니스 환불 · 헬스장 환불	0.58	0.76
항공권 수수료 · 항공권 환불	0.51	0.64
결항 환불 · 항공권 환불	0.48	0.64
휴대폰 요금 · 통신비	0.46	0.52
휴대폰 개통 · 통신비	0.40	0.52

점선: 길이가 긴 연결 4개(다음 Step 에서 긴 것부터 끊는다) · 위치: 5차원 결과를 PCA로 2차원에 그림

BERTopic - HDBSCAN

✓ Step 4 : 가장 긴 연결부터 끊으면 군집이 차례로 나뉜다(계층 트리).

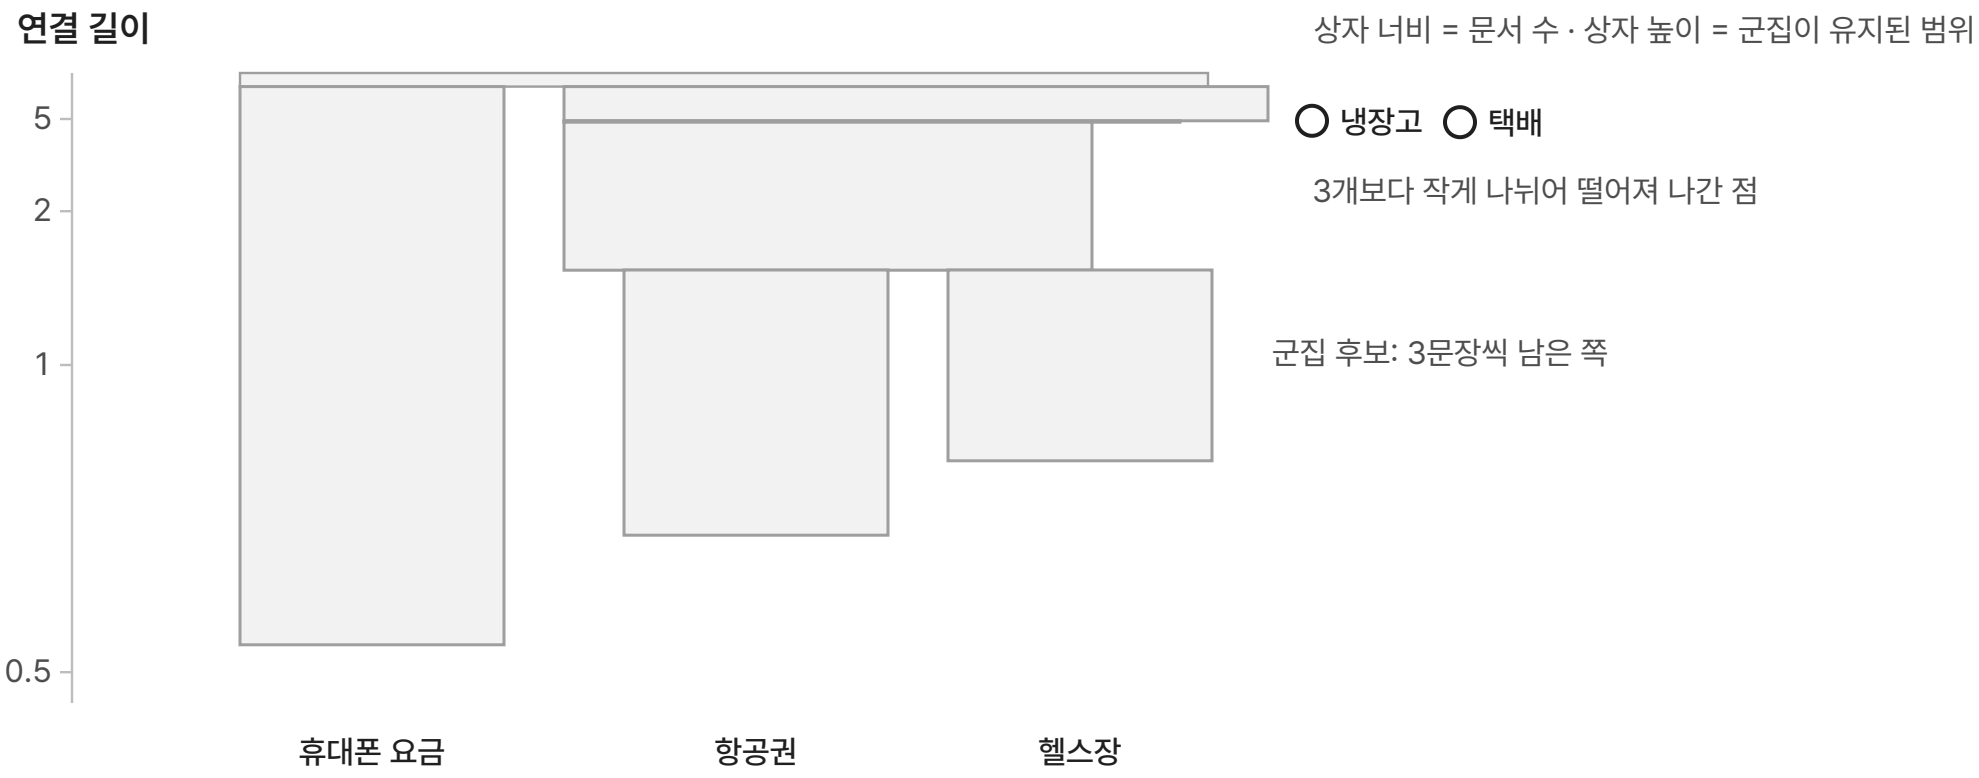
- 10.62를 끊으면 휴대폰 요금 문장 3개와 나머지 8개로 나뉜다.
- 이어서 4.87을 끊으면 냉장고가, 4.76을 끊으면 택배가 하나씩 떨어진다.
- 1.45를 끊으면 항공권 3개와 헬스장 3개로 나뉜다.



세로 위치: 1 ÷ 연결 길이에 비례(위로 갈수록 연결이 길다)

BERTopic - HDBSCAN

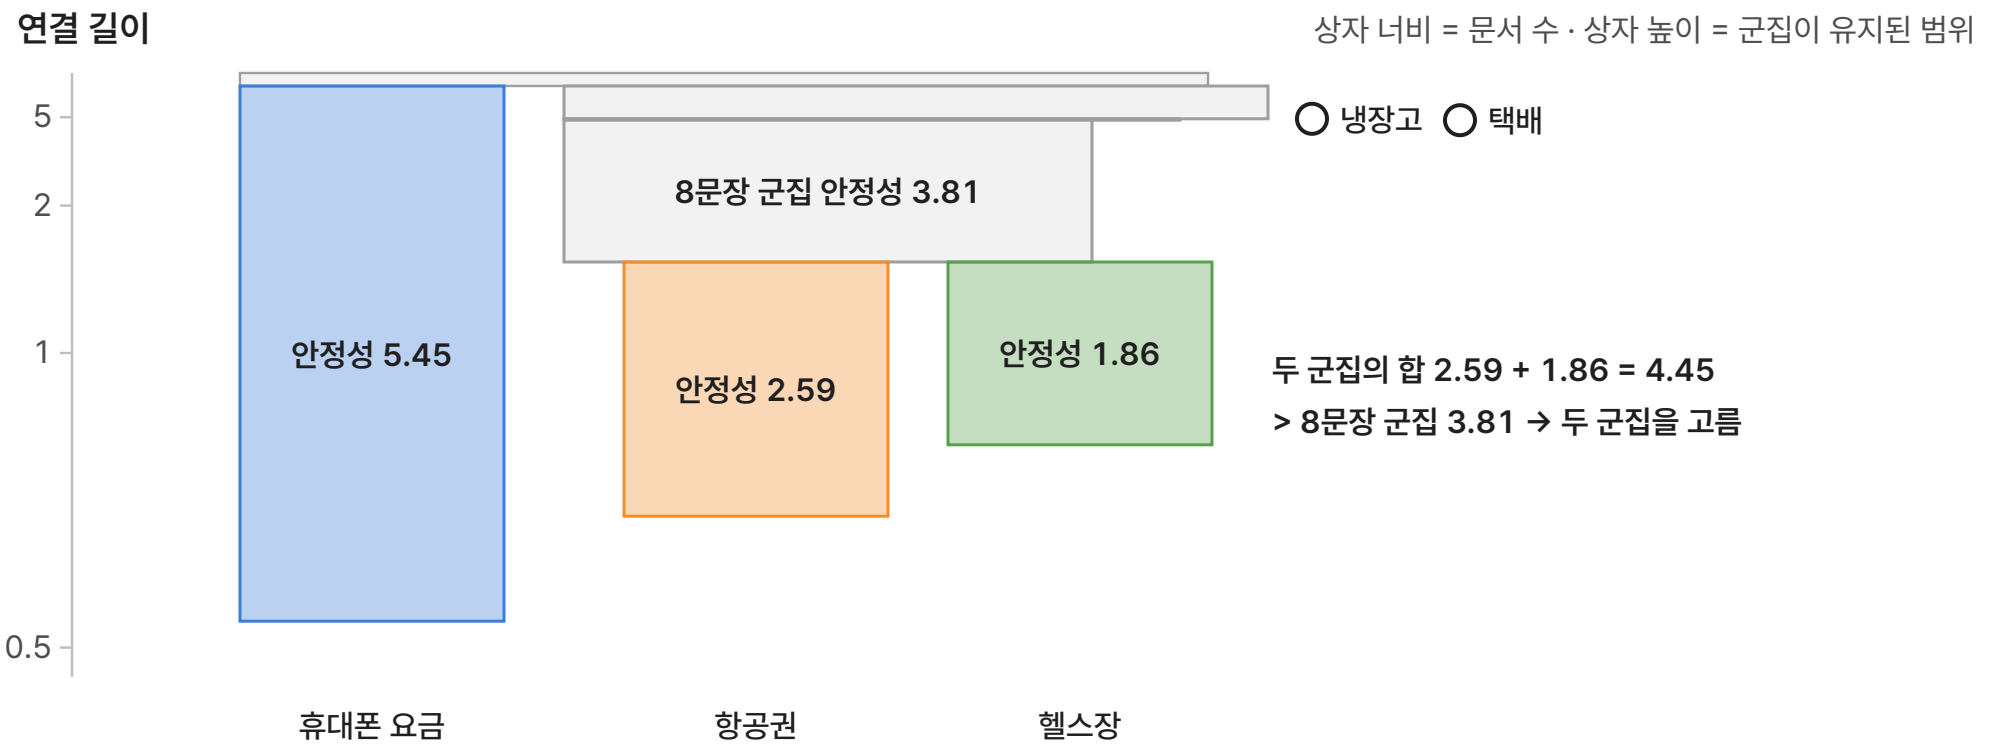
- ✓ Step 5 : min_cluster_size보다 작게 나뉜 쪽은 떨어져 나간 점으로 정리한다(응축 트리).
  - ○ 예시 문장의 min_cluster_size는 3이다.
  - ○ 냉장고 · 택배는 하나씩 나뉘어 3보다 작으므로 떨어져 나간 점이 된다.
  - ○ 휴대폰 요금 · 항공권 · 헬스장은 3문장씩이라 군집 후보로 남는다.



세로 위치: 1 ÷ 연결 길이에 비례(위로 갈수록 연결이 길다)

BERTopic - HDBSCAN

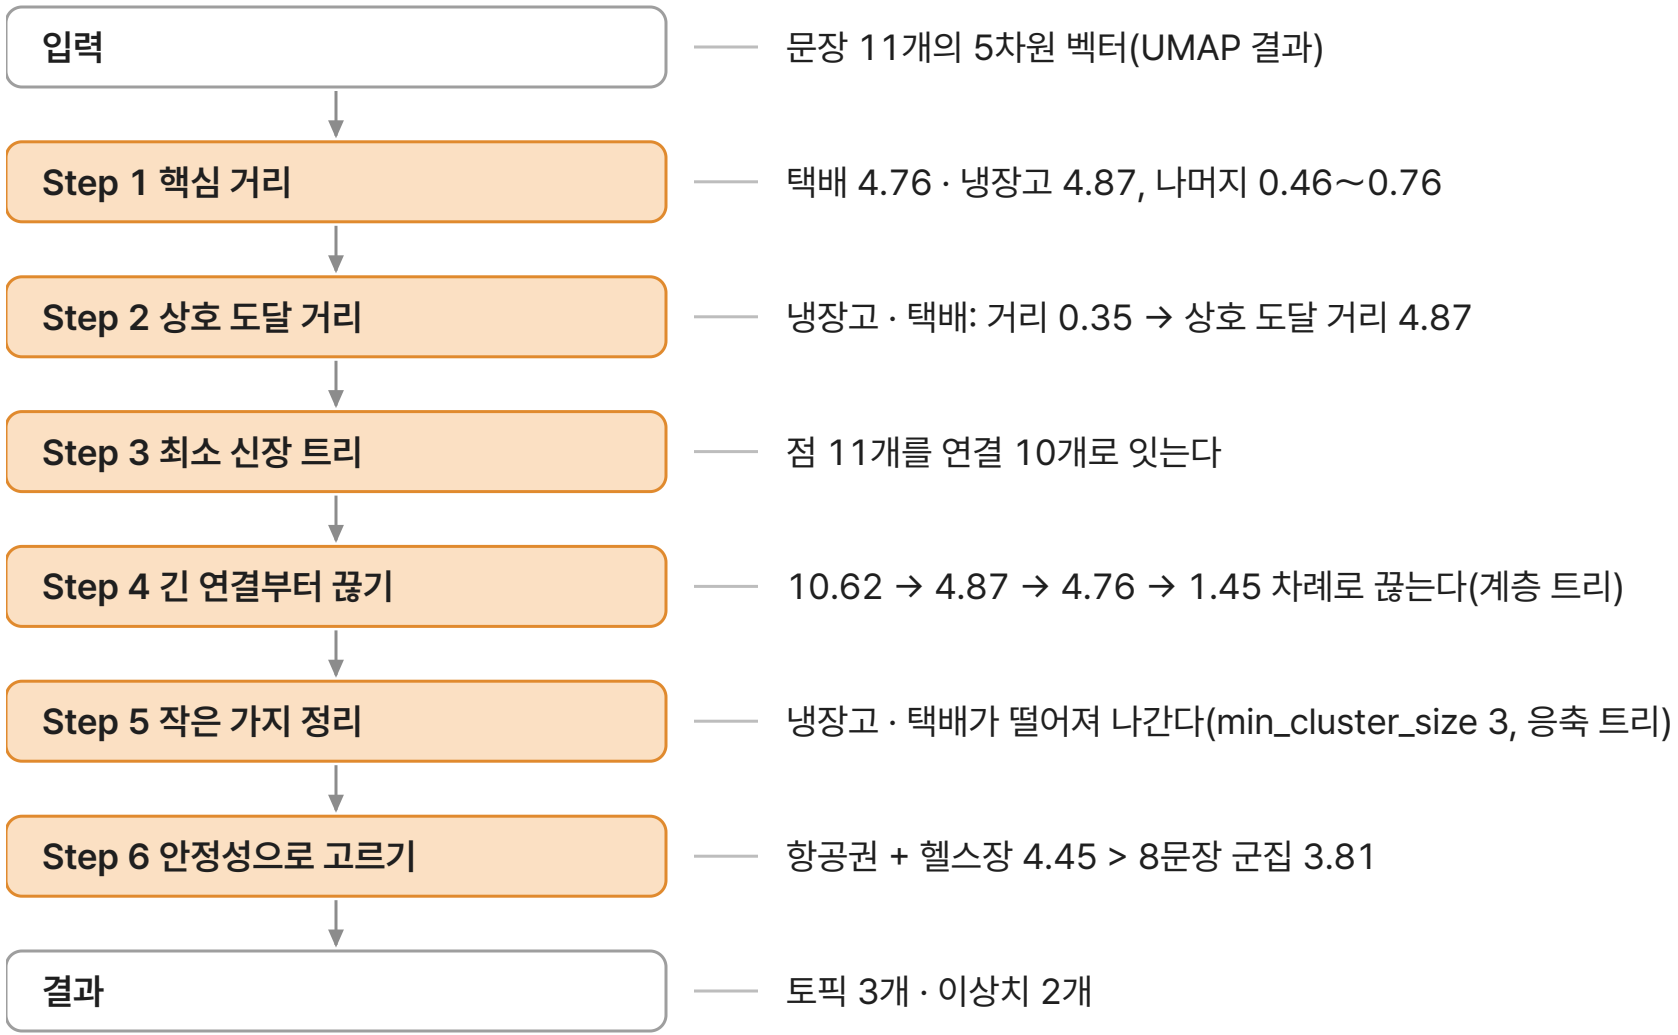
- ✓ Step 6 : 여러 거리 기준에서 계속 유지되는 군집을 고른다.
  - ○ 군집 안정성(stability)은 거리 기준을 넓은 범위로 바꿔도 군집이 유지되는 정도다.
  - ○ 한 군집과 그 안에서 나뉜 군집은 함께 고르지 않고, 안정성이 큰 쪽을 고른다.
- ✓ 고르지 않은 점은 이상치가 된다.



안정성: 상자의 넓이(문서 수 × 유지된 범위, 범위는 1 ÷ 연결 길이의 차이)

BERTopic - HDBSCAN

✓ HDBSCAN은 트리 3개(최소 신장 트리 → 계층 트리 → 응축 트리)를 차례로 만들어 군집을 고른다.



BERTopic - HDBSCAN

- ✓ 예시 문장 11개에서는 토픽 3개와 이상치 2개가 나왔다.
- ✓ 토픽 수 3은 미리 정한 수가 아니라 HDBSCAN 결과로 나온 수다.
  - ○ 시드를 바꾸면 이상치인 택배 · 냉장고 문장이 토픽 0에 속하기도 한다.



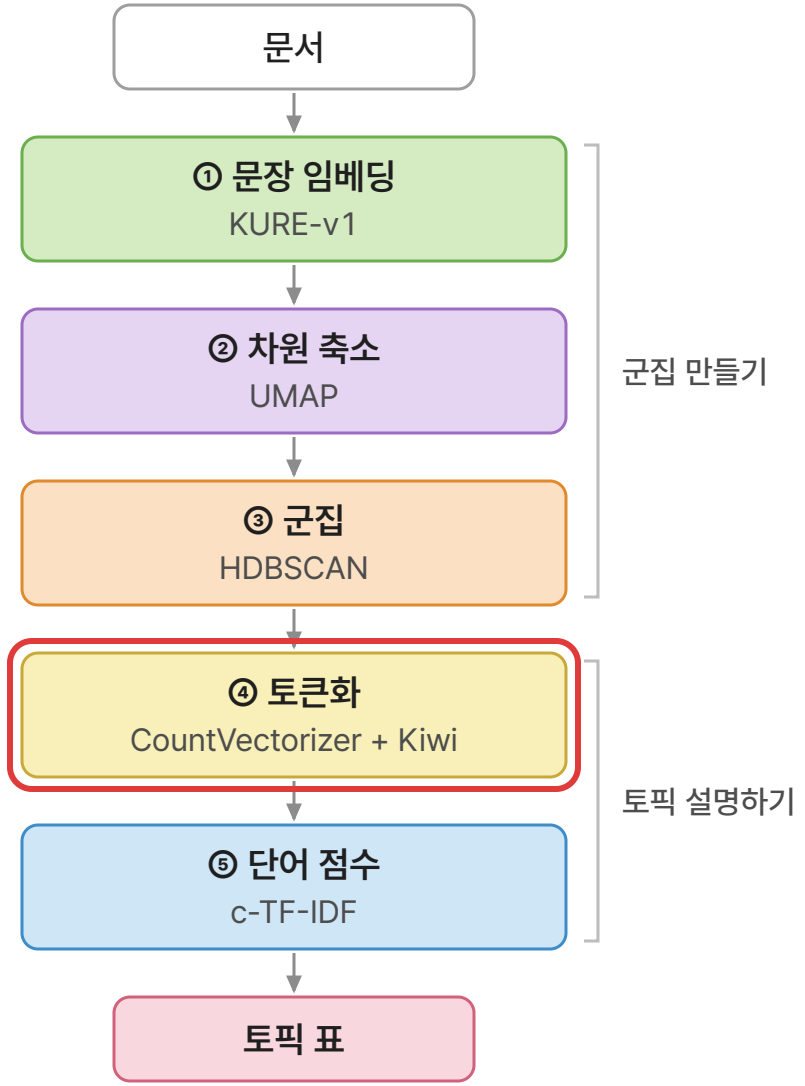
BERTopic - HDBSCAN

- ✓ min_cluster_size : 군집으로 볼 최소 문서 수. 키우면 작은 군집이 빠져 토픽 수가 줄어든다.
- ✓ min_samples : 밀도를 구할 때 쓰는 이웃 수. 키우면 이상치가 늘어난다.
  - ○ 정하지 않으면 min_cluster_size와 같다.
  - ○ 키우면 더 먼 이웃까지의 거리가 핵심 거리가 되어, 주변 문서가 적은 점부터 이상치가 된다.
  - ○ 예시 문장은 주제마다 3문장이라, 기본값 3이면 11개 모두 이상치가 되어 2를 썼다.

	min_samples 1	min_samples 2	min_samples 3
min_cluster_size 2	토픽 4개 · 이상치 0개	토픽 3개 · 이상치 2개	토픽 0개 · 이상치 11개
min_cluster_size 3	토픽 3개 · 이상치 2개	**토픽 3개 · 이상치 2개**	토픽 0개 · 이상치 11개
min_cluster_size 4	토픽 0개 · 이상치 11개	토픽 0개 · 이상치 11개	토픽 0개 · 이상치 11개

BERTopic - 토큰화

- ✓ 토픽마다 그 토픽의 문서를 모두 합쳐 토픽 문서 하나로 만든다.
- ✓ 토픽 문서를 단어로 나누고 단어마다 나온 횟수를 구한다(CountVectorizer).
- ✓ 한국어는 형태소 분석기(Kiwi)로 명사만 남기고 불용어를 뺀다.



BERTopic - 토큰화

✓ 토픽 번호가 같은 문서를 합쳐 토픽 문서 4개(토픽 0 · 1 · 2 · 이상치)를 만든다.

● **토픽 0**	휴대폰 요금 약정 청구 개통 휴대폰 요금 이번 달 통신비 배	**명사 11개**
● **토픽 1**	항공사 항공 환불 항공 취소 수수료 결항 항공편 환불	**명사 9개**
● **토픽 2**	헬스장 중도 해지 위약금 헬스장 회원권 환불 거절 피트니스 센터 이용 환불	**명사 12개**
○ **이상치**	택배 상자 냉장고 문	**명사 4개**

BERTopic - 토큰화

- ✓ 기본 설정(language="english")은 영어 단어만 남긴다.
  - ○ 한국어 문서에서는 토픽 단어가 비거나 영문 약자만 남는다.
- ✓ language를 "multilingual"로 바꾸고, 형태소 분석기를 쓰는 CountVectorizer를 지정한다.

기본 설정

```
topic_model = BERTopic()
# language="english" 가 기본값
topics, _ = topic_model.fit_transform(docs)
```

예시 문장 11개 → ValueError: empty vocabulary

민원 → 상위 단어가 KT · LG 같은 영문 약자뿐

Kiwi 명사 + CountVectorizer

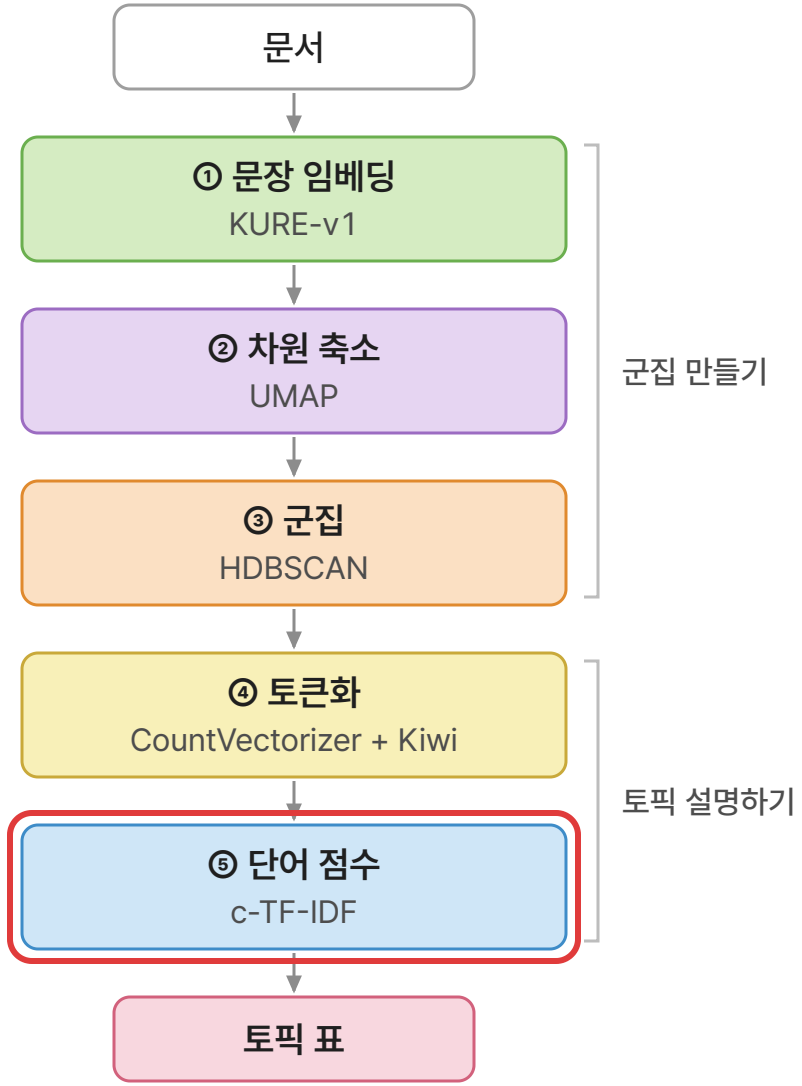
```
vec = CountVectorizer(tokenizer=kiwi_nouns,
                      token_pattern=None)
topic_model = BERTopic(language="multilingual",
                       vectorizer_model=vec)
```

예시 문장 11개 → 토픽 0: 휴대폰 · 요금

민원 → 토픽 0: 개통 · 요금 · 휴대폰

BERTopic - c-TF-IDF

- ✓ c-TF-IDF(class-based TF-IDF)는 토픽마다 단어에 점수를 매긴다.
- ✓ 그 토픽에 자주 나오고 다른 토픽에는 드문 단어일수록 점수가 크다.
- ✓ 상위 단어는 점수가 가장 큰 단어들이다.



BERTopic - c-TF-IDF

$$W = \underbrace{\mathrm{tf}}_{\text{토픽 문서 안 비율}} \times \underbrace{\log\left(1 + A \div f_t\right)}_{\text{로그 항}}$$

- tf : 토픽 문서 안에서 그 단어가 차지하는 비율
- f_t : 모든 토픽 문서에서 그 단어가 나온 횟수
- A : 토픽 문서 하나의 평균 단어 수(예시 문장: 36 ÷ 4 = 9)

✓ TF-IDF와 달리 문서 대신 토픽 문서를 쓰고, 로그 항의 「문서 수 ÷ 단어가 나온 문서 수」가 「$A \div f_t$」로 바뀐다.

	TF-IDF	c-TF-IDF
점수를 매기는 단위	문서 하나	토픽 문서 하나(토픽의 문서를 합친 것)
로그 항	log(문서 수 ÷ 단어가 나온 문서 수)	log(1 + $A \div f_t$)

BERTopic - c-TF-IDF

✓ Step 1 : 토픽 문서 안 비율(tf)을 구한다.

○ 토픽 2(헬스장) 문서의 명사 12개 가운데 「헬스장」 2번, 「환불」 2번, 「거절」 1번

토픽 2(헬스장)의 토픽 문서, 명사 12개

단어	토픽 안 횟수	tf	f_t	로그 항	점수
헬스장	2	0.1667			
환불	2	0.1667			
거절	1	0.0833			

BERTopic - c-TF-IDF

✓ Step 2 : 다른 토픽에도 흔한 단어는 로그 항을 작게 만든다.

- 「환불」은 항공권 토픽에도 나와 f_t가 4이고, 로그 항이 1.18이다.
- 「헬스장」은 이 토픽에만 나와 로그 항이 1.70이다.

토픽 2(헬스장)의 토픽 문서, 명사 12개

단어	토픽 안 횟수	tf	f_t	로그 항	점수
헬스장	2	0.1667	**2**	**1.7047**	
환불	2	0.1667	**4**	**1.1787**	
거절	1	0.0833	**1**	**2.3026**	

BERTopic - c-TF-IDF

✓ Step 3 : 두 값을 곱한 점수로 상위 단어를 고른다.

- 같은 2번이어도 「환불」(0.1964)은 「헬스장」(0.2841)보다 점수가 낮다.
- 「거절」은 로그 항이 가장 크지만 횟수가 1이라 토픽 안 비율이 1/12 이어서, 점수는 「환불」보다 조금 낮다.

토픽 2(헬스장)의 토픽 문서, 명사 12개

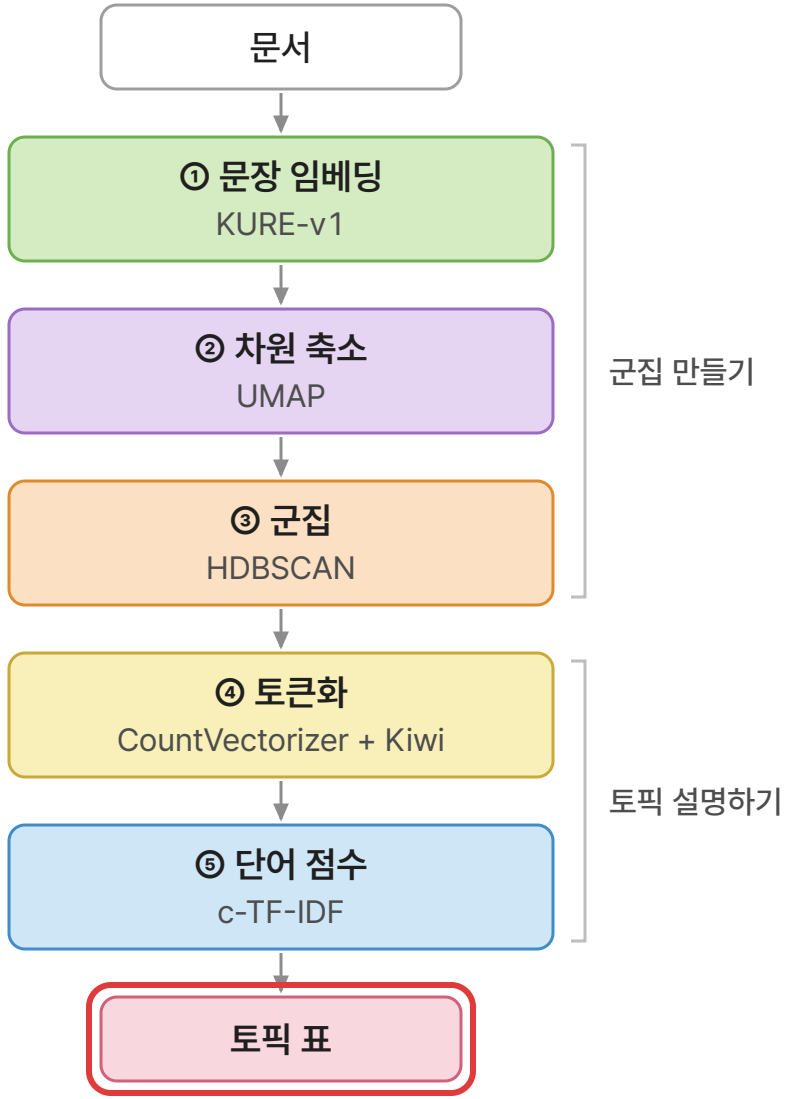
단어	토픽 안 횟수	tf	f_t	로그 항	점수
헬스장	**2**	**0.1667**	**2**	**1.7047**	**0.2841**
환불	2	0.1667	4	1.1787	**0.1964**
거절	1	0.0833	1	2.3026	**0.1919**

$$W_{\text{헬스장}} = \frac{2}{12} \times \log\left(1 + \frac{9}{2}\right) = 0.2841$$

BERTopic - 토픽 표

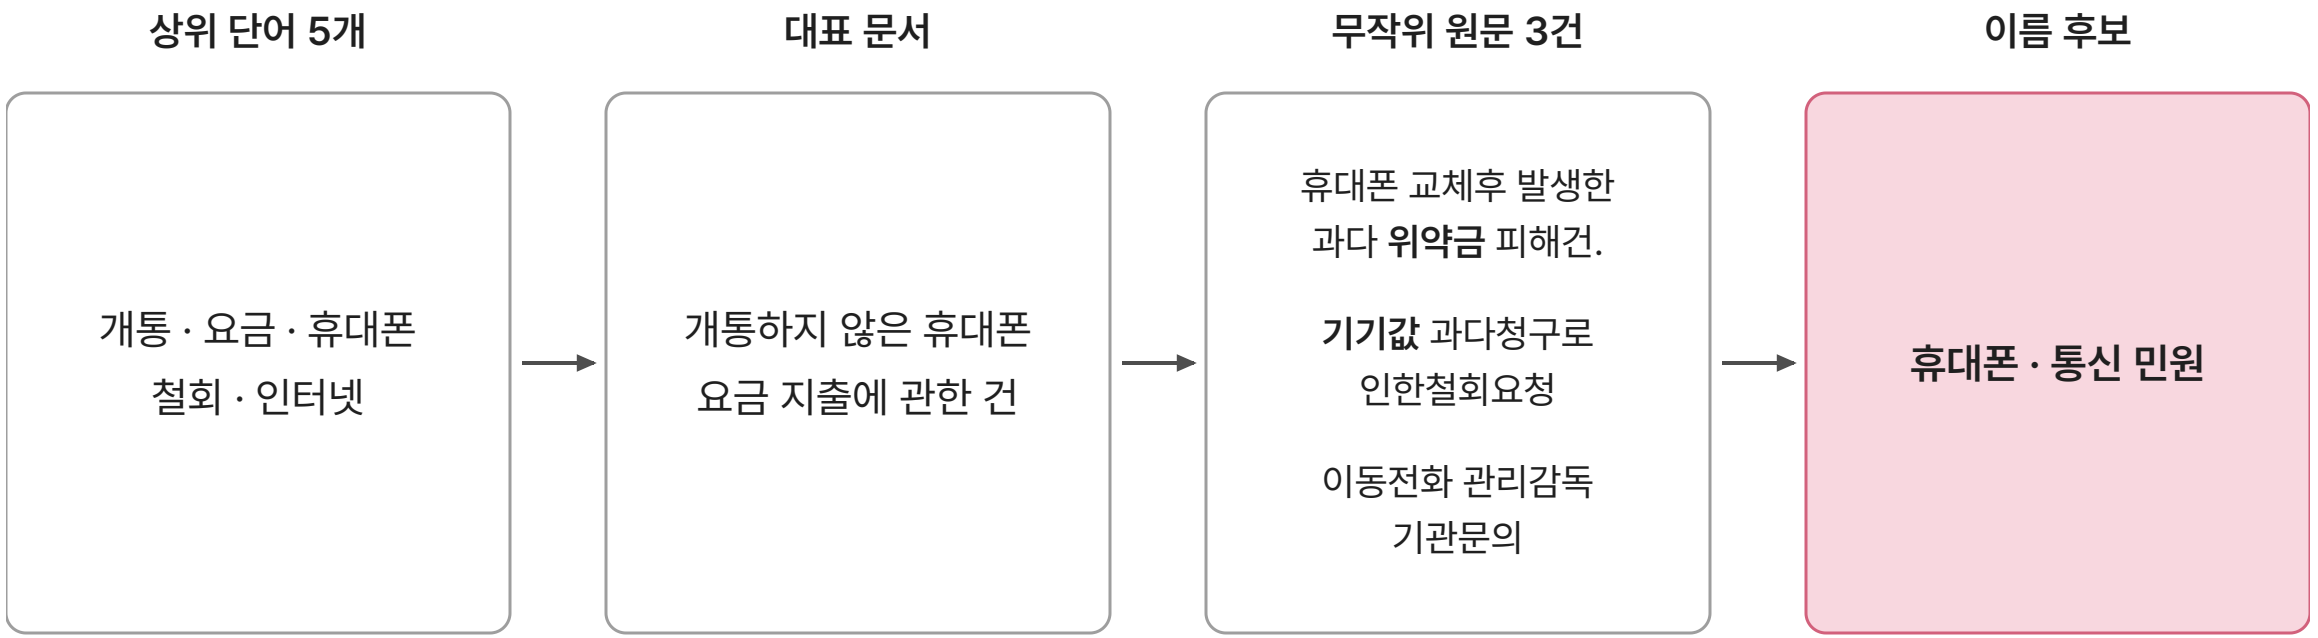
- ✓ 최종 출력은 문서마다 토픽 번호, 토픽마다 건수 · 비율 · 상위 단어다.
- ✓ 비율은 이상치까지 포함한 전체 문서 수로 나눈다.
  - ○ 이상치를 빼고 나누면 모든 토픽이 실제보다 커 보인다.

토픽	건수	비율(전체 11건)	상위 단어
● 토픽 0	3	27.3%	휴대폰 · 요금
● 토픽 1	3	27.3%	항공 · 환불
● 토픽 2	3	27.3%	헬스장 · 환불
○ 이상치(−1)	2	18.2%	택배 · 상자 · 문 · 냉장고



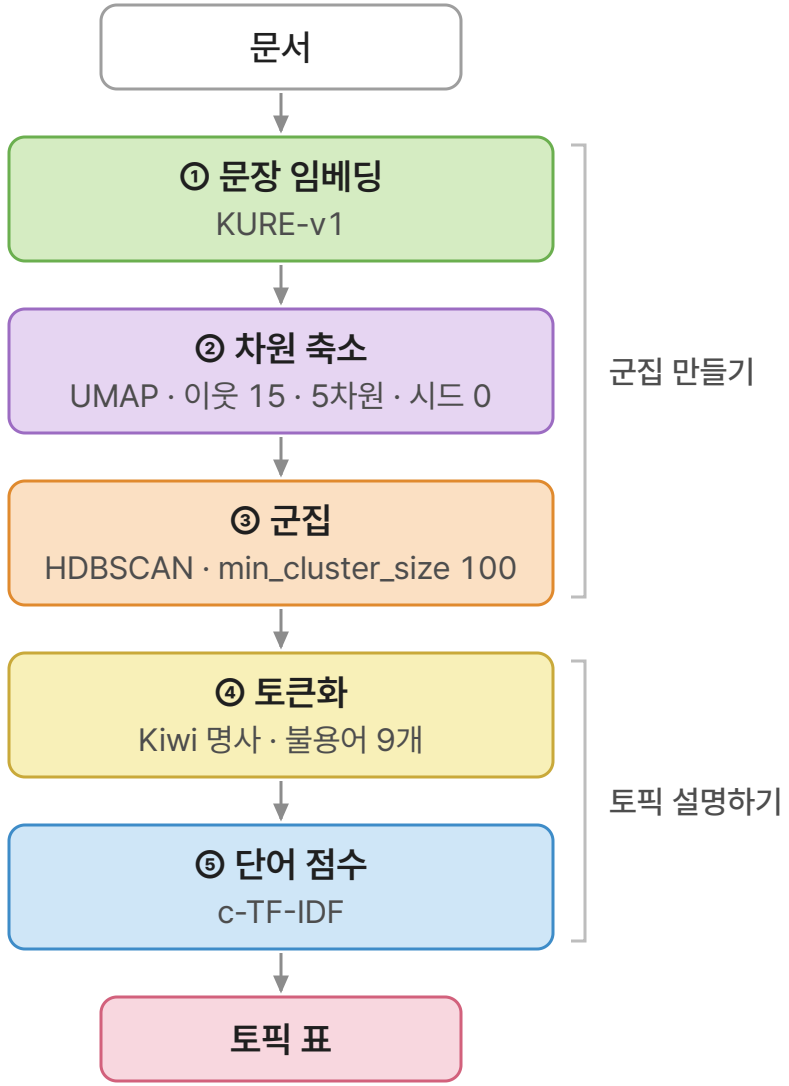
BERTopic - 토픽 이름

- ✓ 상위 단어는 토픽 이름의 후보다.
- ✓ 이름은 상위 단어로 후보를 정하고, 대표 문서와 무작위 원문으로 확인한다.
  - ○ 상위 단어에 없는 내용이 원문에 있을 수 있다(민원 2만 건 토픽 0: 위약금 · 기기값).



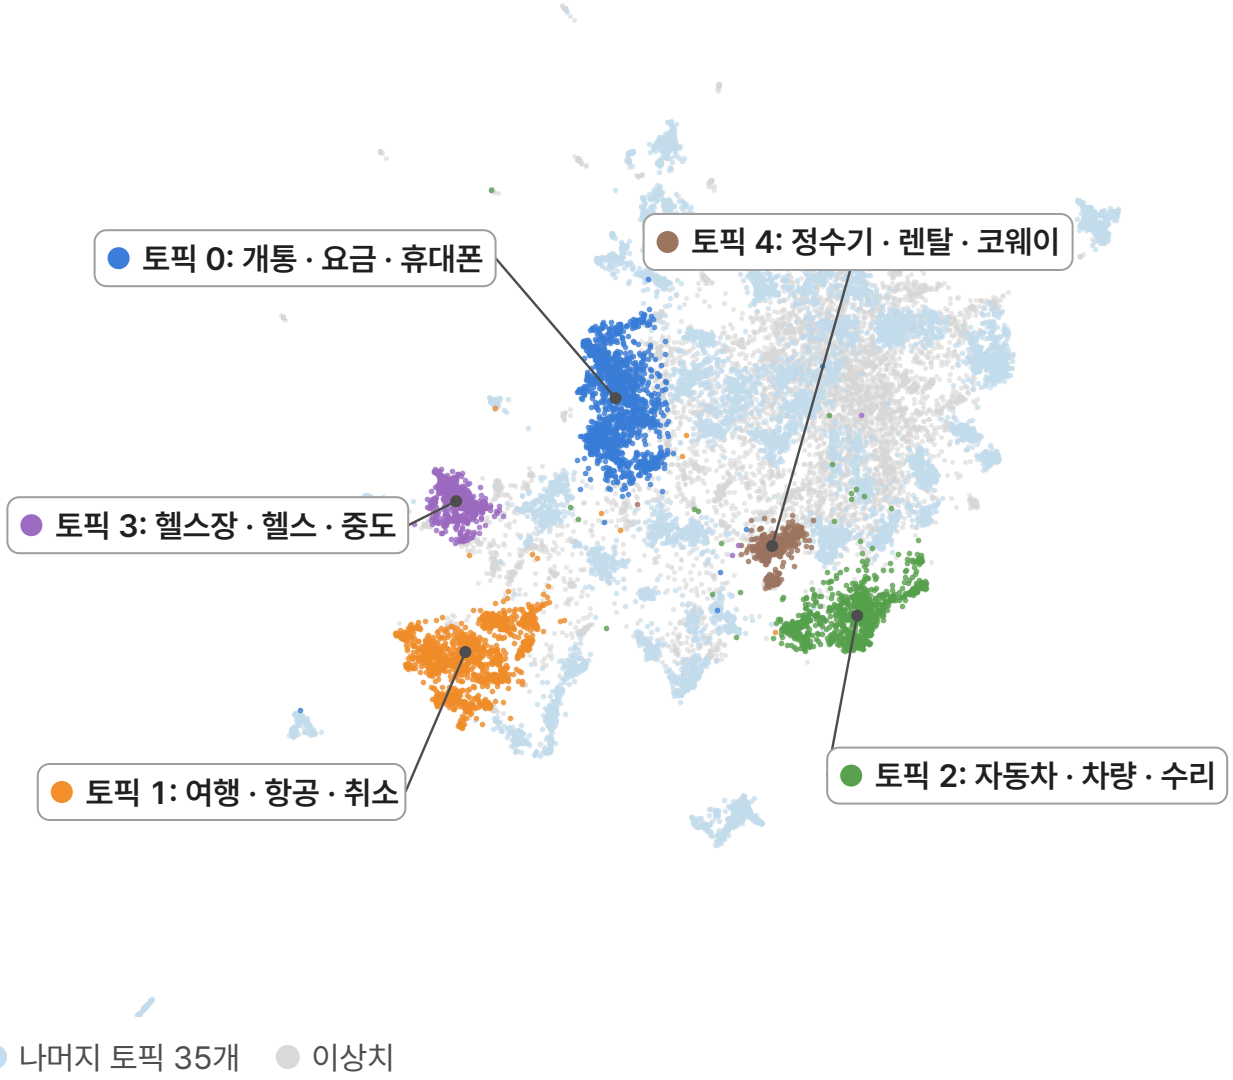
BERTopic - 민원 2만 건

- ✓ 공정위 민원 2만 건에 같은 부품 5개를 썼다.
  - KURE-v1 · UMAP(이웃 15, 5차원, 시드 0) · HDBSCAN(min_cluster_size 100)
  - Kiwi 명사(불용어 9개) · c-TF-IDF
  - 이웃 15는 BERTopic 기본값이고, min_cluster_size 100은 시드를 바꿔도 토픽 수가 같은 값이다.



BERTopic - 민원 2만 건

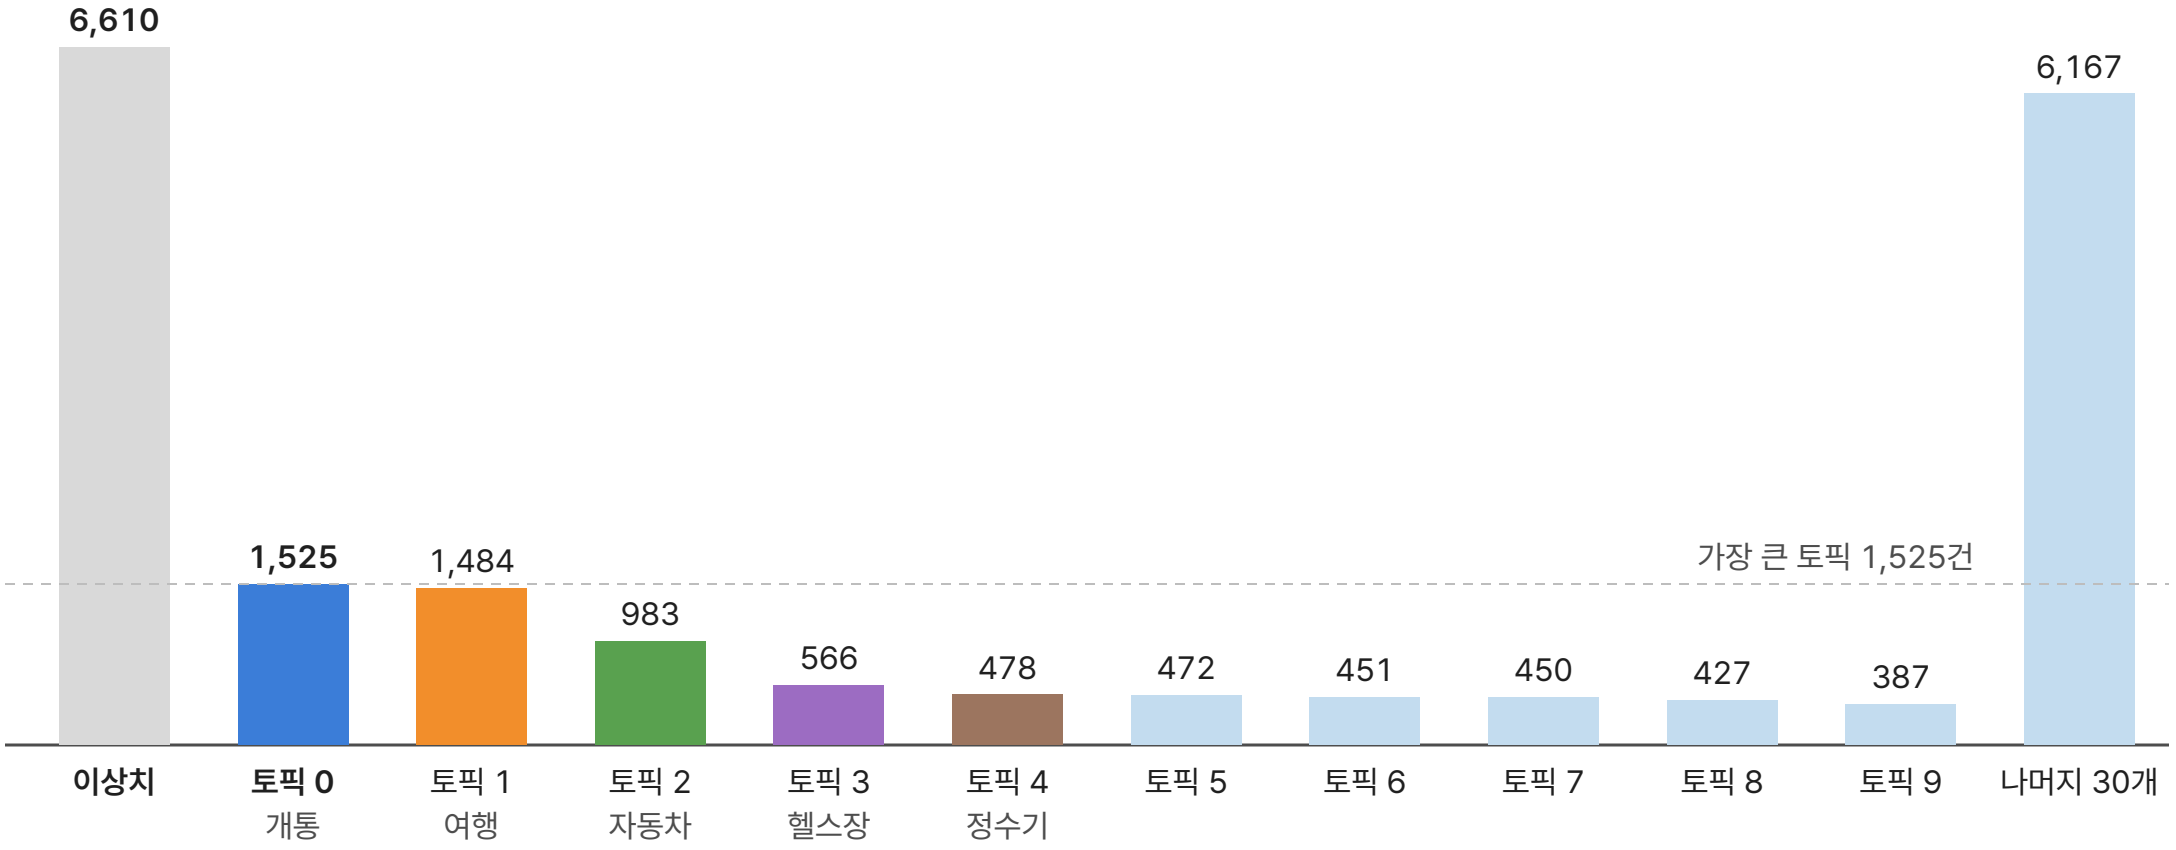
- ✓ 토픽 40개가 나왔고, 민원 3건 가운데 1건은 이상치다.
  - ○ 토픽에 속한 민원 13,390건, 이상치 6,610건(33.05%)
  - ○ 이상치는 어느 토픽에도 가깝지 않은 민원이라 한 주제로 보지 않는다.



위치: UMAP 2차원(군집은 5차원) · 2차원 그림의 위치에는 단위가 없다 · 그림 밖 331건

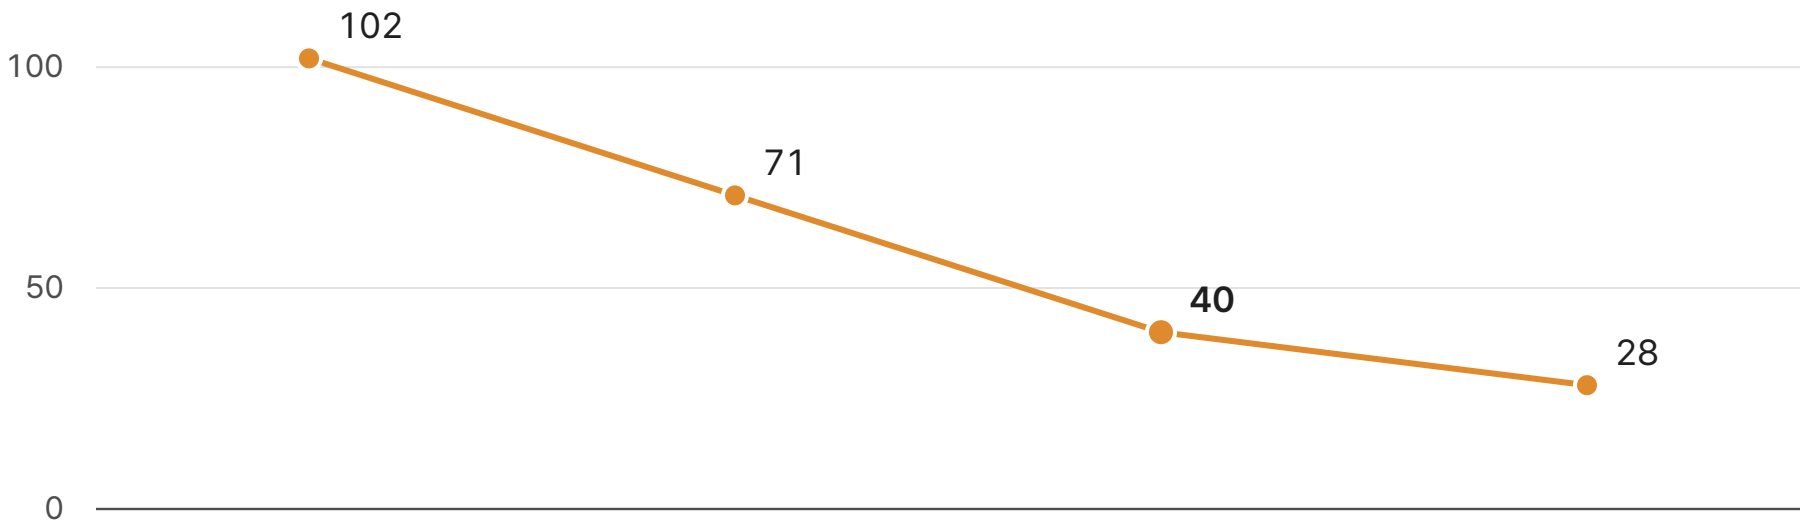
BERTopic - 민원 2만 건

- ✓ 이상치는 어느 한 토픽보다 크다.
- ✓ 토픽 표에 이상치도 항목 하나로 포함하고, 비율은 전체 2만 건으로 나눈다.
  - ○ 가장 큰 토픽 0은 7.63%(이상치를 빼고 나누면 11.39%)



BERTopic - 민원 2만 건

- ✓ min_cluster_size를 키우면 토픽 수가 줄어든다.
- ✓ 100은 시드를 바꿔 3번 적합해도 토픽 수가 같았다.
  - ○ 150도 토픽 수가 같았지만 이상치가 43.55%로 많다.

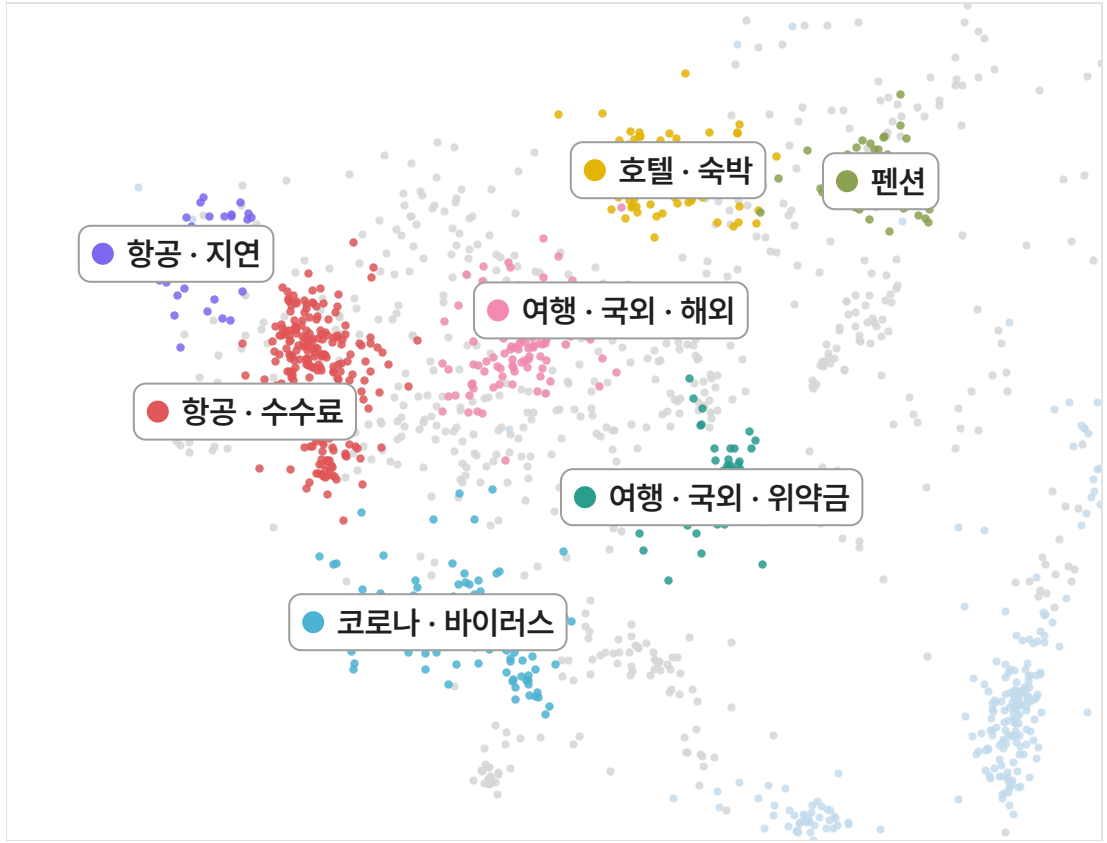


min_cluster_size	30	50	100	150
토픽 수(시드 0 · 1 · 2)	102 · 96 · 103	71 · 74 · 74	**40 · 40 · 40**	28 · 28 · 28
이상치 비율(시드 0)	35.10%	31.91%	**33.05%**	43.55%

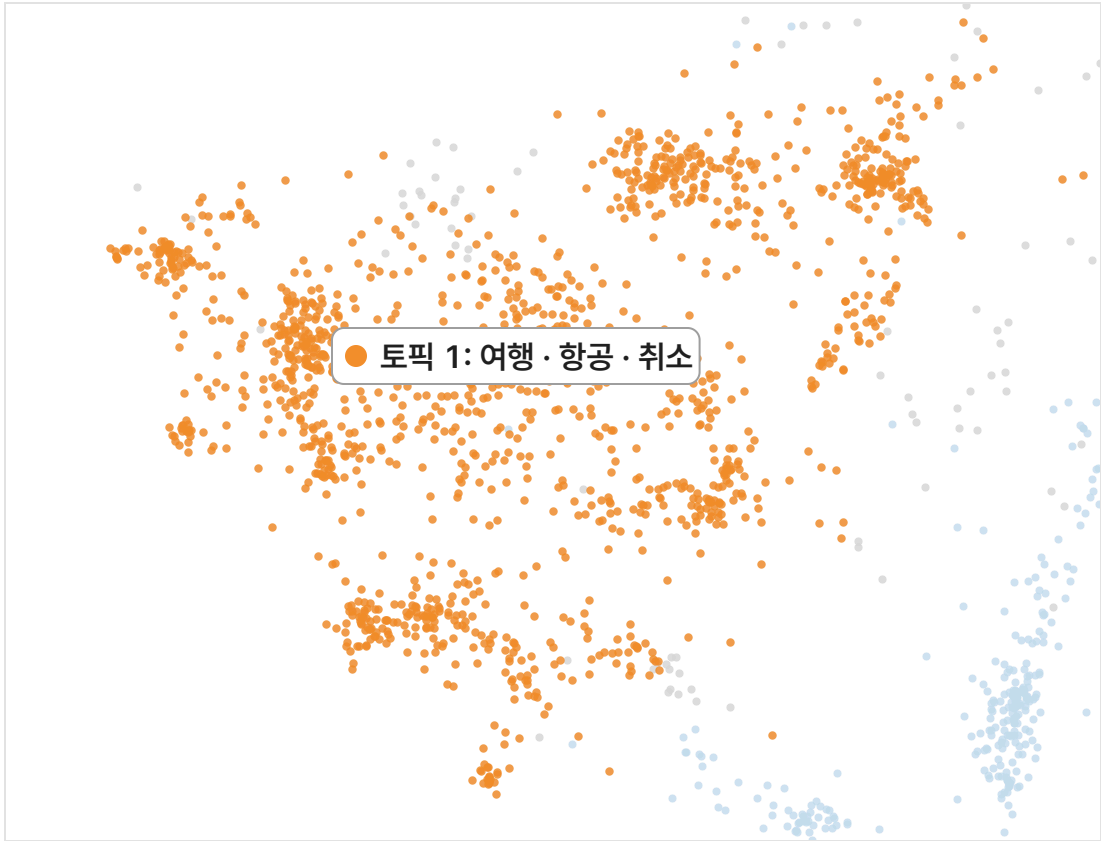
BERTopic - 민원 2만 건

- ✓ min_cluster_size 50에서 따로였던 여행 관련 토픽 7개가 100에서는 토픽 하나가 된다.
  - ○ 토픽 7개의 952건과 그 사이 이상치 532건이 합쳐져 토픽 1(1,484건)이 된다.

min_cluster_size 50: 토픽 7개 952건 + 이상치 532건



min_cluster_size 100: 토픽 1 1,484건



토픽 1 근처를 확대(UMAP 2차원 위치) · 회색 점: 이상치 · 옅은 하늘 점: 다른 토픽

BERTopic - 민원 2만 건

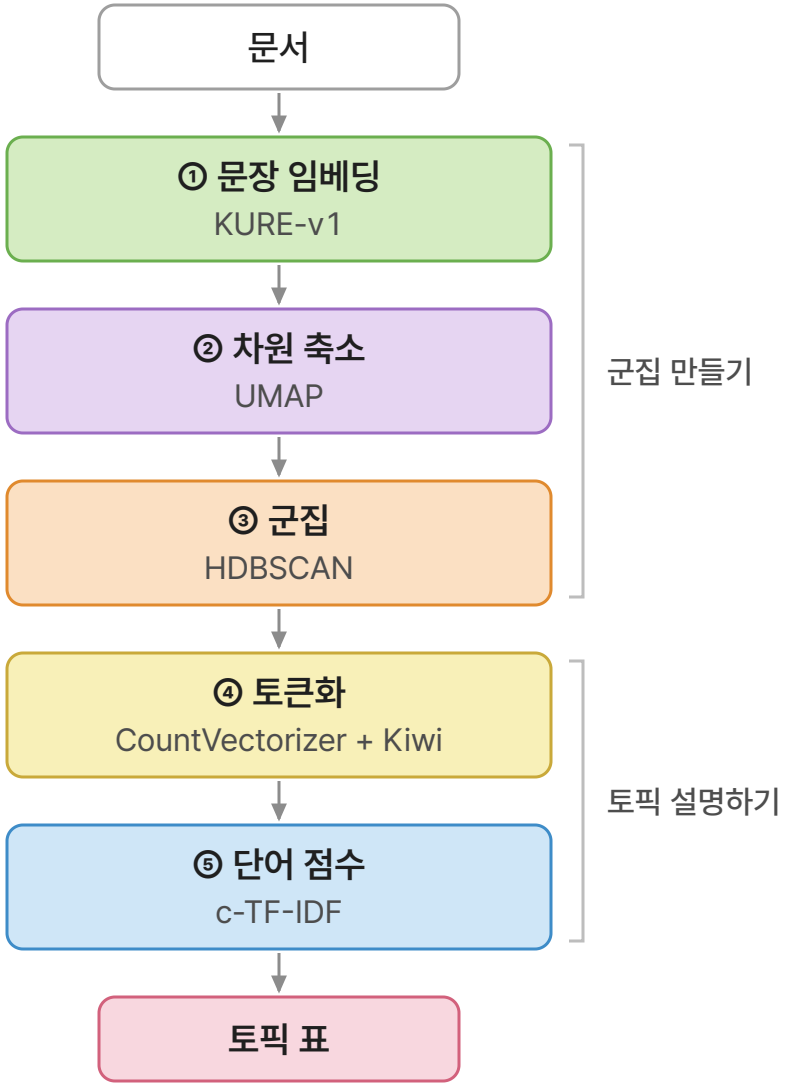
- ✓ 「해지」는 토픽 0에 378번 나와 「개통」(266번)보다 많다.
- ✓ 하지만 「해지」는 다른 토픽에도 흔해 점수가 낮고, 「개통」이 1위다.

민원 2만 건 토픽 0의 토픽 문서(명사 8,063개, A = 2,350)

단어	토픽 안 횟수	tf	f_t	로그 항	점수
개통	**266**	**0.0330**	**271**	**2.2692**	**0.0749**
해지	378	0.0469	2,176	0.7324	0.0343

BERTopic - 정리

- ✓ ①~③으로 비슷한 문서끼리 군집을 만들고, ④~⑤로 군집마다 상위 단어를 고른다.
- ✓ 토픽 수와 이상치 비율은 min_cluster_size 같은 설정에서 나온다.
- ✓ 토픽 이름은 상위 단어로 후보를 정하고 원문으로 확인한다.



참고 문헌

Grootendorst, M. (2022). *BERTopic: Neural topic modeling with a class-based TF-IDF procedure*. arXiv:2203.05794

McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv:1802.03426

McInnes, L., Healy, J., & Astels, S. (2017). *hdbscan: Hierarchical density based clustering*. Journal of Open Source Software, 2(11), 205.

Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates*. PAKDD 2013, 160–172.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). *Latent Dirichlet Allocation*. Journal of Machine Learning Research, 3, 993–1022.

Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K., & Harshman, R. (1990). *Indexing by Latent Semantic Analysis*. JASIS, 41(6), 391–407.

Hofmann, T. (1999). *Probabilistic Latent Semantic Analysis*. UAI 1999, 289–296.

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*. arXiv:1301.3781

Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. EMNLP-IJCNLP 2019. arXiv:1908.10084

Angelov, D. (2020). *Top2Vec: Distributed Representations of Topics*. arXiv:2008.09470

BERTopic 공식 문서. *The Algorithm*. maartengr.github.io/BERTopic/algorithm/algorithm.html

scikit-learn 예제. *Demo of HDBSCAN clustering algorithm*. scikit-learn.org

nlpai-lab. *KURE-v1*. Hugging Face 모델 페이지, huggingface.co/nlpai-lab/KURE-v1